基于降级重建增强的新型大规模数据集遥感图像微小船舶检测方法

陈建奇、陈柯彦、陈浩、邹正霞和史振伟*，*Member, IEEE*

***Abstract*——**广阔海域内船舶的快速探测对于情报获取至关重要。大多数现代基于深度学习的船舶检测方法侧重于在高分辨率（HR）遥感（RS）图像中定位船舶。在中分辨率（MR）遥感图像中的船舶检测方面所做的努力很少。 MR图像覆盖的区域比相同尺寸的HR图像要宽得多，因此有利于快速检测船舶。为此，我们提出了一种针对 MR RS 图像的微型船舶检测方法，即降级重建增强网络（DRENet）。与之前主要关注特征融合策略以提高检测器表达能力的方法不同，我们设计了一个额外的网络分支，即降级重建增强器，以学习在训练阶段回归输入图像的对象感知模糊版本。我们的直觉是，所提出的重建分支可能会引导骨干网更多地关注微小的船舶目标，而不是广阔的背景。此外，我们在检测器中加入了一个 CRoss 级多头注意力模块，通过利用自注意力机制进一步提高特征辨别能力。为了填补缺乏大规模 MR 船舶检测数据集的空白，我们引入了 Levir-Ship，它包含 3876 个 GF-1/GF-6 多光谱图像和超过 3K 的微型船舶实例。 Levir-Ship 上的实验验证了该方法的有效性和效率。我们的方法实现了 82.4 AP 和 85 FPS，优于许多最先进的船舶检测方法。我们的代码和数据集可在 https://github.com/WindVChen/DRENet 上获取。

***Index Terms*——**卷积神经网络（CNN）、船舶检测、深度学习、光学图像、遥感。

一、简介

光学遥感（RS）图像中的船舶HIP检测是指在RS图像中定位船舶并自动给出其位置和尺寸。船舶作为海上运输的主要载体,在军事和民用领域发挥着非常重要的作用[1]。遥感图像中船舶的准确快速检测一直是研究热点。

近年来，随着遥感技术的快速发展，光学图像中船舶检测的研究越来越多

该工作得到了国家重点研发计划项目（2019YFC1510905）、国家自然科学基金项目（62125102）和北京市自然科学基金项目（4192034）的资助。（通讯作者：施振伟）

陈建奇、陈克彦、陈浩和施振伟（北京航空航天大学宇航学院图像处理中心，北京 100191）；北京航空航天大学数字媒体北京市重点实验室，北京 100191；北京航空航天大学宇航学院，北京 100191 虚拟现实技术与系统国家重点实验室。

邹正霞（北京航空航天大学宇航学院制导导航与控制系，北京 100191）

因其内容丰富、表达直观的特点而活跃[2]-[6]。传统的船舶检测方法往往需要复杂的手工特征提取，并且不能适应不断变化的环境[7]，[8]。如今，深度学习（DL）技术，特别是卷积神经网络（CNN）已广泛应用于遥感图像船舶检测。与传统方法相比，基于深度学习的方法可以以端到端的方式学习鲁棒的多级特征和分类器。受到基于深度学习的探测器在计算机视觉（CV）领域取得巨大成功的启发，近年来，大量的工作将深度学习技术引入到遥感船舶检测任务中[9]-[17]，这证实了比传统探测器在准确性和稳定性方面更好的检测性能。

现有的基于深度学习的船舶检测方法大多是基于CV中的目标检测器进行修改的。光学遥感船舶检测的最新进展包括融合船舶形状先验[18]、从船舶首尾提取特征[12]以及应用船舶方向信息[19]。然而，这些方法大多数都专注于高分辨率（HR）图像，因此受益于丰富的纹理和清晰的边缘。

尽管HR RS图像中的船舶检测取得了巨大成功[19]-[21]，但在相对较低分辨率的RS图像（例如中分辨率（MR，约16m/像素）RS图像）的船舶检测方面却很少做出努力。[1]考虑到实际应用中对大范围海域监测和预警的迫切需要[22]、[23]，MR图像中的船舶检测至关重要。我们认为，MR RS 图像比 HR 图像更适合在广阔海域进行快速船舶检测，因为 MR 图像可以比相同尺寸的 HR 图像覆盖更广泛的区域。例如，要检测固定海域的船只，假设我们需要 1 小时的 16m/ 像素 MR 图像（GF-1），那么这意味着我们需要 256 小时，大约 10 天，才能在 1m/ 像素的 HR 图像（SkySat-1）中完成相同的任务。时间成本显然是难以承受的，尤其是在这样一个大数据时代。

现实世界 MR RS 图像中的船舶检测面临多项挑战。首先，MR RS 图像中的船舶检测可能会受到船舶纹理稀缺和边缘模糊的影响。例如，在 GF-1 图像（16m/像素）中，一艘船可能只占据 20 个像素。其次，在真实场景中，遥感图像可能被大量的分形云覆盖。复杂的成像条件可能

[1]Please refer to the website (https://doc.arcgis.com/en/imagery/workflows/resources/managing-medium-resolution-satellite-data.htm) for detailed definitions of high resolution and medium resolution.

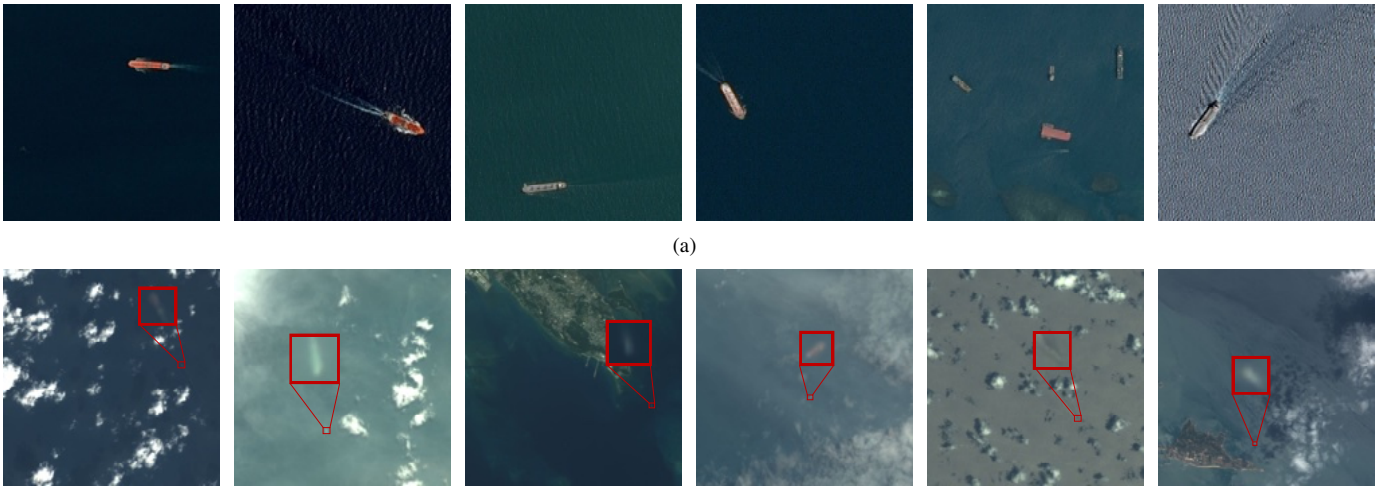

(a)

(b)

图1 。来自不同数据集的 512×512 大小的样本。 (a)：空客船舶检测竞赛数据集[2]的样本，空间分辨率为2m，高 河(b)：来自 Levir-Ship 数据集的样本，空间分辨率为 16m。

在传统检测器中也会引起许多误报。图1给出了HR图像和MR图像的直观对比。 MR 图像中的船只很难被识别（为了获得最佳视图而缩放），也很难与破碎云区分开来。大多数检测网络侧重于通过特征融合[11]、[24]和跨阶段连接[21]、[25]来提高脊柱或颈部的特征表达能力。我们认为，这种特征增强方法正在努力提取微小船舶目标的辨别特征。

为了解决上述问题，我们提出了一种降级重建增强船舶检测网络，称为DRENet - 基于遥感图像降级重建增强的微型船舶检测，它包含一个有效的主干网来提取鲁棒的特征表示，一个降级重建增强器来帮助主干网学习区分船舶与不相关的背景，以及一个用于定位船舶的对象检测器。该流程如图2所示。与之前主要关注特征融合策略[11]、[24]以提高检测器的表达能力的方法不同，我们设计了一个额外的网络分支，即降级重建增强器，以学习在训练阶段回归输入图像的对象感知模糊版本。在增强器中，我们设计了一种称为“选择性降级”的图像处理操作来模糊背景。我们的直觉是，所提出的重建分支可能会引导骨干网更多地关注微小的船舶目标，而不是广阔的背景（例如，分形云）。请注意，我们提出的增强器仅在训练阶段使用，在推理阶段无需计算。此外，我们在检测器中加入了 CRoss 级多头注意力（CRMA）模块，以利用自注意力机制进一步提高特征辨别能力。

据我们所知，目前还没有用于 MR RS 图像船舶检测的公共数据集。因此，我们提出了一个名为“Levir-Ship”的数据集来促进我们的研究。 Levir- Ship 包含 3876 张 512 × 512 像素的图像，收集自高分一号和高分六号卫星，空间分辨率为16m/像素。我们在 Levir-Ship 上进行了实验，结果表明了我们方法的有效性和效率。

我们的工作贡献可概括如下：

- 我们提出了一种有效的微型船舶检测方法（DRENet）。利用退化的重建增强器来引导主干网络更多地关注目标而不是背景，并引入跨阶段多头注意力来进一步提高检测器的辨别能力。
- 我们引入了 Levir-Ship 检测数据集，由 3876 张 GF-1/GF-6 图像（每个尺寸为 512×512 像素，空间分辨率为 16m/像素）和超过 3K 个微型船舶实例组成。
- Levir-Ship 上的大量实验验证了所提出方法的有效性和效率。我们的方法达到了 82.4 AP 和 85 FPS，并超越了几种最先进的船舶检测方法。

本文的其余部分组织如下。相关工作在第二节介绍。在第三节中，我们详细描述了我们的方法。第四节描述了 Levir-Ship 数据集以及与其他船舶检测数据集的比较。第五节报告了实验结果，第六节得出结论。

二.相关工作

数十年来，船舶检测已被广泛研究。一般来说，传统方法执行多阶段从粗到细的过程来获得检测结果[28]-[32]。检测过程通常可以分为两个步骤——区域提议和区域细化，并利用手工特征。尽管在某些场景下取得了一些良好的效果，但这些方法容易受到复杂情况的影响，并且严重依赖于先前和复杂的操作程序。

近年来，受益于硬件和大数据的发展，出现了许多有效的深度学习目标检测方法

[2]https://www.kaggle.com/c/airbus-ship-detection/overview.

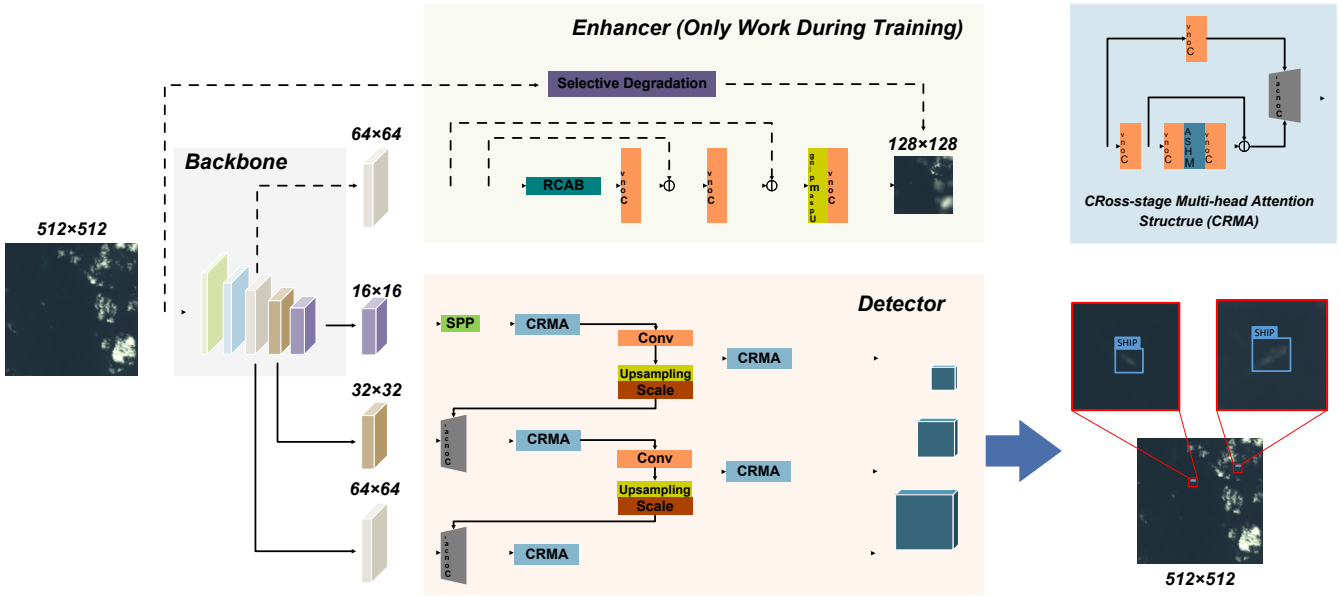

图2.DRENet的整体结构。 a) 主干：一个轻量级的主干，可以有效地进行稳健的特征提取。 b）增强器：提出的降级重建增强器，用于指导主干网通过回归降级图像来提取许多判别性特征。降级的图像来自提议的“选择性降级”操作。 c) 检测器：显示最终检测结果的检测器。我们在探测器中引入了跨级多头注意力（CRMA）模块，该模块可以获得较大的感受野来准确定位船舶，同时节省大量计算量。 （关于RCAB和SPP的详细信息，请参阅[26]和[27]。上采样层的实现与[26]和[27]一致，在检测器中使用最近邻插值，而在增强器中使用子像素卷积。）

已被提出[33]。它们更加灵活、统一、处理任务能力强，可分为两阶段方法和一阶段方法。两阶段方法主要基于R CNN系列[34]-[37]。他们通常会首先获取候选边界框，然后对候选结果进行分类和回归。与两阶段方法相比，以 Yolo [27]、[38]-[41]、SSD [42]、RetinaNet [43]、EfficientDet [44]为首的一阶段方法直接给出检测结果。它们获得了较高的检测速度，但总体上牺牲了一点精度。然而，两阶段和一阶段方法都依赖于锚框的设置，这需要大量的先验知识并限制了方法的泛化。因此，提出了一系列无锚点方法，例如CornerNet [45]、CenterNet [46]、FCOS [47]等，它们可以防止锚框初始化并获得准确的检测结果。

在上述方法的推动下，近年来出现了许多有效的遥感图像目标检测方法[48]-[53]。例如，王*et al*。 [49]提出了一种单阶段方法，Zhang *et al*。 [50]提出了一种无锚方法，Huang *et al*。 [52]提出了一种对象适应标签分配，取得了许多好的结果。虽然更具体地针对船舶目标，但许多方法对利用深度学习技术在遥感图像中进行船舶检测做出了巨大贡献。李*et al*。 [11]提出了一种基于Faster-RCNN的适应不同规模船舶的分层选择性滤波层结构。田*et al*。 [12]在Mask-RCNN的基础上添加了空洞空间金字塔池化，并使用密集层跳跃连接来利用主干中的特征信息，有效地实现了较高的检测精度。陈*et al*。 [24]在YOLOv3中引入了扩张卷积和注意力机制，并提出了ImYOLOv3。此外，研究人员引入先验信息以获得高性能。张*et al*。 [18]根据船舶结构预先设计候选目标的结构，然后将建议输入CNN以检测船舶。吴*et al*。 [20]利用船头的突出点通过定位船头来检测船舶。唐*et al*。 [54]利用船舶与周围环境之间的色调、饱和度和明度的差异来提取船舶。这些方法通常关注HR图像，利用清晰边缘和丰富纹理提取的特征来实现高性能。然而，在解决小型船舶检测问题时，它们可能表现不佳。在本文中，我们提出 DRENet 来解决微型船舶检测问题。

三. 方法论

如图 2 所示，DRENet 由高效主干网、降级重建增强器 (DRE) 和船舶检测器组成。我们以 YOLOv5s（YOLOv5 的小型版本）[27]为骨干来有效地提取多尺度图像特征。降级重建增强器旨在通过在训练阶段对输入图像的对象感知模糊版本进行回归来引导主干网络获取许多判别性特征。增强器的监督来自于我们提出的“选择性降解”操作。在检测器中，我们引入了一个 CRoss 级多头注意力（CRMA）模块，以更好地在输入图像中定位船舶。下面将详细介绍。

Algorithm 1 Selective Degradation for obtaining DRE supervision information

Input: I, the input image
Input: G, all the ground-truth boxes set in I
Define $F(\cdot)$, an increasing function to adjust the mean kernel size
Define $Center(\cdot)$, a function to get the box's central coordinate
Define $Distance(\cdot,\cdot)$, a function to compute the Euclidean Distance between two inputs
Define $EvenInt(\cdot)$, a function to return the nearest even number that is less than the input
Define $Resize(\cdot)$, a function to resize the image by nearest neighbor interpolation
Output: $\hat{I}$, the label of I in DRE

for $i = 0;\ i < H;\ i++$ **do**
  for $j = 0;\ j < W;\ j++$ **do**
    $k \leftarrow +\infty$
    for each $g \in G$ **do**
      $c \leftarrow Center(g)$
      $t \leftarrow Distance((i,j),c)$
      if $t < k$ **then**
        $k = t$
      end if
    end for
    $k = F(k)$
    $k \leftarrow EvenInt(k)$
    $\hat{I}(i,j) = \frac{1}{(k+1)^2}\sum_{m=i-\frac{k}{2},n=j-\frac{k}{2}}^{m=i+\frac{k}{2},n=j+\frac{k}{2}} I(m,n)$
  end for
end for
$\hat{I} = Resize(\hat{I})$
return $\hat{I}$

A. Degraded Reconstruction Enhancer

退化重建增强器（DRE）利用骨干网提取的特征来重建退化的输入图像，这可以引导骨干网更多地关注船舶，保留更多有关物体的信息，并省略复杂的背景。

1) Supervision of DRE: 在这一部分中，我们提出了一种名为“选择性降解”的方法来为增强器生成标签。选择性降级具有过滤的性质，在原始图像的不同位置上执行不同大小的平均过滤器。选择性退化的细节如算法 1 所示。图 3 描述了如何获得图像中某个位置的平均内核大小。通过选择性退化，我们可以得到一个“伪显着图”，其中船舶被完整保留，背景被处理为模糊。通过DRE的训练，骨干网将更多地关注微小的船只，而不是背景的纹理、细节或分形云。

2) Design of DRE: 如图2所示，我们将主干网的特征图作为增强器的输入。这里我们只利用形状为 64 × 64 的特征图

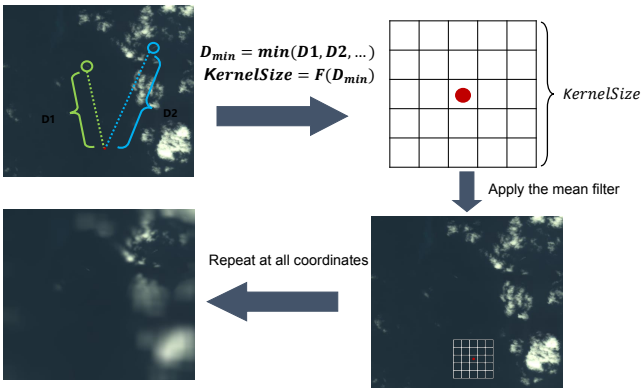

图3.选择性降解的具体操作：计算每个点的平均过滤核大小。 $D1$和$D2$表示从当前像素位置到每个船舶目标的距离，而$F(\cdot)$是调整平均内核大小的递增函数，其中输出，即平均内核大小将随着D_{min}的增加而增加。

利用性能和便利性来重建形状为 128 × 128 的退化标签。我们参考现有的超分辨率方法[26]来设计DRE的结构，但也存在一些差异。在[26]中，由于目标是提高超分辨率图像的质量，因此网络实际上是复杂且深入的。然而，我们的目标不是重建完美的选择性降解标签，而是获得主干的判别性特征表示。因此，我们制作了一个相对较浅的增强器网络，仅使用单个RCAB（Residual Channel Attention Block，[26]中的一个组件模块），以更加专注于主干网络的训练。基于“选择性降解”机制，增强器的标签聚焦于舰船目标，省略了复杂的背景。因此，增强器提供了在主干中获得鲁棒特征表示的趋势，并更准确地对船舶进行分类。

与现有的超分辨率方法[26]、[55]、[56]相比，所提出的DRE更侧重于改善微型船舶的检测结果。 DRE的监督是输入图像的对象感知模糊版本（与现有超分辨率方法的清晰图像不同），它可以引导主干网络更多地关注船舶，并且对复杂背景的干扰具有更强的鲁棒性。此外，与使用较高图像分辨率标签的现有超分辨率方法不同，我们提出的 DRE 重建了比输入图像（512 × 512）更低图像分辨率（128 × 128）的标签，这节省了大量计算和内存。 DRE 的结构也比现有的超分辨率方法更简单、更浅。

B. Efficient Detector

为了实现高效的船舶检测，我们的检测器基于 YOLOv5。我们对微小船舶检测任务进行了一些修改，以进一步提高效率。

为了以短而快的路径将低层特征的丰富空间信息传播到深层特征，YOLOv5采用了PAN[57]结构。但是，当将锚点分配给小型船舶对象中的每个输出层时

检测时，大部分边界框落在浅检测层上，而很少的边界框落在深检测层上。这实际上是一个耗时的操作，但对于丰富深度检测层的空间信息却没有什么好处。在DRENet中，我们删除了PAN路径以提高检测速度。

考虑到 FPN [58] 的不同输出层分配的训练样本数量不平衡，我们在检测器中的两个上采样层后面添加了两个“缩放层”（如图 2 所示），遵循 [59] 的工作。缩放层实际上只是一个可学习的参数，可以平衡 FPN 自下而上路径层中不同输出层的反向传播梯度。假设自下而上的路径由浅到深有两层C1、C2，对应自上而下的路径有两层P1、P2。在原始FPN中，$P1 = C1 + upsample(P2)$，在我们添加尺度层后，它变成了$P1 = C1 + \alpha \times upsample(P2)$，其中$\alpha$是一个可学习的参数。

为了实现全图像感受野，我们提出了一个 CRossstage 多头注意力（CRMA）模块，并取代了 YOLOv5 瓶颈中的类 CSP 层。 YOLOv5 中的类 CSP 层是基于 CSPNet [60] 设计的。该结构将输入从通道维度分成两半，然后将这两部分传递到两个分支（一个分支具有许多卷积运算，而另一个分支只有相同的映射），最后将两个分支的输出连接起来作为最终输出。在我们的工作中，我们认为分支中的许多卷积成本效益较低，并将其替换为[61]中设计的多头自注意力（MHSA）层，与[62]中的原始版本相比，它可以在保持低参数和复杂性的同时扩大网络的感受野，并且更适合视觉任务（使用相对位置编码和2D风格的Q、K、V）。通过融合CSPNet的思想和MHSA层，我们构建了CRMA模块。 CRMA 的更多细节如图 2 和表 I 所示。另请注意，我们在 YOLOv5s 的瓶颈中用 CRMA 替换了所有五个类似 CSP 的层，这可以在保持良好性能的同时大大减少网络的计算和复杂性。

表 I CRMA 配置详细信息。 CBS 代表卷积、批量归一化和 SILU 激活函数的运算。 MHSA 表示多头自注意力层。

Input: 16×16×512				
Pathway	Layer	Filters	Size	Output
1	CBS	256	1×1	16×16×256
	CBS	128	1×1	16×16×128
	MHSA	—	—	16×16×128
	CBS	256	1×1	16×16×256
	Residual	—	—	16×16×256
2	CBS	256	1×1	16×16×256
Output	Concat	—	—	16×16×512

C. Loss Function

DRENet的损失函数由两部分组成，包括增强器损失和检测器损失。

1) Enhancer Loss: 我们应用均方误差（MSE）来形成增强器的重建误差。损失函数的公式如下：

$$Loss_{enhancer} = \frac{\sum(y^* - y)^2}{N} \tag{1}$$

其中y^*表示重建结果的像素值，y表示“选择性退化”标签的像素值，N表示总像素数。

2) Detector Loss: 检测器损失函数包含回归损失和分类损失。我们在目标检测任务中进行典型的损失 - CIoULoss [63] 用于回归误差，二元交叉熵损失用于分类。在 DRENet 中，它们被定义为：

$$loss_{reg} = 1 - CIoU \tag{2}$$

$$CIoU = IOU - \frac{\rho^2(b, b^{gt})}{c^2} - \frac{\nu^2}{1 - IOU + \nu} \tag{3}$$

$$\nu = \frac{4}{\pi^2}(\arctan\frac{w^{gt}}{h^{gt}} - \arctan\frac{w}{h})^2 \tag{4}$$

其中b和b^{gt}表示预测框和目标框的中心点，$\rho(\cdot)$表示欧氏距离，c是覆盖两个框的最小包围框的对角线长度，ν衡量长宽比的一致性，w^{gt}，h^{gt}，w，h分别表示两个框的宽度和高度。

$$loss_{cls} = -\frac{\sum(y_n \times \ln y_n^* + (1 - y_n) \times ln(1 - y_n^*))}{n} \tag{5}$$

其中n表示所有锚框的数量，y_n^*表示第n个预测边界框的概率。 y_n 是与预测边界框对应的标签，由 $CIoU$ 表示。最后，我们设计平衡因子为0.05的探测器损耗。

$$Loss_{detector} = loss_{reg} + 0.05 \times loss_{cls} \tag{6}$$

3) DRENet Loss: 增强器和检测器联合训练可能会在两个分支之间出现不平衡，从而导致次优。如何权衡这两个分支对船舶检测的性能影响很大。受到肯德尔 (Kendall) *et al* 工作的激励。 [64]，我们设计了一种自动平衡增强器和检测器的训练偏好的方法，这是通过两个可学习的权重系数来实现的。最后，DRENet 损失定义为：

$$Loss = \frac{1}{2a^2}Loss_{enhancer} + \frac{1}{2b^2}Loss_{detector} + \ln a + \ln b \tag{7}$$

其中 a 和 b 是网络自动学习的两个系数。在训练中，$Loss$ 的前两项中的a和b往往是较大的值，而在后两项中，它们往往是较小的值。它们是相互调节的。这样的设计可以帮助训练进展顺利、稳定。

D. Implementation Details

我们的主干遵循 YOLOv5s 的设计。主干网中有 5 个阶段，每个阶段下采样 2，因此我们有不同的特征图：256×256、128×128、64×64、32×32 和 16×16。将 64×64、32×32 和 16×16 的特征作为检测器的输入，通过推理得到船舶的概率、位置和形状。至于增强器，我们采用 64 × 64 特征图来重建形状为 128 × 128 的退化标签。

我们采用随机梯度下降（SGD）优化器，动量为 0.99，权重衰减为 0.0005。学习率最初设置为 0.01，并在余弦退火策略中衰减，直到 500 个时期。批量大小为16。对于损失中两个权重系数a和b的优化，我们采用自适应矩估计（Adam）优化器，学习率设置为0.01。值得注意的是，增强器和检测器在训练阶段联合优化，但在测试阶段，可以删除增强器，只使用检测器。

四．莱维尔船

近几十年来，光学遥感领域出现了许多有效的物体检测数据集。

NWPU-VHR-10 [65]包含10个类别的800张图像。然而，只有 57 张图像，包括总共 302 艘船，这不足以训练 DL 网络，并且会出现过度拟合。此外，数据集的空间分辨率为0.5-2m。

HRSC2016 [66]是用于船舶检测的单类数据集。图片均来自6个知名端口。总共有 1070 张图像和 2976 个物体。数据集的空间分辨率为0.4-2m。

DIOR [67]是近年来提出的一个比较大的数据集。它包含 20 个类别、23463 张图像和 192472 个实例。船舶类别共有 2702 张图像和 62400 个对象。然而，该船也处于高空间分辨率下。

HRRSD [68]是最近提出的另一个大规模RS数据集。有 13 个类别、21761 张图像和 55740 个实例。它包含2165张图像，3886个船舶物体，但0.15-1.2m的分辨率仍然太高。

大多数船舶检测数据集侧重于高空间分辨率，例如 0.3m、0.5m 和 2m [65]–[68]。很少有数据集集中于空间分辨率较低的微小船舶物体。在我们的工作中，我们提出了一个空间分辨率为 16m 的小型船舶检测数据集，名为 Levir-Ship。

Levir-Ship 中的图像是由高分一号和高分六号卫星的多光谱相机捕获的。我们只使用 R、G 和 B 波段。数据集中收集了 85 个场景，像素分辨率在 10000×10000 到 50000×20000 之间。我们对原始图像进行裁剪，最终得到 1973 个正样本和 1903 个负样本，大小为 512×512。如图 4 所示，我们绘制了 Levir-Ship 数据集中船舶宽度/高度的分布。我们可以观察到 Levir-Ship 中的船舶像素大小几乎低于 20×20，并且集中在 10×10 左右。 Levir-Ship中的船舶与广阔的背景相比相对较小，这给检测网络带来了许多挑战。

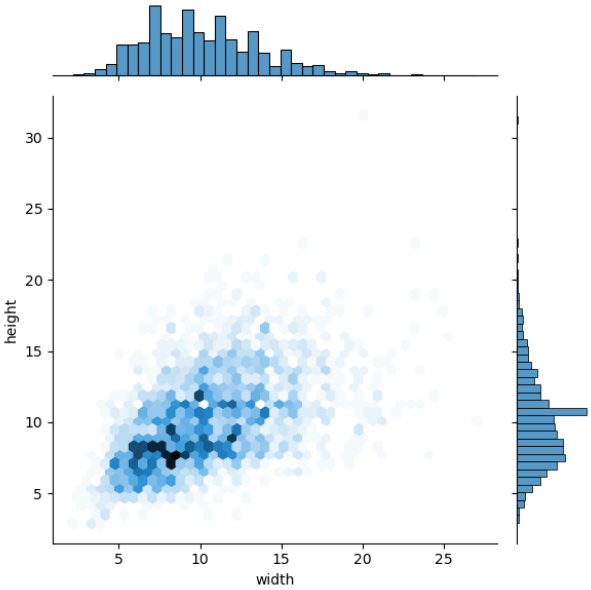

图 4. LEVIR-SHIP 中船舶目标尺寸统计。我们以实际船舶目标的最小外接矩形作为衡量标准。

表 II 显示了 Levir-Ship 和几个现有 RS 目标检测数据集之间的比较。 Levir-Ship中的船舶周围背景复杂，与HR图像中的船舶相比，难以识别。此外，由于不同时间、不同摄影师、不同地点的影响，图像呈现出不同的状况，这给任务带来了很多挑战。

从图5中我们可以看到背景比较复杂，图像中的船只即使放大几倍也很难找到。同时，由于Levir-Ship覆盖了多种环境条件，深度学习网络可以获得更好的泛化性、稳定性和充分性。

五、实验结果与分析

在本节中，我们对所提出的方法进行实验比较分析。我们的实验基于Levir-Ship，我们将数据集随机分为训练集、验证集和测试集（详细信息如表III所示）。所有实验均在 NVIDIA Tesla V100 GPU 上实施。

A. Evaluation Metrics

我们通过检测精度和模型复杂性来评估所提出方法的有效性和效率。这些指标包括平均精度 (AP)、浮点运算 (FLOP)、模型参数和每秒帧数 (FPS)。详细说明如下。

为了评估检测精度，我们使用 IoU 大于 0.5) 时的 AP_{50}（预测为真正样本作为评估指标来衡量模型的检测精度。在计算AP值时，我们采用COCO数据集中说明的方法（在Precision-Recall曲线中，根据分类置信度，采样了101个点

表 II 拟议的 Levir-Ship 数据集与四个公开可用的物体检测数据集之间的比较。BB 编号表示边界框的数量。对于包含多个类别的数据集，此处仅列出有关船舶类别的信息。

Dataset	Images Number	BB Number	Source	Resolution	Year
NWPU VHR-10	57	302	Google Earth	0.5-2m	2014
HRSC2016	1070	2976	Google Earth	0.4-2m	2016
DIOR	2702	62400	Google Earth	0.5-30m	2018
HRRSD	2165	3886	Google Earth & Baidu Earth	0.15-1.2m	2019
LEVIR-SHIP (Ours)	3876	3219	GaoFen-1 & GaoFen-6	16m	2021

(a) Images with different amounts of cloud

(b) Images of different land percentages

(c) Images of different light intensity

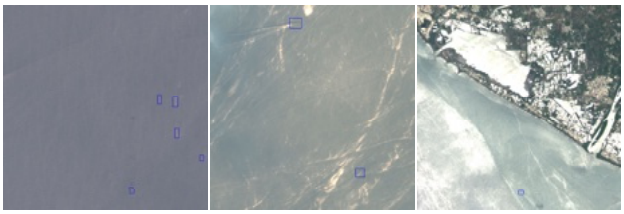

(d) Images of different sea area characteristics

图5. LEVIR-SHIP中包含的数据在船舶检测过程中可能遇到的不同情况下的部分显示。蓝色边界框是基本事实。

表3 训练集、验证集、测试集的划分

	Image number	Target number
Training set	2320	2002
Validation set	788	665
Test set	788	552

等间隔，然后对这些点对应的Precision值进行累加平均，得到最终的AP值），以保证Precision-Recall曲线面积的计算更加准确。我们使用 FLOP、参数和 FPS 来反映检测速度。

B. State-of-the-art Comparison

我们将 DRENet 与 Levir-Ship 数据集上的其他最先进的船舶检测网络进行比较，包括 YOLOv3 [40]、YOLOv5s [27]、Retinanet [43]、SSD [42]、FasterRCNN [36]、Efficient Det [44]、FCOS [47]、CenterNet [46]、HSFNet [11]、ImYOLOv3 [24]、DFR 和Tian *et al*提出的RFE结构。 [12]。最后三种方法是针对船舶检测任务提出的。我们也尝试与一些传统的比较 SVDNet [28]和PCANet [69]（配置为[28]）等方法，但不幸的是发现这些方法失败了，因为船舶目标只覆盖了图像的一小部分区域。除非另有说明，我们使用批量大小 16 对所有网络进行 500 轮训练。

表四显示了网络的比较结果。可以看出，与其他方法相比，我们提出的方法实现了最高的检测精度和实时检测速度。 DRENet 与最接近的竞争对手 EfficientDet-D2 [44] 相比，在 AP 上有 1.5 点的差距，同时速度更快 (85 vs.21 FPS)。与最快的 YOLOv5s [27] 相比，DRENet 速度稍慢，但准确得多（82.4 vs.75.6 AP）。此外，DRENet 的 Params 和 FLOP 都很小。这些都可以证明DRENet在微小船舶检测任务上的优异检测性能。

图6给出了DRENet和其他方法之间的一些检测结果。蓝色框代表真正的阳性检测。红色框表示假阴性检测。黄色框表示假阳性样本。图中从上到下，背景的复杂程度逐渐升高。图像中的船舶表现得非常小，可区分的特征不够清晰。与此同时，一些船只被破碎云包围，给检测带来了挑战。我们可以观察到我们的方法实现了更好的检测

表 IV 与一些众所周知的检测方法和最先进的船舶检测方法的比较。粗体代表最佳指标。

Methods	Params(Inference)	FLOPs(Inference)	AP	FPS
YOLOv3	61.52M	99.2G	69.9	61
YOLOv5s	7.05M	10.4G	75.6	**95**
Retinanet (ResNet50)	36.33M	104.4G	74.9	12
SSD (VGG16)	24.39M	175.2G	52.6	25
FasterRCNN (VGG16)	136.70M	299.2G	70.8	10
EfficientDet-D0	**3.84M**	**4.6G**	71.3	32
EfficientDet-D2	8.01M	20.0G	80.9	21
FCOS (ResNet50)	5.92M	51.8G	75.5	37
CenterNet (Hourglass-104)	191.24M	584.6G	77.7	25
HSFNet	157.59M	538.1G	73.6	7
ImYOLOv3	62.86M	101.9G	72.6	51
MaskRCNN (ResNet50)+DFR+RFE	24.99M	237.8G	76.2	6
DRENet (ours)	4.79M	8.3G	**82.4**	85

结果优于其他方法。 DRENet 可以检测到更多的真阳性船舶并错过更少的目标。此外，与图中所示的其他方法检测结果相比，可以很好地避免误报检测。例如，对于第 3 行图像，除了 DRENet 之外，没有提到的方法可以找到云后面的船。对比结果表明DRENet对于微小船舶目标检测任务具有更高的适用性和鲁棒性。

为了进一步分析我们的方法在不同背景情况下的性能，我们根据不同的背景情况将测试集粗略地分为五个子集：“蛤海”、“薄云”、“厚云”、“强波”和“碎云”。为了更好地说明这些情况之间的差异，我们为每个子集选择一个示例图像，如图7所示。表V显示了DRENet与其他方法在不同情况下的比较，从中我们可以观察到“厚云”、“强波”和“分形云”子集比其他两个子集更困难，因为其他方法的性能在这些场景中下降了很多。从结果中我们可以看出，我们的方法对于“分形云”等复杂背景比其他方法更加鲁棒，同时在“平静的大海”等简单场景中也保持了良好的性能。

C. Controlled Experiment

1) Degradation Function F: 我们比较了采用不同函数 $F(\cdot)$调整平均核大小时对原始输入图像的退化效果，包括线性函数、对数函数和指数函数。如图8所示，可以看出指数函数进行了更明显的退化效果，能够更好地满足增强器突出船舶和模糊背景的需要。为了保留船舶的细节并最小化背景的影响，我们应用指数函数来计算均值滤波器的大小每个像素位置的内核。算法 1 中给出了步骤。

2) Design of Enhancer : 退化的重建增强器用于提取船舶目标和背景之间更可区分的基本特征表示。我们对增强器的不同结构和监督进行了实验。

不同的增强子结构。在这里，我们对增强器的不同内部结构进行比较，以选择最适合船舶检测任务的增强器结构。我们通过 AP 和网络复杂性来评估性能。表VI详细显示了结果。“n-RCAB”代表我们的增强子网络中包含的 RCAB 数量。“上采样”表示不同的上采样倍数，对应重建不同分辨率的Enhancer标签。从结果可以看出，当进行1个RCAB结构和2次上采样时，性能最好。当增强器变得更加复杂时，增强器的训练更多地集中在高层层，而不是主干的基本层。这可以说明为什么性能会随着结构的加权而下降。同时，当上采样因子变大时，退化图像的重建变得更加困难，这导致增强器的退化。那么经过训练的增强器就无法实现检测器所需的正确特征表示。

不同的监督形式。我们比较增强器中的不同标签生成策略，以获得对重建分支更好的监督。如表七所示，不同的生成策略对检测精度有不同的影响。我们采用的增强器结构是1个RCAB和2次上采样。从表中，我们可以得出一些观察结果。首先，与仅没有增强器的检测器相比，直接下采样可以提高检测性能。这可能是因为主干通过拟合标签保留了更多的空间信息，这

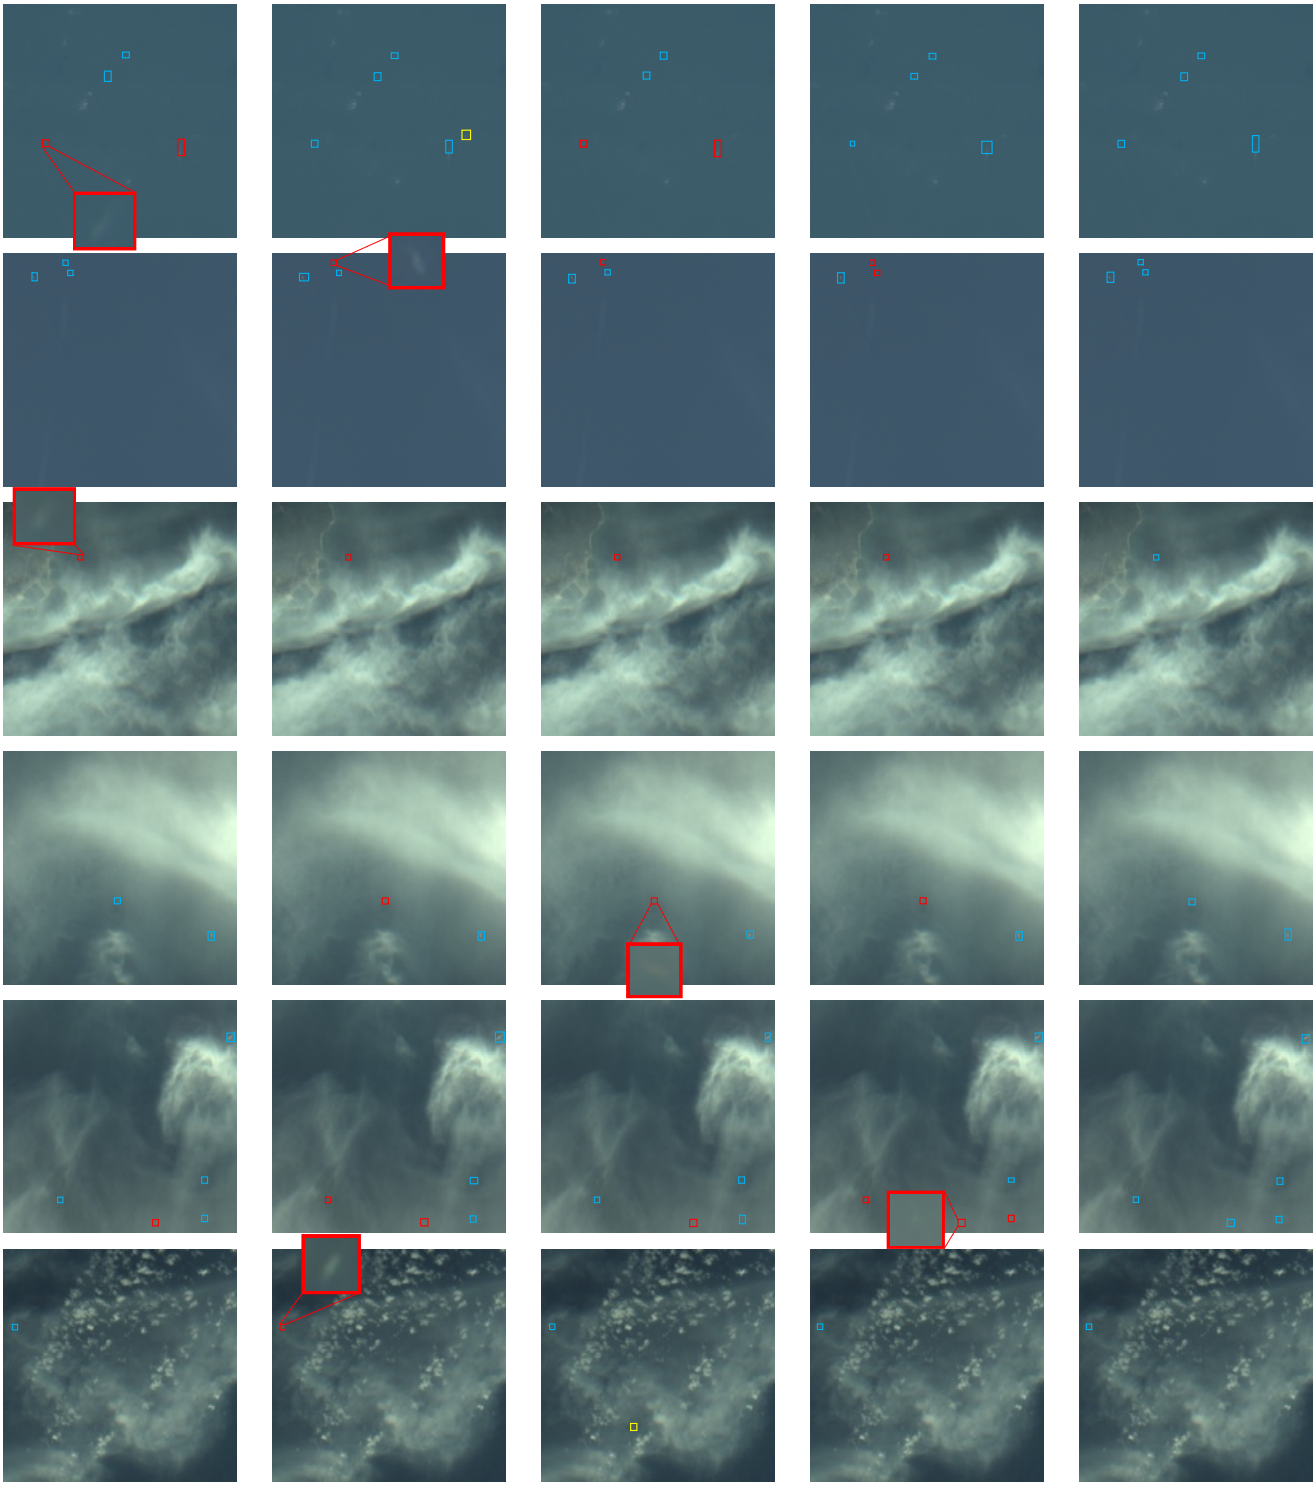

(a) (b) (c) (d) (e)

图6.不同方法检测结果比较。 (a) YOLOv5。 (b) EfficientDet-D2。 (c) ImYOLOv3。 (d)方法[12]。 (e) 我们的。蓝色框代表检测到的真实目标，红色框代表漏报目标，黄色框代表误报。为了便于观察，我们随机放大了一些错过的船舶目标。

为微小船舶的探测做出更多贡献。其次，我们还可以看到突然模糊方法降低了检测精度，这主要是因为Levir-Ship数据集中的一艘船只占据很小的区域，网络的训练会受到相对较小的损失。因此，网络学习偏离了原来的方向，无法在抑制背景的同时关注小船的细节。第三，通过使用“选择性降解”，即表七中的连续性模糊来生成标签，检测性能得到了显着提高。

(a) (b) (c) (d) (e)

图 7. 作为每种背景情况示例的图像。（一）平静的海面。 (b) 薄云。 (c) 厚云。 (d) 强波。 (e) 分形云。

表5 不同情况下DRENET与其他方法的比较，其中“数字”表示每种情况下的图像数量。最高 AP 值以粗体标记。

Situations	Number	YOLOv5s	EfficientDet-D2	ImYOLOv3	Method [12]	DRENet (ours)
calm sea	262	76.8	**83.0**	75.9	78.4	82.1
thin cloud	238	84.3	83.9	83.7	82.4	**87.3**
thick cloud	60	60.5	78.9	56.6	70.1	**86.8**
strong wave	101	73.4	73.3	62.8	71.8	**82.8**
fractus cloud	127	72.1	74.7	61.8	64.4	**76.5**

表六
C增强器中不同网络复杂性的比较。“训练”代表我们保留退化的重建增强器的训练过程。最高 AP 值以粗体标记。

Structure	n-RCAB	Upsampling	AP	Params(Train)	FLOPs(Train)
YOLOv5s	—	—	75.6	7.05M	10.4G
YOLOv5s+Degraded reconstruction enhancer	1	×2	**76.8**	8.25M	20.3G
	1	×4	76.2	8.84M	40.0G
	2	×2	76.6	8.55M	22.7G
	2	×8	75.6	9.73M	121.2G

表VII 增强剂中不同标签的比较。“突然模糊”是指对目标之外的区域进行均匀模糊，而不对目标周围的区域进行操作，而“连续模糊”则表示应用指数函数（如$F(\cdot)$）进行选择性退化。最高 AP 值以粗体标记。

Label generation method	AP
Original (YOLOv5s)	75.6
Down-sampling	76.6
Sudden-blur+Down-sampling	75.2
Continuity-blur(λ=1.01)+Down-sampling	76.8
Continuity-blur(λ=1.03)+Down-sampling	**78.7**
Continuity-blur(λ=1.05)+Down-sampling	77.1

另外，我们在退化函数F中采用不同的参数λ，最终选择1.03，因为它的性能相对较好。

3) Structure of Detector: 我们对原始 YOLOv5s 原型进行了一些改进，以在微小船舶检测中获得更好的性能。为了验证不同修改的效果，我们进行了一系列的消融研究在探测器上。结果示于表VIII中。我们可以从表中得到一些观察结果。首先，通过添加“Scale Layer”，在不增加复杂性的情况下出现了微小的改进。可能是因为Scale Layer在一定程度上缓解了FPN中不同层训练不平衡的问题。其次，用我们提出的CRMA模块替换CSP瓶颈后，复杂度显着降低，检测AP提高了4.2。我们认为这是由于更大的感受野导致更丰富的特征，有利于微小船舶物体的检测。它验证了所设计的CRMA结构的有效性。我们进一步对是否去除PAN进行权衡。从表九中，我们可以观察到当去除PAN 结构时，网络参数和操作的数量大大减少，而检测精度几乎没有损失。因此，我们在最终模型中删除了 PAN。

与YOLOv5s原型相比，参数量和FLOPs分别减少了近−32%和−19%，而AP增加了4.7个点。改进后的探测器速度更快、模型更小、精度更高，更适合MR RS图像中的船舶检测。

4) Network Overall Setting: 在这一部分中，我们将对损失函数和训练策略进行实验。

损失函数。 DRENet 由增强器和

表 VIII 探测器修改的烧蚀研究。最佳值以粗体标记。

Network description	Scale	CRMA	AP	Params	FLOPs
Baseline (YOLOv5s)	×	×	75.6	7.05M	10.4G
Add Scale	✓	×	76.3	7.05M	10.4G
Replace CSP bottleneck with CRMA	×	✓	79.8	5.69M	9.1G
Add Scale and CRMA	✓	✓	**80.8**	**5.69M**	**9.1G**

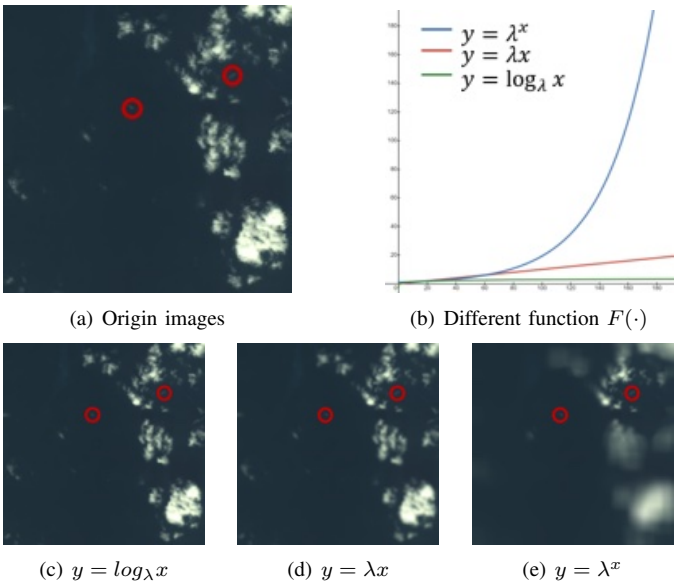

(a) Origin images (b) Different function $F(\cdot)$

(c) $y = log_\lambda x$ (d) $y = \lambda x$ (e) $y = \lambda^x$

图 8. 采用对数函数、线性函数和指数函数计算每个位置的平均滤波器内核大小时的退化效果。图像中的红色圆圈是船只。 λ是一个函数常量，设置它是为了确保船舶区域保持畅通。 x 是到发射目标的最短距离，y 表示内核大小。

表 IX 保留平底锅和取出平底锅之间的权衡。 W 表示保留，W/O 表示删除。

	AP	Params	FLOPs
w	**80.8**	5.69M	9.1G
w/o	80.3	**4.79M**	**8.3G**

检测器，这两个部分需要联合训练。总损失包含检测标签和退化重建标签的监督。包括DRENet Loss中提到的自动平衡学习方法（参见第III-C3节），我们还设计了一个固定平衡因子来验证性能。平衡因子固定的公式表示为:

$$loss = loss_{detector} + \alpha \times loss_{enhancer} \tag{8}$$

其中α是平衡检测器损失和增强器损失的固定因子。比较结果如表X所示。这表明自动权重学习方法可以带来显着的改进。同时，在该方法中，

表X 损失函数不同配置方法的比较。 α 表示两个分支损失函数之和的权重。最高 AP 值以粗体标记。

Combination description	weight α	AP
Fixed weight summation	100	80.9
	10	81.6
	1	81
	0.1	80.6
Automatic weight summation	—	**82.4**

表十一不同训练方法的比较。预训练是指先训练Enhancer，然后联合训练。最高 AP 值以粗体标记。

Training method	Pretrained epoches	AP
Joint train without pre-training	—	**82.4**
Joint train with pre-training	100	81.9
	300	81.4
	500	80.5
	1000	77.5

表 XII DRENET 对现有 HR 数据集的下采样版本的概括。

Method	Enhancer	Efficient Detector	AP
YOLOv5s	-	-	51.5
DRENet	+	-	52.8
	-	+	50.9
	+	+	51.6

固定平衡因子，随着因子α从0.1变大到10，AP也增加，这再次揭示了增强器的有效性。

培训策略。表 XI 显示了不同训练方法的结果。我们的目标是寻求更好的船舶检测性能，增强器只是一个辅助分支。所以我们尝试预训练增强器，然后进行联合训练。但实验结果表明，预训练的性能比直接联合训练要差，并且随着预训练epoch的增加，AP逐渐

拒绝。我们认为，出现这种现象主要是因为两个分支相辅相成。由于增强器可以被视为目标位置加目标分割，因此直接训练增强器更加困难，并且网络学习可能会出现恶化和发散。而探测器可以为增强器提供目标的位置引导，使其具有更好的学习效果。因此，增强器的预训练会导致检测精度较差，并且会随着epoch数的增加而加剧。

5) Generalization on Existing High-Resolution Dataset: 我们还分析了我们的方法在现有 HR 数据集上的推广，即在 HR 图像的下采样版本上进行实验。

这里我们选择 HRRSD 数据集来实现实验。考虑到HRRSD中图像的大小和分辨率（0.15-1.2m），我们首先将所有图像重塑为64×64，然后进行消融实验以揭示DRENet的性能。

从表 XII 的结果来看，当仅应用我们的高效检测器时，AP 值下降了一点（-0.6），我们认为这主要是由输入的大小引起的。由于图像尺寸仅为 64×64，经过网络主干处理后，CRMA 消耗的特征尺寸会更小，因此 CRMA 的大感受野特性无法比 YOLOv5s 的类 CSP 结构中的卷积运算获得更多优势。因此，当我们在高效检测器中去除 PAN 结构时，性能就会恶化，这也在表 IX 中得到了验证。

同时，我们还可以从结果中观察到我们的增强器继续显示出巨大的提升。当我们仅应用增强器时，AP 增加 +1.3 个点，当我们结合增强器和检测器时，我们的 DRENet 与基线 YOLOv5s 相比实现了接近的性能 (AP +0.1)。这些结果可以进一步证明我们的增强剂的有效性。考虑到 DRENet 中节省的计算量和复杂性（如表 IV 所示），即使在现有高分辨率数据集的下采样版本中，DRENet 实际上也实现了良好的性能。

六. 结论

在本文中，我们提出了一个微型船舶检测数据集 - “Levir-Ship”，以及一个高效的微型船舶检测网络 - DRENet，用于现实世界的微型船舶检测任务。 Levir-Ship包含来自GaoFen-1和GaoFen-6卫星的3876张图像，这些图像具有16m空间分辨率的多光谱相机。 DRENet 执行两个部分，包括用于在主干中获得更多可区分特征的增强器，以及用于对小型船舶进行有效检测的检测器。该增强器是免推理的，因此不会在应用程序中引入额外的推理成本。 Levir-Ship 上的实验验证了我们提出的 DRENet 与其他最先进的检测方法相比，具有更高的检测精度，同时保证了实时检测速度。

参考

[1] 何浩，林宇，陈凤，H.-M. Tai 和 Z. Yin，“通过加权姿态投票进行遥感图像中的近海船舶检测”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 55，没有。 6，第 3091–3107 页，2017 年。 [2] J. Han，D. Zhang，G. Cheng，L.Guo，J. Ren，“基于弱监督学习和高级特征学习的光学遥感图像目标检测”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 53，没有。 6，第 3325–3337 页，2015 年。 [3] H. Lin、Z. Shi 和 Z. Zou，“用于光学遥感图像近岸船舶检测的全卷积网络和任务分区”，*IEEE Geoscience and Remote Sensing Letters*，卷。 14、没有。 10, pp. 1665–1669, 2017. [4] F. Yang, Q. Xu, and B. Li, “基于显着性分割和结构-lbp特征的光学卫星图像船舶检测”, *IEEE Geoscience and Remote Sensing Letters*, vol. 10, pp. 1665–1669, 2017. 14、没有。 5，第 602–606 页，2017 年。 [5] K. Chen、Z. Zou 和 Z. Shi，“使用稀疏令牌转换器从遥感图像中提取建筑物”，*Remote Sensing*，卷。 13、没有。 21，p。 4441, 2021. [6] W. Li, K. Chen, H. Chen, and Z. Shi, “地理知识驱动的遥感图像表示学习”, *IEEE Transactions on Geoscience and Remote Sensing*, 2021. [7] J. Xu, X. Sun, D. Zhang, and K. Fu, “利用鲁棒不变广义霍夫变换自动检测高分辨率遥感图像中的近海船舶，” *IEEE geoscience and remote sensing letters*，卷。 11、没有。 12，第2070-2074页，2014年。 [8] S. Li，Z. Zhou，B. Wang，and F. Wu，“一种通过船头分类和船体边界确定的新型近海船舶检测”，*IEEE Geoscience and Remote Sensing Letters*，卷。 13、没有。 12, pp. 1920–1924, 2016。 [9] S. Zhang, R. Wu, K. Xu, J. Wang, and W. Sun, “基于 R-cnn 的高分辨率遥感图像船舶检测”，*Remote Sensing*，卷。 11、没有。 6，p。 631, 2019. [10] L. He, S. Yi, X. Mu, and L. Zhang, “基于 gabor 滤波器和快速 rcnn 模型的海洋卫星图像船舶检测方法”, 见 *Proceedings of the 3rd International Conference on Computer Science and Application Engineering*, 2019, pp. 1-7. [11] Q. Li，L. Mou，Q. Liu，Y. Wang，and X. X. Zhu，“Hsf-net：光学遥感图像中船舶检测的多尺度深度特征嵌入”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 56，没有。 12，第 7147–7161 页，2018。 [12] L. Tian，Y. Cao，B. He，Y. Zhang，C. He 和 D. Li，“遥感图像中船舶目标检测的目标特征和密集特征重用网络驱动的图像增强”，*Remote Sensing*，卷。 13、没有。 7，p。 1327, 2021。 [13] A. Van Etten，“你只需看两次：卫星图像中的快速多尺度目标检测”，*arXiv preprint arXiv:1805.09512*，2018。 [14] Y. Wang、L. Wang、Y. Jiang 和 T. Li，“基于 yolov4 网络的自建数据集检测”，见 *2020 IEEE 3rd International Conference on Information Systems and Computer Aided Education (ICISCAE)*。 IEEE，2020 年，第 640–642 页。 [15] Y. Wang、C. Wang 和 H. Zhu，“将单次多盒检测器与迁移学习相结合，使用 Sentinel-1 sar 图像进行船舶检测”，*Remote sensing letters*，卷。 9、不。 8，第 780–788 页，2018。 [16] Y. Wang、C. Wang、H. Zhu、Y. Dong 和 S. Wei，“使用多分辨率 gaofen-3 图像的基于 Retinanet 的自动船舶检测”，*Remote Sensing*，卷。 11、没有。 5，p。 531, 2019. [17] Y. Gui, X. Li, and L. Xu, “一种用于合成孔径雷达船舶探测的多层融合光头探测器”, *Sensors*, vol. 531, 2019. 19、没有。 5，p。 1124，2019。[18]R.Zhang，J.Yao，K.Zhang，C.Feng，J.Zhang，“基于 S-CNN 的高分辨率遥感图像船舶检测”。 *International Archives of the Photogrammetry, Remote Sensing & Spatial Information Sciences*，卷。 [19] L. Li, Z. Zhou, B. Wang, L. Miao, and H. Zong, “一种基于CNN的通过旋转边界框在小时光学遥感图像中精确检测船舶的新方法”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 41，2016。 59，没有。 [20] F. Wu, Z. Zhou, B. Wang, and J. Ma, “基于光学卫星图像中卷积神经网络的近海船舶检测”，第 1 卷，第 686–699 页，2020 年。 11、没有。 [21] W. Liu, L. Ma, and H. Chen, “光学遥感图像中任意导向的船舶检测框架”，第 11 页，第 4005–4015 页，2018 年。 15、没有。 6, pp. 937–941, 2018. [22] Y. You, Z. Li, B. Ran, J. Cao, S. Lv, and F. Liu, “基于深度卷积神经网络的船舶检测广域目标搜索系统”，*Remote Sensing*, vol. 6, pp. 937–941, 2018. 11、没有。 17，p。 1965 年，2019 年。[23] Z. Song、H. Sui 和 L. Hua，“一种使用显着性检测和 cnn 的大规模光学遥感卫星图像分层目标检测方法”，*International Journal of Remote*

Sensing，卷。 42、没有。 8，第 2827–2847 页，2021 年。[在线]。可用：https://doi.org/10.1080/01431161.2020.1826059 [24] L. Chen、W. Shi 和 D. Deng，“基于注意力机制的改进 yolov3，用于光学遥感图像中快速准确的船舶检测”，*Remote Sensing*，卷。 13、没有。 4，p。 660, 2021. [25] L. Chen, W. Shi, C. Fan, L. Zou, and D. Deng,“一种基于深度残差密集网络的光学遥感图像船舶检测新方法”，*Remote Sensing*，第 660 期，2021 年。 12、没有。 19，p。 3115, 2020. [26] Y.Zhang, K.Li, K.Li, L. Wang, B.Zhong, and Y.Fu,“使用非常深的残差通道注意网络的图像超分辨率”，in *Proceedings of the European conference on computer vision (ECCV)*, 2018, pp. 286-301. [27] G. Jocher、A. Stoken、J. Borovec、NanoCode012、A. Chaurasia、TaoXie、L. Changyu、A. V、Laughing、tkianai、yxNONG、A. Hogan、lorenzomammana、AlexWang1900、J. Hajek、L. Diaconu、Marc、Y. Kwon、oleg、wanghaoyang0106、 Y. Defretin、A. Lohia、ml5ah、B. Milanko、B. Fineran、D. Khromov、D. Yiwei、Doug、Durgesh 和 F. Ingham，“ultralytics/yolov5：v5.0 - YOLOv5-P6 1280 模型、AWS、Supervise.ly 和 YouTube 集成”，2021 年 4 月。[在线]。可用：https://doi.org/10.5281/zenodo.4679653 [28] Z. Zou 和 Z. Shi，“利用 svd 网络进行星载光学图像中的船舶检测”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 54，没有。 10，第 5832–5845 页，2016 年。 [29] G. Mattyus，“光学卫星图像上的近实时自动船舶检测”，*ISPRS Hannover Workshop*。 ISPRS 档案，2013 年，第 233–237 页。 [30] J. Han，P. Zhou，D. Zhang，G. Cheng，L.Guo，Z.Liu，S.Bu，J.Wu，“基于视觉显着性建模和稀疏编码判别学习的多类地理空间目标的高效同步检测”，*ISPRS Journal of Photogrammetry and Remote Sensing*，卷。 89，第37-48页，2014年。 [31] C. Zhu，H. Zhou，R. Wang，J.Guo，“一种基于形状和纹理特征的星载光学图像船舶检测的新型分层方法”，*IEEE Transactions on geoscience and remote sensing*，卷。 48，没有。 9，第 3446–3456 页，2010。 [32] Z. Shi，X. Yu，Z. Jiang，and B. Li，“基于异常检测器和局部形状特征的高分辨率光学图像中的船舶检测”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 52，没有。 8，第 4511–4523 页，2013。[33] Z. Zou、Z. Shi、Y.Guo 和 J.Ye，“20 年的对象检测：一项调查”，*arXiv preprint arXiv:1905.05055*，2019。[34] R. Girshick、J. Donahue、T. Darrell 和 J. Malik，“用于精确对象检测和语义分割的丰富特征层次结构”，参见 *Proceedings of the IEEE conference on computer vision and pattern recognition*，2014 年，第 580–587 页。 [35] R. Girshick，“Fast r-cnn”，载于 *Proceedings of the IEEE international conference on computer vision*，2015 年，第 1440–1448 页。 [36] S. Ren、K. He、R. Girshick 和 J. Sun，“更快的 r-cnn：通过区域提议网络实现实时对象检测”，*IEEE transactions on pattern analysis and machine intelligence*，卷。 39，没有。 6，第 1137–1149 页，2016 年。 [37] K. He、G. Gkioxari、P. Dollár 和 R. Girshick，“Mask r-cnn”，*Proceedings of the IEEE international conference on computer vision*，2017 年，第 2961–2969 页。 [38] J. Redmon、S. Divvala、R. Girshick 和 A. Farhadi，“你只看一次：统一的实时对象检测”，载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*，2016 年，第 779–788 页。 [39] J. Redmon 和 A. Farhadi，“Yolo9000：更好、更快、更强”，载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*，2017 年，第 7263–7271 页。 [40] Redmon, Joseph 和 Farhadi, Ali，“Yolov3：渐进式改进”，*arXiv preprint arXiv:1804.02767*，2018。 [41] A. Bochkovskiy，C.-Y。王和 H.-Y。 M. Liao，“Yolov4：目标检测的最佳速度和准确性”，*arXiv preprint arXiv:2004.10934*，2020。[42] W. Liu，D. Anguelov，D. Erhan，C. Szegedy，S. Reed，C.-Y。 Fu 和 A. C. Berg，“Ssd：单发多盒检测器”，*European conference on computer vision*。施普林格，2016 年，第 21-37 页。 [43] T.-Y。 Lin、P. Goyal、R. Girshick、K. He 和 P. Dollár，“密集物体检测的焦点损失”，*Proceedings of the IEEE international conference on computer vision*，2017 年，第 2980-2988 页。 [44] M. Tan、R. Pang 和 Q. V. Le，“Efficientdet：可扩展且高效的对象检测”，载于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*，2020 年，第 10 781–10 790 页。 [45] H. Law 和 J. Deng，“Cornernet：将对象检测为配对关键点”，*Proceedings of the European conference on computer vision (ECCV)*，2018 年，第 734-750 页。 [46] X. Zhou、D. Wang 和 P. Krähenbühl，“对象作为点”，*arXiv preprint arXiv:1904.07850*，2019。 [47] Z. Tian、C. Shen、H. Chen 和 T. He，“Fcos：全卷积单阶段对象检测”，《*Proceedings of the IEEE/CVF international conference on computer vision*》，2019 年，第 177 页。 9627–9636。 [48] Z. Zou和Z. Shi，“随机存取存储器：高分辨率航空遥感图像中目标检测的新范例”，*IEEE Transactions on Image Processing*，卷。 27、没有。 3，第1100-1111页，2017。 [49] G. Wang，Y. Zhuang，H. Chen，X. Liu，T. Zhang，L. Li，S. Dong，and Q. Sang，“Fsod-net：光学遥感图像的全尺寸物体检测”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 60，第 1–18 页，2021 年。 [50] T. 张、Y. Zhuang、G. Wang、S. Dong、H. Chen 和 L. Li，“用于光学遥感图像的多尺度语义融合引导的分形卷积目标检测网络”，*IEEE Transactions on Geoscience and Remote Sensing*，2021 年。 [51] Z. Huang、W. Li、X.-G. Xia、X. Wu、Z. Cai 和 R. Tao，“一种新颖的非局部感知金字塔和多尺度多任务细化检测器，用于遥感图像中的目标检测”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 60，第 1-20 页，2021 年。 [52] Z. Huang，W. Li，X.-G。 Xia 和 R.Tao，“用于任意面向对象检测的通用高斯热图标签分配”，*IEEE Transactions on Image Processing*，卷。 31，第1895-1910页，2022。 [53] Z. Huang，W. Li，X.-G。夏，王，杰，陶，“Lo-det：遥感图像中的轻量级目标检测”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 60，第 1-15 页，2022 年。 [54] G. Tang、S. Liu、I. Fujino、C. Claramunt、Y. Wang 和 S. Men，“H-yolo：基于感兴趣区域预选网络的单次船舶检测方法”，*Remote Sensing*，卷。 12、没有。 24，p。 4192, 2020. [55] 雷森、史振威、邹正霞，“基于局部-全局组合网络的遥感图像超分辨率”，*IEEE Geoscience and Remote Sensing Letters*，第 4192 期。 14、没有。 8，第 1243–1247 页，2017 年。 [56] S. Lei、Z. Shi 和 Z. Zou，“遥感图像超分辨率的耦合对抗训练”，*IEEE Transactions on Geoscience and Remote Sensing*，卷。 58，没有。 5，第 3633–3643 页，2019。 [57] S. Liu，L. Qi，H.qin，J. Shi 和 J. Jia，“用于实例分割的路径聚合网络”，*Proceedings of the IEEE conference on computer vision and pattern recognition*，2018 年，第 8759–8768 页。 [58] T.-Y。 Lin、P. Dollár、R. Girshick、K. He、B. Hariharan 和 S. Belongie，“用于对象检测的特征金字塔网络”，*Proceedings of the IEEE conference on computer vision and pattern recognition*，2017 年，第 2117-2125 页。 [59] Y.Gong，X.Yu，Y.Ding，X.Peng，J.Zhao，and Z.Han，“fpn 中微小物体检测的有效融合因子”，载于 *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*，2021 年，第 1160–1168 页。 [60] C.-Y.王，H.-Y。 M.廖，Y.-H。吴，P.-Y。陈，J.-W。 Hsieh 和 I.-H.叶，“Cspnet：一种可以增强 cnn 学习能力的新主干网”，载于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*，2020 年，第 390-391 页。 [61] A.斯里尼瓦斯，T.-Y。 Lin, N. Parmar, J. Shlens, P. Abbeel, 和 A. Vaswani，“视觉识别的瓶颈变压器”，载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*，2021 年，第 16 519–16 529 页。 [62] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser 和 I. Polosukhin，“注意力就是你所需要的”，*arXiv preprint arXiv:1706.03762*，2017 年。 [63] Z. Cheng、P. Wang、W. Liu、J. Li、R. Ye 和 D. Ren，“距离- iou 损失：更快更好地学习边界框回归”，*Proceedings of the AAAI Conference on Artificial Intelligence*，第 1 卷。 34、没有。 07，第 12 993–13 000 页，2020 年 4 月。[在线]。可用：https://ojs.aaai.org/index.php/AAAI/article/view/6999 [64] A. Kendall、Y. Gal 和 R. Cipolla，“使用不确定性来权衡场景几何和语义损失的多任务学习”，*Proceedings of the IEEE conference on computer vision and pattern recognition*，2018 年，第 7482-7491 页。 [65] G. Cheng，J. Han，P. Zhou，L.Guo，“基于部分检测器集合的多类地理空间目标检测和地理图像分类”，*ISPRS Journal of Photogrammetry and Remote Sensing*，卷。 98，第 119–132 页，2014 年。 [66] Z. Liu、L. Yuan、L. Weng 和 Y. Yang，“用于船舶识别的高分辨率光学卫星图像数据集和一些新基线”，

在*International conference on pattern recognition applications and methods*，卷。 2. SCITEPRESS，2017 年，第 324-331 页。 [67] K. Li，G. Wan，G. Cheng，L.Meng，J. Han，“光学遥感图像中的目标检测：一项调查和一个新基准”，*ISPRS Journal of Photogrammetry and Remote Sensing*，卷。 159，第 296-307 页，2020。 [68] Y. 张，Y. Yuan，Y. Feng，和 X. Lu，“用于超高分辨率遥感目标检测的分层稳健卷积神经网络”，*IEEE Transactions on Geoscience and Remote Sens- ing*，卷。 57、没有。 8，第 5535–5548 页，2019 年。[69] T.-H。 Chan、K. Jia、S. Gau、J. Lu、Z. Zeng 和 Y. Ma，“Pcanet：用于图像分类的简单深度学习基线？”*IEEE transactions on image processing*，卷。 24、没有。 12，第 5017–5032 页，2015 年。

陈建琪 (Jianqi Chen) 获得学士学位2021年于北京航空航天大学宇航学院图像处理中心获得博士学位。目前正在攻读硕士学位。毕业于北京航空航天大学宇航学院图像处理中心，获博士学位。他的研究兴趣包括深度学习、目标检测和人工智能安全。

陈克彦获得理学学士学位2019年毕业于北京航空航天大学宇航学院，获博士学位。目前正在攻读硕士学位。毕业于北京航空航天大学宇航学院图像处理中心，获博士学位。他的研究兴趣包括图像处理、机器学习和模式识别。

陈浩获得学士学位2017年于北京航空航天大学宇航学院图像处理中心获得博士学位，目前在北京航空航天大学宇航学院图像处理中心攻读博士学位。研究兴趣包括机器学习、深度学习和语义分割。

邹正霞获得理学学士和博士学位。 2013年、2018年于北京航空航天大学获博士学位。现任北京航空航天大学宇航学院副教授。 2018-2021年在美国密歇根大学安娜堡分校从事博士后研究。他的研究兴趣包括计算机视觉和遥感相关问题。他在TPAMI、TIP、TGRS、CVPR、ICCV、AAAI等顶级期刊和会议上发表了20多篇同行评审论文。他的研究成果被更多报道全球超过30家科技媒体，并被多个全球用户超过5000万的应用平台采用。他的个人网站是https://zhengxiazou.github.io/。

史振伟（IEEE会员）获得博士学位。 2005年毕业于大连理工大学数学系，获学士学位。

2005年至2007年在清华大学自动化系从事博士后研究，2013年至2014年在美国西北大学电气工程与计算机科学系访问学者，现任北航宇航学院教授、图像处理中心主任大学，北京。他在学术期刊和论文集上撰写或共同撰写了 200 多篇科学论文，包括 IEEE 模式分析和机器智能学报、IEEE 图像处理学报、IEEE 地球科学和遥感学报、IEEE 地球科学和遥感快报、IEEE 计算机视觉和模式识别会议以及 IEEE 计算机视觉国际会议。他的研究兴趣包括遥感图像处理与分析、计算机视觉、模式识别和机器学习。

石博士还担任《Pattern Recognition》、《ISPRS Journal of Photogrammetry and Remote Sensing》、《Infrared物理与技术》等杂志的编辑。他的个人网站是http://levir.buaa.edu.cn/。