

一种基于退化重建增强的遥感图像微小舰船检测方法及其新的大规模数据集

陈建奇、陈克岩、陈浩、邹正霞和石振伟*, *Member, IEEE*

Abstract—在广阔海域快速检测船只对于情报获取至关重要。多数基于深度学习的现代船舶检测方法聚焦于高分辨率遥感图像中的船舶定位，而针对中分辨率遥感图像的船舶检测研究较少。同等尺寸下，中分辨率图像覆盖区域远大于高分辨率图像，有利于实现快速船舶检测。为此，我们提出了一种面向中分辨率遥感图像的微小船舶检测方法——退化重建增强网络。与以往主要关注特征融合策略以提升检测器表达能力的方法不同，我们设计了附加网络分支（即退化重建增强器），在训练阶段学习回归输入图像的物体感知模糊版本。我们的直觉是，所提出的重建分支可引导主干网络更聚焦于微小船舶目标而非广阔背景。此外，我们在检测器中引入跨阶段多头注意力模块，通过自注意力机制进一步提升特征判别能力。为填补大规模中分辨率船舶检测数据集的空白，我们推出了包含3876幅GF-1/GF-6多光谱图像及超3000个微小船舶实例的Levir-Ship数据集。在Levir-Ship上的实验验证了所提方法的有效性与高效性，该方法以85 FPS的速度达到82.4 AP，性能优于多种先进船舶检测方法。代码与数据集详见<https://github.com/WindVChen/DRENet>。

Index Terms—卷积神经网络（CNN）、船舶检测、深度学习、光学图像、遥感。

一、引言

S

HIP detection in optical remote sensing (RS) images

近年来，随着遥感技术的快速发展，光学图像中船舶检测的研究更加

该研究部分得到了国家重点研发计划项目（项目编号：2019YFC1510905）、国家自然科学基金项目（项目编号：62125102）以及北京市自然科学基金项目（项目编号：4192034）的资助。（通信作者：史振威）

transportation, ship plays a very important role in the military. 陈建奇、陈克岩、陈浩与施振伟隶属于北京航空航天大学宇航学院图像处理中心（北京 100191），同时任职于北京航空航天大学北京市数字媒体技术重点实验室（北京 100191），并兼任北京航空航天大学宇航学院虚拟现实技术与系统国家重点实验室（北京 100191）研究人员。

in RS images has been a hot research topic, 陈建奇隶属于北京航空航天大学宇航学院图像处理中心，位于中国北京市，邮编100191。

由于其内容丰富和表达直观的特点，遥感图像中的船舶检测研究一直非常活跃[2]–[6]。传统船舶检测方法通常需要复杂的手工特征提取，且难以适应环境变化[7]、[8]。如今，深度学习技术，特别是卷积神经网络，已广泛应用于遥感图像船舶检测领域。与传统方法相比，基于深度学习的方法能够以端到端的方式学习鲁棒的多层次特征和分类器。受深度学习检测器在计算机视觉领域取得巨大成功的启发，近年来大量研究将深度学习技术引入遥感船舶检测任务[9]–[17]，这些研究在检测精度和稳定性方面均证实了其优于传统方法的性能。

现有的基于深度学习的船舶检测方法大多是在计算机视觉中的目标检测器基础上改进的。光学遥感船舶检测的最新进展包括融合船舶形状先验[18]、从船首和船尾提取特征[12]以及应用船舶方向信息[19]。然而，这些方法大多聚焦于高分辨率图像，因此能够从丰富的纹理和清晰的边缘中获益。

尽管在高分辨率遥感图像中船舶检测已取得显著成果[19]–[21]，但针对中低分辨率遥感图像（如中分辨率图像，约16m/像素）的船舶检测研究却鲜有涉足。¹考虑到实际应用中对于广阔海域进行监测与预警的迫切需求[22][23]，中分辨率图像中的船舶检测显得尤为重要。我们认为，相较于高分辨率图像，中分辨率遥感图像更适用于大范围海域的快速船舶检测，因为同等尺寸的中分辨率图像能覆盖更广阔的海域。例如，若在16m/像素的中分辨率图像（GF-1）中检测固定海域的船舶需1小时，则在1m/像素的高分辨率图像（SkySat-1）中完成相同任务将耗时256小时（约10天）。这种时间成本显然难以承受，尤其是在当前的大数据时代。

现实世界中的中分辨率遥感图像中的船舶检测面临若干挑战。首先，中分辨率遥感图像中的船舶检测可能面临纹理稀疏和船舶边缘模糊的问题。例如，在一幅GF-1图像（16m/像素）中，一艘船可能仅占据20个像素。其次，在真实场景中，遥感图像可能被大量碎云覆盖。复杂的成像条件可能导致

¹Please refer to the website (<https://doc.arcgis.com/en/imagery/workflows/resources/managing-medium-resolution-satellite-data.htm>) for detailed definitions of high resolution and medium resolution.




图1 来自不同数据集的512×512尺寸样本。(a)：来自空客船舶检测竞赛数据集的样本²，空间分辨率为2m，且高。r。(b)：来自Levir-Ship数据集的样本，空间分辨率为16m。

在传统检测器中也会引发许多误报。图1直观对比了高分辨率图像与中分辨率图像。中分辨率图像中的船只难以识别（已放大至最佳观看效果），且不易与碎云区分。大多数检测网络致力于通过特征融合[11]、[24]和跨阶段连接[21]、[25]来提升主干网络或颈部网络的特征表达能力。我们认为这类特征增强方法难以有效提取微小船只目标的判别性特征。

为解决上述问题，我们提出了一种基于退化重建增强的遥感图像微小船舶检测网络DRENet。该网络包含三个核心组件：用于提取鲁棒特征的高效主干网络、通过退化重建增强器辅助主干网络区分船舶与无关背景的机制，以及用于船舶定位的目标检测器。其整体流程如图2所示。与以往主要关注特征融合策略[11][24]以提升检测器表达能力的不同，我们设计了额外的网络分支——退化重建增强器，在训练阶段学习回归输入图像的对象感知模糊版本。该增强器采用我们设计的“选择性退化”图像处理操作来模糊背景。我们的设计思路是：重建分支可引导主干网络更聚焦于微小船舶目标而非广阔背景（如碎云）。需特别说明的是，该增强器仅用于训练阶段，在推理阶段无需计算开销。此外，我们在检测器中引入跨阶段多头注意力（CRMA）模块，通过自注意力机制进一步提升特征判别能力。

据我们所知，目前仍没有公开的MR遥感图像舰船检测数据集。为此，我们提出了名为“Levir-Ship”的数据集以推动研究。Levir-Ship包含3876张512×512像素的图像，采集自

高分一号和高分六号卫星的空间分辨率为16m/像素。我们在Levir-Ship数据集上进行实验，结果表明我们的方法具有有效性和高效性。

我们工作的贡献可概括如下：• 我们提出了一种高效小型船舶检测的有效方法（DRENet）。通过引入退化重建增强器引导主干网络更关注目标而非背景，并采用跨阶段多头注意力机制进一步提升检测器的判别能力。• 我们发布了Levir-Ship检测数据集，包含3876幅GF-1/GF-6卫星影像（每幅尺寸为512×512像素，空间分辨率16m/米/像素），涵盖超过3000个微小船舶实例。• 在Levir-Ship数据集上的大量实验验证了所提方法的有效性、高效性，我们的方法以85 FPS的速度达到82.4% AP，性能超越多种先进船舶检测方法。

本文的其余部分组织如下。相关工作在第二部分介绍。第三部分详细描述了我们的方法。第四部分介绍了Levir-Ship数据集以及与其他船舶检测数据集的比较。实验结果在第五部分报告，结论在第六部分得出。

二、相关工作

船舶检测已被广泛研究数十年。传统方法通常采用从粗到精的多阶段处理流程来获取检测结果[28]–[32]。检测过程通常可分为区域提议和区域细化两个步骤，并利用手工设计的特征。尽管在某些场景下取得了良好效果，但这些方法对复杂情况较为敏感，且存在过度依赖先验知识和操作流程复杂的局限性。

近年来，得益于硬件和大数据的发展，许多有效的深度学习目标检测方法

²<https://www.kaggle.com/c/airbus-ship-detection/overview>.




图2. DRENet的整体结构。a) 骨干网络：采用轻量化骨干网络实现高效稳健的特征提取。b) 增强器：通过回归退化图像引导骨干网络提取判别性特征，其中退化图像源自提出的“选择性退化”操作。c) 检测器：用于展示最终检测结果。我们在检测器中引入跨阶段多头注意力（CRMA）模块，该模块能在节省计算量的同时获得大感受野以精确定位船舶。（关于RCAB和SPP的详细信息请参阅文献[26]和[27]。上采样层的实现与[26][27]保持一致，检测器中使用最近邻插值，增强器中采用亚像素卷积。）

已有多种方法被提出[33]。这些方法在处理任务时更加灵活、统一且强大，可分为两阶段方法和单阶段方法。两阶段方法主要基于RCNN系列[34]–[37]，其核心思路是先获取候选边界框，再对候选结果进行分类与回归。相比之下，以Yolo[27][38]–[41]、SSD[42]、RetinaNet[43]、EfficientDet[44]为代表的单阶段方法直接输出检测结果，通常以略微牺牲精度为代价获得更高的检测速度。然而，无论是两阶段还是单阶段方法都依赖于锚框的设置，这需要大量先验知识并限制了方法的泛化能力。因此，一系列无需锚框的方法被提出，例如CornerNet[45]、CenterNet[46]、FCOS[47]等，这些方法避免了锚框初始化过程，同时也能实现精确的检测效果。

[24]在YOLOv3中引入空洞卷积与注意力机制，提出ImYOLOv3模型。研究者还通过引入先验信息提升检测性能：张*et al*[18]根据船舶结构预设计候选目标框架，再将提案输入CNN进行船舶检测；吴*et al*[20]利用船首突出特征，通过定位舰船船部实现检测；唐*et al*[54]基于船舶与周边环境的色调、饱和度和明度差异进行目标提取。这些方法通常针对高分辨率图像，利用清晰边缘和丰富纹理特征实现优越性能，但在处理微小船舶检测时效果欠佳。本文提出DRENet以解决微小船舶检测难题。

受上述方法的启发，近年来涌现了许多有效的遥感图像目标检测方法[48]–[53]。例如，Wang等人[49]提出了一种单阶段方法，Zhang等人[50]提出了一种无锚框方法，Huang等人[52]提出了目标自适应标签分配策略，这些方法均取得了良好效果。在船舶目标检测这一更具体的领域，许多方法基于深度学习技术对遥感图像中的船舶检测作出了重要贡献。Li等人[11]提出了基于Faster-RCNN的分层选择性滤波层结构，以适应不同尺度的船舶检测。Tian等人[12]在Mask-RCNN基础上引入空洞空间金字塔池化，并采用密集层跳跃连接以有效利用主干网络中的特征信息，实现了较高的检测精度。Chen等人

三、方法

如图2所示，DRENet由高效骨干网络、退化重建增强器（DRE）和船舶检测器组成。我们采用YOLOv5s（YOLOv5的小型版本）[27]作为骨干网络，以高效提取多尺度图像特征。退化重建增强器通过训练阶段回归输入图像的对象感知模糊版本，引导骨干网络获取大量判别性特征。该增强器的监督信号来自我们提出的“选择性退化”操作。在检测器中，我们引入了跨阶段多头注意力（CRMA）模块，以更精准地定位输入图像中的船舶。具体细节将在下文详述。

Algorithm 1 Selective Degradation for obtaining DRE super-resolution information

Input: I , the input image

Input: G , all the ground-truth boxes set in I

Define $F(\cdot)$, an increasing function to adjust the mean kernel size

Define $Center(\cdot)$, a function to get the box's central coordinate

Define $Distance(\cdot, \cdot)$, a function to compute the Euclidean Distance between two inputs

Define $EvenInt(\cdot)$, a function to return the nearest even number that is less than the input

Define $Resize(\cdot)$, a function to resize the image by nearest neighbor interpolation

Output: $\hat{I}$, the label of I in DRE

```

1: for  $i = 0; i < H; i++$  do
2:   for  $j = 0; j < W; j++$  do
3:      $k \leftarrow +\infty$ 
4:     for each  $g \in G$  do
5:        $c \leftarrow Center(g)$ 
6:        $t \leftarrow Distance((i, j), c)$ 
7:       if  $t < k$  then
8:          $k = t$ 
9:       end if
10:    end for
11:     $k = F(k)$ 
12:     $k \leftarrow EvenInt(k)$ 
13:     $\hat{I}(i, j) = \frac{1}{(k+1)^2} \sum_{m=i-\frac{k}{2}, n=j-\frac{k}{2}}^{m=i+\frac{k}{2}, n=j+\frac{k}{2}} I(m, n)$ 
14:  end for
15: end for
16:  $\hat{I} = Resize(\hat{I})$ 
17: return  $\hat{I}$ 

```

A. Degraded Reconstruction Enhancer

退化重建增强器（DRE）利用骨干网络提取的特征来重建退化的输入图像，这可以引导骨干网络更加关注船只，保留更多目标信息，并忽略复杂背景。

1) *Supervision of DRE*: 在本部分中，我们提出了一种名为“选择性退化”的方法来为增强器生成标签。选择性退化具有过滤特性，可对原始图像中不同位置进行不同尺寸的均值滤波处理。算法1详细说明了选择性退化的具体流程，图3则展示了如何确定图像中特定位置的均值核尺寸。通过选择性退化处理，我们能获得一张“伪显著图”——其中船舶目标保持完整，而背景则被处理为模糊状态。借助DRE的训练，主干网络将更专注于微小船舶目标，而非背景中的纹理、细节或碎云干扰。

2) *Design of DRE*: 如图2所示，我们从主干网络提取特征图作为增强器的输入。此处仅使用形状为 64×64 的特征图。




图3. 选择性降噪的具体操作：计算各点处均值滤波核尺寸。 $D1$ 和 $D2$ 表示当前像素位置到各舰船目标的距离， $F(\cdot)$ 为调节均值核尺寸的递增函数，其输出（即均值核尺寸）将随 D_{min} 增大而增加。

为了利用其性能与便捷性，重建形状为 128×128 的退化标签。我们参考现有的超分辨率方法[26]来设计DRE的结构，但存在一些差异。在[26]中，由于目标是提升超分辨率图像的质量，网络实际上复杂且深。然而，我们的目标并非重建完美的选择性退化标签，而是获取主干网络的判别性特征表示。因此，我们构建了一个相对较浅的增强器网络，仅使用单个RCAB（残差通道注意力块，[26]中的一个组件模块），以更专注于主干的训练。基于“选择性退化”机制，增强器的标签聚焦于舰船目标并忽略复杂背景。因此，增强器倾向于在主干中获得鲁棒的特征表示，从而更精确地对舰船进行分类。

与现有超分辨率方法[26]、[55]、[56]相比，本文提出的DRE更侧重于提升微小舰船的检测效果。DRE的监督信号采用输入图像的对象感知模糊版本（区别于现有超分辨率方法的清晰图像），可引导主干网络更聚焦舰船目标，并增强对复杂背景干扰的鲁棒性。此外，现有超分辨率方法采用更高分辨率的图像标签，而本文DRE重构的标签分辨率（ 128×128 ）低于输入图像分辨率（ 512×512 ），显著节省计算量与内存占用。DRE的网络结构也较现有超分辨率方法更为简洁浅层。

B. Efficient Detector

为实现高效舰船检测，我们的检测器基于YOLOv5s架构。针对微小舰船检测任务，我们进行了若干改进以进一步提升检测效率。

为了将低层特征的丰富空间信息通过短而快的路径传播到深层特征，YOLOv5采用了PAN[57]结构。然而，在微小船舶目标检测中为每个输出层分配锚点时，

在检测过程中, 大多数边界框落在浅层检测层上, 而深层检测层上的边界框较少。这实际上是一项耗时操作, 但对丰富深层检测层的空间信息收效甚微。在DRENet中, 我们移除了PAN路径以提高检测速度。

考虑到FPN[58]不同输出层分配的训练样本数量不均衡, 我们在检测器的两个上采样层后添加了两个“尺度层”(如图2所示), 这一做法遵循了[59]的研究。尺度层实际上仅是一个可学习的参数, 能够平衡FPN自底向上路径层中不同输出层回传的梯度。假设自底向上路径中存在从浅到深的两个层C1和C2, 而自顶向下路径中有对应的两个层P1和P2。在原始FPN中, 表达式为 $\$v*\$1 \$v*\$1 \$v*\$2 \$v*\$$, 加入尺度层后变为 $\$v*\$1 \$v*\$1 \$v*\$2 \$v*\$$, 其中 $\$v*\$$ 为可学习参数。

为实现全图像感受野, 我们提出跨阶段多头注意力(CRMA)模块, 用以替换YOLOv5s瓶颈结构中类CSP层。YOLOv5中的类CSP层基于CSPNet[60]设计, 其结构从通道维度将输入对半分后, 分别输入两个分支(一个分支包含多级卷积运算, 另一分支仅进行恒等映射), 最后拼接两支输出作为最终结果。本文认为该分支中的多重卷积计算性价比低, 故采用[61]提出的多头自注意力(MHSA)层进行替代——该层在保持低参数量与复杂度的同时能显著扩大网络感受野, 且通过使用相对位置编码与二维风格的Q/K/V设计, 相比[62]原始版本更适配视觉任务。融合CSPNet思想与MHSA层后, 我们构建出CRMA模块, 其详细结构见图2与表1。值得注意的是, 我们将YOLOv5s瓶颈中全部五个类CSP层替换为CRMA模块, 在保持良好性能的同时显著降低了网络计算量与复杂度。

表1 CRMA配置详情。CBS代表卷积、批量归一化及SiLU激活函数的操作组合。MHSA指代多头自注意力层。

Input: 16×16×512				
Pathway	Layer	Filters	Size	Output
1	CBS	256	1×1	16×16×256
	CBS	128	1×1	16×16×128
	MHSA	—	—	16×16×128
	CBS	256	1×1	16×16×256
	Residual	—	—	16×16×256
2	CBS	256	1×1	16×16×256
Output	Concat	—	—	16×16×512

$$loss_{reg} = 1 - CIoU \quad (2)$$

$$CIoU = IOU - \frac{\rho^2(b, b^{gt})}{c^2} - \frac{\nu^2}{1 - IOU + \nu} \quad (3)$$

$$\nu = \frac{4}{\pi^2} (\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h})^2 \quad (4)$$

其中 b 和 b^{gt} 表示预测框与目标框的中心点, $\rho(\cdot)$ 表示欧几里得距离, c 是覆盖两个框的最小外接框的对角线长度, ν 衡量长宽比的一致性, 而 w^{gt} 、 h^{gt} 、 w 、 h 分别表示两个框的宽度和高度。

$$loss_{cls} = - \frac{\sum (y_n \times \ln y_n^* + (1 - y_n) \times \ln(1 - y_n^*))}{n} \quad (5)$$

其中 n 代表所有锚框的数量, y_n^* 表示第 n 个预测边界框的概率。 y_n 是对应预测边界框的标签, 由 $CIoU$ 公式化表示。最后, 我们以0.05的平衡因子设计了检测器损失。

$$Loss_{detector} = loss_{reg} + 0.05 \times loss_{cls} \quad (6)$$

C. Loss Function

DRENet的损失函数由两部分组成, 包括增强器损失和检测器损失。

1) *Enhancer Loss*: 我们采用均方误差(MSE)来构建增强器的重建误差。损失函数定义如下:

$$Loss_{enhancer} = \frac{\sum (y^* - y)^2}{N} \quad (1)$$

其中 y^* 表示重建结果的像素值, y 表示“选择性退化”标签的像素值, N 表示总像素数。

2) *Detector Loss*: 检测器的损失函数包含回归损失和分类损失。我们采用目标检测任务中的典型损失函数——回归误差使用CIoULoss[63], 分类使用二元交叉熵损失。在DRENet中, 它们定义为:

3) *DRENet Loss*: 增强器与检测器的联合训练可能导致两个分支之间的不平衡, 从而影响船舶检测性能的最优化。如何权衡这两个分支对检测效果具有重要影响。受 Kendall *et al* [64] 研究的启发, 我们设计了一种自动平衡增强器和检测器训练偏好的方法, 通过两个可学习的权重系数实现。最终, DRENet 的损失函数定义为:

$$Loss = \frac{1}{2a^2} Loss_{enhancer} + \frac{1}{2b^2} Loss_{detector} + \ln a + \ln b \quad (7)$$

其中 a 和 b 是网络自动学习的两个系数。在训练过程中, $Loss$ 的前两项中的 a 和 b 往往呈现较大数值, 而在后两项中则倾向于较小数值。它们相互制约, 这种设计有助于训练过程平稳顺利地进行。

D. Implementation Details

我们的主干网络遵循YOLOv5s的设计。主干网络包含5个阶段，每个阶段通过2倍下采样获得不同尺寸的特征图：256×256、128×128、64×64、32×32和16×16。选取64×64、32×32和16×16的特征图作为检测器输入，通过推理获得船舶的概率、位置和形状信息。增强器则采用64×64特征图来重建尺寸为128×128的退化标签。

我们采用随机梯度下降（SGD）优化器，动量为0.99，权重衰减为0.0005。初始学习率设为0.01，并采用余弦退火策略在500个周期内逐步衰减。批处理大小为16。而对于损失函数中两个权重系数 a 和 b 的优化，则采用自适应矩估计（Adam）优化器，学习率设置为0.01。值得注意的是，增强器和检测器在训练阶段是联合优化的，但在测试阶段可以移除增强器，仅使用检测器。

四、LEVIR-SHIP

近几十年来，光学遥感领域涌现出许多有效的目标检测数据集。

NWPU-VHR-10 [65] 数据集包含10个类别的800张图像。然而，其中仅有57张图像包含总计302艘船只，这不足以训练深度学习网络且存在过拟合问题。此外，该数据集的空间分辨率为0.5-2米。

HRSC2016 [66] 是一个用于船舶检测的单类别数据集。所有图像均来自6个知名港口，共计1070张图像，包含2976个目标。该数据集的空间分辨率为0.4-2米。

DIOR [67]是近年来提出的一个相对较大的数据集。它包含20个类别、23463张图像和192472个实例。船舶类别共有2702张图像和62400个目标。然而，船舶数据同样具有较高的空间分辨率。

HRRSD [68] 是近期提出的另一个大规模遥感数据集，包含13个类别、21761张图像和55740个实例。该数据集拥有2165张包含3886个船舶目标的图像，但0.15-1.2米的分辨率仍然过高。

大多数船舶检测数据集聚焦于高空间分辨率，如0.3米、0.5米和2米[65]–[68]。鲜有数据集关注空间分辨率较低情况下的微小船舶目标。在本研究中，我们提出了一个名为Levir-Ship的微小船舶检测数据集，其空间分辨率为16米。

Levir-Ship数据集中的图像由高分一号和高分六号卫星的多光谱相机拍摄。我们仅使用R、G、B三个波段。该数据集共收录85个场景，像素分辨率介于10000×10000至50000×20000之间。通过对原始图像进行裁剪，最终获得1973个正样本和1903个负样本，尺寸均为512×512。如图4所示，我们绘制了Levir-Ship数据集中船舶宽高比的分布情况。可以观察到船舶像素尺寸基本小于20×20，并集中在10×10左右。相较于广阔的背景，Levir-Ship中的船舶目标相对较小，这给检测网络带来了诸多挑战。




图4. LEVIR-SHIP中船舶目标尺寸统计。我们采用实际船舶目标的最小外接矩形作为衡量标准。

表II展示了Levir-Ship与现有几种遥感目标检测数据集的对比。相较于高分辨率图像中的船舶，Levir-Ship中的船舶被复杂背景环绕，难以识别。此外，由于受不同时间、不同拍摄者及不同地理位置的影响，图像呈现多样化状态，这给任务带来了诸多挑战。

从图5可以看出，背景复杂，即使放大数倍图像中的船只也难以发现。同时，由于Levir-Ship涵盖了多种环境条件，深度学习网络能够获得更好的泛化性、稳定性和充分性。

五、实验结果与分析

在本节中，我们对所提出的方法进行了实验对比分析。我们的实验基于Levir-Ship数据集，并将数据集随机划分为训练集、验证集和测试集（具体细节见表III）。所有实验均在NVIDIA Tesla V100 GPU上实现。

A. Evaluation Metrics

我们通过检测精度和模型复杂度来评估所提方法的有效性和效率。衡量指标包括平均精度（AP）、浮点运算次数（FLOPs）、模型参数量以及每秒帧率（FPS）。具体细节如下所述。

为了评估检测精度，我们采用 AP_{50} （当IoU大于0.5时预测为真正样本）作为衡量模型检测精度的评价指标。在计算AP值时，我们采用COCO数据集中说明的方法（在精确率-召回率曲线上，根据分类置信度采样101个点）。

表二 提出的LEVIR-SHIP数据集与四个公开可用目标检测数据集的比较。BB数量表示边界框的数量。对于包含多个类别的数据集，此处仅列出有关船舶类别的信息。

Dataset	Images Number	BB Number	Source	Resolution	Year
NWPU VHR-10	57	302	Google Earth	0.5-2m	2014
HRSC2016	1070	2976	Google Earth	0.4-2m	2016
DIOR	2702	62400	Google Earth	0.5-30m	2018
HRRSD	2165	3886	Google Earth & Baidu Earth	0.15-1.2m	2019
LEVIR-SHIP (Ours)	3876	3219	GaoFen-1 & GaoFen-6	16m	2021




图5. LEVIR-SHIP数据集中包含的在船舶检测过程中可能遇到的不同情况下的部分数据展示。蓝色边界框为真实标注框。

表III 训练集、验证集与测试集的划分

	Image number	Target number
Training set	2320	2002
Validation set	788	665
Test set	788	552

在等间隔处，然后对这些点对应的精确度值进行累加并求平均，以获得最终的AP值），以确保精确度-召回率曲线下面积的计算更为准确。我们使用FLOPs、参数量和FPS来反映检测速度。

B. State-of-the-art Comparison

我们在Levir-Ship数据集上比较了DRENet与其他先进网络在船舶检测方面的性能，包括YOLOv3 [40]、YOLOv5s [27]、Retinanet [43]、SSD [42]、FasterRCNN [36]、EfficientDet [44]、FCOS [47]、CenterNet [46]、HSFNet [11]、ImYOLOv3 [24]以及Tian *et al*提出的DFR和RFE结构[12]。后三种方法是专门为船舶检测任务设计的。我们还尝试与一些传统方法进行比较。

诸如SVDNet[28]和PCANet[69]（配置同[28]）等方法，但遗憾的是，由于船舶目标仅覆盖图像的极小区域，这些方法均告失败。除非另有说明，我们所有网络的训练周期均为500轮，批处理大小设为16。

表IV展示了各网络的对比结果。可以看出，与其他方法相比，我们提出的方法实现了最高的检测精度和实时检测速度。DRENet与最接近的竞争对手EfficientDet-D2[44]拉开了显著的1.5个点AP差距，同时检测速度更快（85 *vs.* 21 FPS）。与最快的YOLOv5s[27]相比，DRENet速度略慢但精度显著更高（82.4 *vs.* 75.6 AP）。此外，DRENet的参数量和浮点运算量均较小。这些结果充分证明了DRENet在微小船舶检测任务上的优异检测性能。

图6展示了DRENet与其他方法的部分检测结果对比。蓝色框表示真阳性检测，红色框代表假阴性检测，黄色框则标示假阳性样本。从图中自上而下，背景复杂度逐渐增加。图像中的船只尺寸极小，可区分特征不够清晰。同时部分船只只被碎云环绕，导致检测难度加大。可以观察到我们的方法取得了更优的检测效果。

优指标。

表四 与一些知名检测方法 & 最先进的船舶检测方法的比较。 **粗体**表示最优指标。

Methods	Params(Inference)	FLOPs(Inference)	AP	FPS
YOLOv3	61.52M	99.2G	69.9	61
YOLOv5s	7.05M	10.4G	75.6	95
Retinanet (ResNet50)	36.33M	104.4G	74.9	12
SSD (VGG16)	24.39M	175.2G	52.6	25
FasterRCNN (VGG16)	136.70M	299.2G	70.8	10
EfficientDet-D0	3.84M	4.6G	71.3	32
EfficientDet-D2	8.01M	20.0G	80.9	21
FCOS (ResNet50)	5.92M	51.8G	75.5	37
CenterNet (Hourglass-104)	191.24M	584.6G	77.7	25
HSFNet	157.59M	538.1G	73.6	7
ImYOLOv3	62.86M	101.9G	72.6	51
MaskRCNN (ResNet50)+DFR+RFE	24.99M	237.8G	76.2	6
DRENet (ours)	4.79M	8.3G	82.4	85

与其他方法相比，DRENet能够检测到更多的真阳性船只并减少漏检目标。此外，与图中展示的其他方法检测结果相比，该方法能有效避免误检。例如在第三行图像中，除DRENet外，其他提及的方法均未能发现云层后的船只。对比结果表明，DRENet在微小船只目标检测任务中具有更高的适用性和鲁棒性。

为进一步分析本方法在不同背景条件下的性能表现，我们依据背景差异将测试集大致划分为五个子集：“平静海面”、“薄云”、“厚云”、“强浪”和“碎云”。为清晰展现这些场景的差异性，图7展示了各子集的示例图像。表V呈现了DRENet与其他方法在不同场景下的对比结果，可见“厚云”、“强浪”和“碎云”子集的检测难度明显高于另外两类，其他方法在这些场景中性能显著下降。实验结果表明，本方法对“碎云”等复杂背景具有更强鲁棒性，同时在“平静海面”等简单场景中仍保持优异性能。

C. Controlled Experiment

1) *Degradation Function F*: 我们比较了采用不同函数 $F(\cdot)$ 调整均值核大小时对原始输入图像产生的退化效果，包括线性函数、对数函数和指数函数。如图8所示，可以看出指数函数能产生更显著的退化效果，更能满足增强器突出船舶、模糊背景的需求。为保留船舶细节并最小化背景干扰，我们采用指数函数来计算均值滤波器的大小。

每个像素位置的内核。步骤在算法1中给出。

2) *Design of Enhancer*: 退化重建增强器用于提取舰船目标与背景之间更具区分度的基本特征表示。我们针对增强器的不同结构和监督方式进行了实验。

不同的增强器结构。在此，我们对增强器的不同内部结构进行比较，以选择最适合船舶检测任务的增强器结构。我们通过AP（平均精度）和网络复杂度来评估性能。表VI详细展示了结果。“n-RCAB”表示我们增强器网络中包含的RCAB数量。“上采样”指不同的上采样倍数，对应于重建不同分辨率的增强器标签。从结果可以看出，当采用1个RCAB结构并进行2倍上采样时，性能最佳。当增强器变得更为复杂时，其训练更侧重于高层网络层，而非骨干网络的基础层。这或许解释了为何随着结构变得臃肿，性能会下降。同时，当上采样因子增大时，退化图像的重建变得更加困难，导致增强器性能恶化。因此，训练后的增强器无法实现检测器所需的适当特征表示。

不同的监督形式。我们在增强器中比较不同的标签生成策略，以获得对重构分支更优的监督。如表VII所示，不同的生成策略对检测精度有不同的影响。我们采用的增强器结构为1个RCAB并上采样2倍。从表中可以得出一些观察结果。首先，与仅使用检测器而无增强器相比，直接下采样能提升检测性能。这可能是因为主干网络通过拟合标签保留了更多空间信息。




图6. 不同方法的检测结果对比。(a) YOLOv5s。(b) EfficientDet-D2。(c) ImYOLOv3。(d) 方法[12]。(e) 本文方法。蓝色框表示检测到的真实目标，红色框表示漏检目标，黄色框表示误报目标。为便于观察，我们随机放大了一些漏检的船舶目标。

对微小船只的检测做出了更多贡献。其次，我们也可以看到突然模糊方法降低了检测精度，这主要是因为Levir-Ship数据集的船只仅占据较小区域，网络训练会因此受到相对较小的损失。因此，

网络学习偏离了原始方向，在抑制背景的同时无法聚焦于微小船只的细节。第三，通过采用“选择性退化”，即表VII中的连续性模糊来生成标签，检测性能得到了显著提升。




图7. 各类背景情境示例图像。(a)平静海面。(b)薄云。(c)厚云。(d)强浪。(e)碎云。

表V：DRENET与其他方法在不同情境下的比较，其中“数量”表示每种情境下的图像数量。最高的AP值以**粗体**标出。

Situations	Number	YOLOv5s	EfficientDet-D2	ImYOLOv3	Method [12]	DRENet (ours)
calm sea	262	76.8	83.0	75.9	78.4	82.1
thin cloud	238	84.3	83.9	83.7	82.4	87.3
thick cloud	60	60.5	78.9	56.6	70.1	86.8
strong wave	101	73.4	73.3	62.8	71.8	82.8
fractus cloud	127	72.1	74.7	61.8	64.4	76.5

表 VI
C增强器中不同网络复杂度的比较。“训练”表示我们保留降质重建增强器的训练过程。最高AP值以**粗体**标出。

Structure	n-RCAB	Upsampling	AP	Params(Train)	FLOPs(Train)
YOLOv5s	—	—	75.6	7.05M	10.4G
YOLOv5s+Degraded reconstruction enhancer	1	×2	76.8	8.25M	20.3G
	1	×4	76.2	8.84M	40.0G
	2	×2	76.6	8.55M	22.7G
	2	×8	75.6	9.73M	121.2G

表VII 增强器中不同标签的比较。“突然模糊”指对目标外部区域进行均匀模糊而不处理目标周边区域，而“连续性模糊”表示采用指数函数 y^x 的选择性退化。最高AP值以**粗体**标出。

Label generation method	AP
Original (YOLOv5s)	75.6
Down-sampling	76.6
Sudden-blur+Down-sampling	75.2
Continuity-blur($\lambda=1.01$)+Down-sampling	76.8
Continuity-blur($\lambda=1.03$)+Down-sampling	78.7
Continuity-blur($\lambda=1.05$)+Down-sampling	77.1

此外，我们在退化函数 F 中采用了不同的参数 λ ，最终因其相对较好的性能选择了1.03。

y^x 我们对原始YOLOv5s原型进行了一些改进，以在微小船只检测中获得更好的性能。为了验证不同修改的效果，我们进行了一系列消融实验。

在检测器上。结果如表VIII所示。从表中我们可以得出一些观察结果。首先，通过添加“尺度层”，在不增加复杂性的情况下出现了小幅改进。这可能是因为尺度层在一定程度上缓解了FPN中不同层训练不平衡的问题。其次，在用我们提出的CRMA模块替换CSP瓶颈后，复杂性显著降低，检测AP上升了4.2。我们认为这是由于更大的感受野带来了更丰富的特征，有利于微小船舶目标检测。这验证了设计的CRMA结构的有效性。我们进一步权衡了是否移除PAN。从表IX中可以看出，当移除PAN结构时，网络参数和操作数量大大减少，而检测精度仅有小幅下降。因此，我们在最终模型中移除了PAN。

与YOLOv5s原型相比，参数量和FLOPs分别降低了近-32%和-19%，而AP提升了4.7个百分点。改进后的检测器具有更快的速度、更小的模型和更高的精度，更适合用于MR遥感图像中的船舶检测。

4) *Network Overall Setting*: 在本部分中，我们将对损失函数和训练策略进行实验。

损失函数。DRENet由一个增强器和

表VIII 检测器修改的消融研究。最优值以**粗体**标出。

Network description	Scale	CRMA	AP	Params	FLOPs
Baseline (YOLOv5s)	×	×	75.6	7.05M	10.4G
Add Scale	✓	×	76.3	7.05M	10.4G
Replace CSP bottleneck with CRMA	×	✓	79.8	5.69M	9.1G
Add Scale and CRMA	✓	✓	80.8	5.69M	9.1G




图8. 采用对数函数、线性函数和指数函数计算各位置均值滤波器核尺寸时的退化效果。图中红色圆圈标识为船舶区域。 λ 是函数中的常数，其设置旨在确保船舶区域保持清晰。 x 表示到船舶目标的最短距离， y 代表核尺寸。

表IX 保持PAN与移除PAN之间的权衡。 W 表示保留，而 W/O 表示移除。

	AP	Params	FLOPs
w	80.8	5.69M	9.1G
w/o	80.3	4.79M	8.3G

检测器，且这两部分需要联合训练。总损失包含检测标签和降质重建标签的监督。除了DRENet损失中提到的自动平衡学习方法（参见第III-C3节），我们还设计了一个固定平衡因子来验证性能。带有固定平衡因子的公式表示为：

$$loss = loss_{detector} + \alpha \times loss_{enhancer} \quad (8)$$

其中 α 是一个用于平衡检测器损失和增强器损失的固定因子。对比结果如表X所示，表明自动权重学习方法能带来显著提升。同时，在使用该方法时，

表X 不同损失函数配置方法的比较。 α 表示两个分支损失函数之和的权重。最高AP值以粗体标出。

Combination description	weight α	AP
Fixed weight summation	100	80.9
	10	81.6
	1	81
	0.1	80.6
Automatic weight summation	—	82.4

表XI 不同训练方法的比较。预训练指先训练增强器，再进行联合训练。最高AP值以**粗体**标出。

Training method	Pretrained epoches	AP
Joint train without pre-training	—	82.4
Joint train with pre-training	100	81.9
	300	81.4
	500	80.5
	1000	77.5

表XII DRENet在现有HR数据集下采样版本上的泛化能力。

Method	Enhancer	Efficient Detector	AP
YOLOv5s	-	-	51.5
DRENet	+	-	52.8
	-	+	50.9
	+	+	51.6

固定平衡因子，当因子 α 从0.1增大到10时，AP也随之增加，这再次证明了增强器的有效性。

训练策略。表XI展示了不同训练方法的结果。我们的目标是在舰船检测上寻求更好的性能，而增强器仅是一个辅助分支。因此，我们尝试先对增强器进行预训练，然后执行联合训练。然而，实验结果显示，预训练的性能要差于直接联合训练，并且随着预训练轮次的增加，AP逐渐

下降。我们认为这一现象主要是因为两个分支相互补充。由于增强器可视为目标定位加目标分割，直接训练增强器难度较大，网络学习可能出现恶化和发散的情况。而检测器能为增强器提供目标位置引导，使其获得更好的学习效果。因此，预训练增强器会导致检测精度较差，并且随着训练轮次增加而加剧。

5) *Generalization on Existing High-Resolution Dataset:* 我们还在现有HR数据集上分析了我们方法的泛化能力，即在降采样版本的HR图像上实施实验。

在此我们选用HRRSD数据集进行实验实施。考虑到HR RSD中图像的尺寸与分辨率(0.15-1.2米)特性，我们首先将所有图像统一调整为64 $\times$ 64尺寸，随后通过消融实验来揭示DRENet的性能表现。

根据表十二的结果，当仅应用我们的高效检测器时，AP值略有下降(-0.6)，我们认为这主要是由输入尺寸引起的。由于图像尺寸仅为64 $\times$ 64，经过网络骨干处理后，CRMA所消耗的特征尺寸会更小，因此CRMA的大感受野特性无法比YOLOv5s类CSP结构中的卷积操作获得更多优势。因此，当我们在高效检测器中移除PAN结构时，性能随之下降，这已在表九中得到验证。

然而，从结果中我们也可以观察到，我们的增强器持续表现出显著提升。仅应用增强器时，AP提升了+1.3个百分点；而当同时使用增强器和检测器时，我们的DRENet与基线YOLOv5s相比达到了接近的性能(AP +0.1)。这些结果进一步证明了我们增强器的有效性。考虑到DRENet在计算量和复杂度上的节省(如表IV所示)，即使在现有高分辨率数据集的降采样版本上，DRENet也实现了良好的性能。

六、结论

本文针对现实世界中的微小船只检测任务，提出微型船舶检测数据集"Levir-Ship"及高效检测网络DRENet。Levir-Ship包含来自高分一号和高分六号卫星的3876幅图像，这些卫星搭载空间分辨率为16米的多光谱相机。DRENet包含特征增强器和检测器两部分：增强器在骨干网络中获取更具区分度的特征，检测器实现微小船只的高效检测。该增强器无需推理过程，因此不会在实际应用中产生额外计算成本。在Levir-Ship数据集上的实验表明，相较于其他先进检测方法，我们提出的DRENet在保持实时检测速度的同时具有更高的检测精度。

参考文献

[1] 何浩、林阳、陈峰、戴惠民、尹志，"基于加权姿态投票的遥感图像近岸船舶检测"，*IEEE Transactions on Geoscience and Remote Sensing*，第55卷第6期，第3091-3107页，2017年。

[2] 韩军，张丹，程刚，郭雷，任杰，"基于弱监督学习与高层特征学习的光学遥感图像目标检测"，*IEEE Transactions on Geoscience and Remote Sensing*，第53卷第6期，3325-3337页，2015。[3] 林浩，史振，邹志，"采用任务划分全卷积网络的光学遥感图像近岸船舶检测"，*IEEE Geoscience and Remote Sensing Letters*，第14卷第10期，1665-1669页，2017。[4] 杨帆，徐强，李斌，"基于显著性分割与结构LBP特征的光学卫星图像船舶检测"，*IEEE Geoscience and Remote Sensing Letters*，第14卷第5期，602-606页，2017。[5] 陈科，邹志，史振，"基于稀疏令牌变换器的遥感图像建筑物提取"，*Remote Sensing*，第13卷第21期，4441页，2021。[6] 李伟，陈科，陈浩，史振，"地理知识驱动的遥感图像表征学习"，*IEEE Transactions on Geoscience and Remote Sensing*，2021。[7] 徐杰，孙旭，张丹，傅魁，"基于鲁棒不变广义霍夫变换的高分辨率遥感图像近岸船舶自动检测"，*IEEE geoscience and remote sensing letters*，第11卷第12期，2070-2074页，2014。[8] 李松，周正，王波，吴飞，"通过舰首分类与舰体边界判定的新型近岸船舶检测"，*IEEE Geoscience and Remote Sensing Letters*，第13卷第12期，1920-1924页，2016。[9] 张帅，吴锐，徐可，王健，孙伟，"基于R-CNN的高分辨率遥感图像船舶检测"，*Remote Sensing*，第11卷第6期，631页，2019。[10] 何龙，易升，慕晓，张雷，"基于Gabor滤波器和Fast R-CNN模型的海域卫星图像船舶检测方法"，载于*Proceedings of the 3rd International Conference on Computer Science and Application Engineering*，2019，1-7页。[11] 李青，牟磊，刘强，王宇，朱孝新，"HSF-Net：光学遥感图像中船舶检测的多尺度深度特征嵌入"，*IEEE Transactions on Geoscience and Remote Sensing*，第56卷第12期，7147-7161页，2018。[12] 田亮，曹阳，何斌，张宇，何超，李丹，"基于目标特性与密集特征重用网络的遥感图像船舶目标检测图像增强"，*Remote Sensing*，第13卷第7期，1327页，2021。[13] A. Van Etten，"你只需看两次：卫星图像中的快速多尺度目标检测"，*arXiv preprint arXiv:1805.09512*，2018。[14] 王岩，王力，姜宇，李涛，"基于YOLOv4网络的自建数据集检测"，载于*2020 IEEE 3rd International Conference on Information Systems and Computer Aided Education (ICISCAE)*，IEEE，2020，640-642页。[15] 王宇，王晨，张华，"结合单次多框检测器与迁移学习的Sentinel-1 SAR图像船舶检测"，*Remote sensing letters*，第9卷第8期，780-788页，2018。[16] 王宇，王晨，张华，董宇，魏松，"基于Retina Net的多分辨率高分三号图像自动船舶检测"，*Remote Sensing*，第11卷第5期，531页，2019。[17] 桂阳，李旭，薛雷，"用于SAR船舶检测的多层融合轻量检测器"，*Sensors*，第19卷第5期，1124页，2019。[18] 张瑞，姚军，张凯，冯程，张健，"基于S-CNN的高分辨率遥感图像船舶检测"，*International Archives of the Photogrammetry, Remote Sensing & Spatial Information Sciences*，第41卷，2016。[19] 李立，周正，王波，苗力，宗华，"基于CNN的旋转边界框高分辨率光学遥感图像精确船舶检测新方法"，*IEEE Transactions on Geoscience and Remote Sensing*，第59卷第1期，686-699页，2020。[20] 吴飞，周正，王波，马杰，"光学卫星图像中基于卷积神经网络的近岸船舶检测"，*IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*，第11卷第11期，4005-4015页，2018。[21] 刘伟，马龙，陈浩，"光学遥感图像中任意朝向船舶检测框架"，*IEEE Geoscience and Remote Sensing Letters*，第15卷第6期，937-941页，2018。[22] 游宇，李政，冉斌，曹军，吕帅，刘飞，"基于深度卷积神经网络的船舶检测广域目标搜索系统"，*Remote Sensing*，第11卷第17期，1965页，2019。[23] 宋志，隋华，华雷，"利用显著性检测与CNN的大尺度光学遥感卫星图像分层目标检测方法"，*International Journal of Remote*

- Sensing, 第42卷第8期, 第2827–2847页, 2021年。[在线]。可访问: <https://doi.org/10.1080/01431161.2020.1826059> [24] 陈力、施文、邓东, “基于注意力机制的改进YOLOv3用于光学遥感图像中快速准确的船舶检测”, *Remote Sensing*, 第13卷第4期, 第660页, 2021年。[25] 陈力、施文、范超、邹亮、邓东, “一种基于深度残差密集网络的光学遥感图像船舶检测粗到精新方法”, *Remote Sensing*, 第12卷第19期, 第3115页, 2020年。[26] 张宇、李科、李康、王亮、钟斌、傅莹, “使用极深残差通道注意力网络的图像超分辨率”, 载于 *Proceedings of the European conference on computer vision (ECCV)*, 2018年, 第286–301页。[27] G. Jocher, A. Stoken, J. Borovec, NanoCode012, A. Chaurasia, TaoXie, 常雨, A. V. Laughing, tkianai, yxNONG, A. Hogan, lorenzomammanna, AlexWang1900, J. Hajek, L. Diaconu, Marc, 权勇, oleg, wanghaoyang0106, Y. Defretin, A. Lohia, ml5ah, B. Milanko, B. Fineran, D. Khromov, D. Yiwei, Doug, Durgesh, F. Ing ham, “ultralytics/yolov5: v5.0–YOLOv5-P6 1280模型, AWS, Supervise.ly和YouTube集成”, 2021年4月。[在线]。可访问: <https://doi.org/10.5281/zenodo.4679653> [28] 邹政、史政, “基于SVD网络的星载光学图像船舶检测”, *IEEE Transactions on Geoscience and Remote Sensing*, 第54卷第10期, 第5832–5845页, 2016年。[29] G. Matyus, “光学卫星图像上近实时自动船舶检测”, 载于 *ISPRS Hannover Workshop*. ISPRS档案, 2013年, 第233–237页。[30] 韩军、周鹏、张东、程刚、郭磊、刘政、步帅、吴军, “基于视觉显著性建模和稀疏编码判别学习的多类地理空间目标高效同步检测”, *ISPRS Journal of Photogrammetry and Remote Sensing*, 第89卷, 第37–48页, 2014年。[31] 朱成、周浩、王锐、郭军, “一种基于形状和纹理特征的星载光学图像船舶检测分层新方法”, *IEEE Transactions on geoscience and remote sensing*, 第48卷第9期, 第3446–3456页, 2010年。[32] 史政、于翔、蒋政、李斌, “基于异常检测器和局部形状特征的高分辨率光学图像船舶检测”, *IEEE Transactions on Geoscience and Remote Sensing*, 第52卷第8期, 第4511–4523页, 2013年。[33] 邹政、史政、郭阳、叶军, “二十年目标检测综述”, *arXiv preprint arXiv:1905.05055*, 2019年。[34] R. Girshick, J. Donahue, T. Darrell, J. Malik, “用于精确目标检测和语义分割的丰富特征层次结构”, 载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2014年, 第580–587页。[35] R. Girshick, “Fast R-CNN”, 载于 *Proceedings of the IEEE international conference on computer vision*, 2015年, 第1440–1448页。[36] 任少卿、何恺明、R. Girshick、孙剑, “Faster R-CNN: 通过区域提议网络实现实时目标检测”, *IEEE transactions on pattern analysis and machine intelligence*, 第39卷第6期, 第1137–1149页, 2016年。[37] 何恺明、G. Gkioxari, P. Dollár, R. Girshick, “Mask R-CNN”, 载于 *Proceedings of the IEEE international conference on computer vision*, 2017年, 第2961–2969页。[38] J. Redmon, S. Divvala, R. Girshick, A. Farhadi, “You Only Look Once: 统一实时目标检测”, 载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016年, 第779–788页。[39] J. Redmon, A. Farhadi, “YOLO9000: 更好、更快、更强”, 载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017年, 第7263–7271页。[40] Redmon, Joseph, Farhadi, A li, “YOLOv3: 渐进式改进”, *arXiv preprint arXiv:1804.02767*, 2018年。[41] A. Bochkovskiy, 王崇宇、廖弘毅, “YOLOv4: 目标检测的最佳速度与精度”, *arXiv preprint arXiv:2004.10934*, 2020年。[42] 刘伟、D. Anguelov, D. Erhan, C. Szegedy, S. Reed, 傅晨阳, A. C. Berg, “SSD: 单次多框检测器”, 载于 *European conference on computer vision*. Springer, 2016年, 第21–37页。[43] 林德宇、P. Goyal, R. Girshick、何恺明、P. Dollár, “用于密集目标检测的焦点损失”, 载于 *Proceedings of the IEEE international conference on computer vision*, 2017年, 第2980–2988页。[44] 谭明、庞锐、Le Q. V., “EfficientDet: 可扩展高效的目标检测”, 载于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020年, 第10781–10790页。[45] H. Law 与 J. Deng, “CornerNet: 通过成对关键点进行目标检测”, 发表于 *Proceedings of the European conference on computer vision (ECCV)*, 2018年, 第734–750页。[46] X. Zhou, D. Wang 与 P. Krähenbühl, “目标即点”, *arXiv preprint arXiv:1904.07850*, 2019年。[47] Z. Tian, C. Shen, H. Chen 与 T. He, “FCOS: 全卷积单阶段目标检测”, 发表于 *Proceedings of the IEEE/CVF international conference on computer vision*, 2019年, 第9627–9636页。[48] Z. Zou 与 Z. Shi, “随机存取记忆: 高分辨率航空遥感图像目标检测新范式”, *IEEE Transactions on Image Processing*, 第27卷第3期, 第1100–1111页, 2017年。[49] G. Wang, Y. Zhuang, H. Chen, X. Liu, T. Zhang, L. Li, S. Dong 与 Q. Sang, “FSOD-Net: 光学遥感影像全尺度目标检测”, *IEEE Transactions on Geoscience and Remote Sensing*, 第60卷, 第1–18页, 2021年。[50] T. Zhang, Y. Zhuang, G. Wang, S. Dong, H. Chen 与 L. Li, “多尺度语义融合引导的分形卷积目标检测网络在光学遥感影像中的应用”, *IEEE Transactions on Geoscience and Remote Sensing*, 2021年。[51] Z. Huang, W. Li, X.-G. Xia, X. Wu, Z. Cai 与 R. Tao, “遥感图像目标检测的新型非局部感知金字塔与多尺度多任务优化检测器”, *IEEE Transactions on Geoscience and Remote Sensing*, 第60卷, 第1–20页, 2021年。[52] Z. Huang, W. Li, X.-G. Xia 与 R. Tao, “任意方向目标检测的通用高斯热图标签分配方法”, *IEEE Transactions on Image Processing*, 第31卷, 第1895–1910页, 2022年。[53] Z. Huang, W. Li, X.-G. Xia, H. Wang, F. Jie 与 R. Tao, “Lo-Det: 遥感图像轻量级定向目标检测”, *IEEE Transactions on Geoscience and Remote Sensing*, 第60卷, 第1–15页, 2022年。[54] G. Tang, S. Liu, I. Fujino, C. Claramunt, Y. Wang 与 S. Men, “H-YOLO: 基于感兴趣区域预选网络的单次船舶检测方法”, *Remote Sensing*, 第12卷第24期, 第4192页, 2020年。[55] 雷森, 石振伟, 邹正霞, “基于局部-全局联合网络的遥感图像超分辨率重建”, *IEEE Geoscience and Remote Sensing Letters*, 第14卷第8期, 第1243–1247页, 2017年。[56] S. Lei, Z. Shi 与 Z. Zou, “遥感图像超分辨率的耦合对抗训练”, *IEEE Transactions on Geoscience and Remote Sensing*, 第58卷第5期, 第3633–3643页, 2019年。[57] S. Liu, L. Qi, H. Qin, J. Shi 与 J. Jia, “实例分割的路径聚合网络”, 发表于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018年, 第8759–8768页。[58] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan 与 S. Belongie, “目标检测的特征金字塔网络”, 发表于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017年, 第117–121页。[59] Y. Gong, X. Yu, Y. Ding, X. Peng, J. Zhao 与 Z. Han, “FPN中小目标检测的有效融合因子”, 发表于 *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2021年, 第1160–1168页。[60] C.-Y. Wang, H.-Y. M. Liao, Y.-H. Wu, P.-Y. Chen, J.-W. Hsieh 与 I.-H. Yeh, “CSPNet: 增强CNN学习能力的新骨干网络”, 发表于 *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops*, 2020年, 第390–391页。[61] A. Srinivas, T.-Y. Lin, N. Parmar, J. Shlens, P. Abbeel 与 A. Vaswani, “视觉识别的瓶颈Transformer”, 发表于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021年, 第16519–16529页。[62] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser 与 I. Polosukhin, “注意力机制即所有”, *arXiv preprint arXiv:1706.03762*, 2017年。[63] Z. Zheng, P. Wang, W. Liu, J. Li, R. Ye 与 D. Ren, “Distance-IoU损失: 边界框回归的更快更好学习”, *Proceedings of the AAAI Conference on Artificial Intelligence*, 第34卷第07期, 第12993–13000页, 2020年4月。[在线]。可用: <https://ojs.aaai.org/index.php/AAAI/article/view/6999> [64] A. Kendall, Y. Gal 与 R. Cipolla, “利用不确定性加权损失进行场景几何与语义多任务学习”, 发表于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018年, 第7482–7491页。[65] G. Cheng, J. Han, P. Zhou 与 L. Guo, “基于部件检测器集合的多类地理空间目标检测与地理图像分类”, *ISPRS Journal of Photogrammetry and Remote Sensing*, 第98卷, 第119–132页, 2014年。[66] Z. Liu, L. Yuan, L. Weng 与 Y. Yang, “高分辨率光学卫星图像船舶识别数据集及新基线”,

在 *International conference on pattern recognition applications and methods*, 第2卷. SCITEPRESS, 2017年, 第324–331页。[67] K. Li, G. Wan, G. Cheng, L. Meng, 和 J. Han, “光学遥感图像中的目标检测：综述与新基准”, *ISPRS Journal of Photogrammetry and Remote Sensing*, 第159卷, 第296–307页, 2020年。[68] Y. Zhang, Y. Yuan, Y. Feng, 和 X. Lu, “用于高分辨率遥感目标检测的层次化鲁棒卷积神经网络”, *IEEE Transactions on Geoscience and Remote Sensing*, 第57卷第8期, 第5535–5548页, 2019年。[69] T.-H. Chan, K. Jia, S. Gao, J. Lu, Z. Zeng, 和 Y. Ma, “PCANet: 一种简单的图像分类深度学习基线?”, *IEEE transactions on image processing*, 第24卷第12期, 第5017–5032页, 2015年。



石振伟 (IEEE会员) 于2005年在中国大连的大连理工大学获得数学博士学位。

他于2005年至2007年在北京清华大学自动化系担任博士后研究员, 并于2013年至2014年在美国伊利诺伊州埃文斯顿西北大学电气工程与计算机科学系担任访问学者。现任北京航空航天大学宇航学院图像处理中心主任、教授。

北京某大学。他在包括IEEE模式分析与机器智能汇刊、IEEE图像处理汇刊、IEEE地球科学与遥感汇刊、IEEE地球科学与遥感快报、IEEE计算机视觉与模式识别会议以及IEEE国际计算机视觉大会在内的评审期刊和会议论文集上发表或合著了200多篇科学论文。其研究兴趣涵盖遥感图像处理与分析、计算机视觉、模式识别和机器学习。



陈建祺于2021年获得北京航空航天大学宇航学院图像处理中心学士学位, 目前正在该中心攻读硕士学位。他的研究方向包括深度学习、目标检测与人工智能安全。

史博士还担任《模式识别》、《ISPRS摄影测量与遥感杂志》、《红外物理与技术》等期刊的编辑。他的个人网站是<http://levir.buaa.edu.cn/>。



陈科研于2019年获得北京航空航天大学宇航学院学士学位, 目前在该校宇航学院图像处理中心攻读硕士学位。他的研究方向包括图像处理、机器学习与模式识别。



陈浩于2017年获得北京航空航天大学宇航学院图像处理中心学士学位。目前在北京航空航天大学宇航学院图像处理中心攻读博士学位, 其研究方向包括机器学习、深度学习及语义分割。



邹正夏于2013年和2018年分别获得北京航空航天大学学士学位和博士学位, 现为北京航空航天大学宇航学院副教授。2018年至2021年期间, 他在密歇根大学安娜堡分校从事博士后研究工作。其研究方向涵盖计算机视觉及遥感领域的相关问题, 已在TPAMI、TIP、TGRS、CVPR、ICCV、AAAI等顶级期刊和会议上发表20余篇同行评审论文, 多项研究成果获得重点报道。

超过30家全球科技媒体报道, 并被多个应用平台采纳, 覆盖全球超过500万用户。他的个人网站是<https://zhengxiaou.github.io/>。