

学 号： 2022217586

密 级： 公开

合肥工业大学

Hefei University of Technology

本科毕业设计（论文）

UNDERGRADUATE THESIS



类 型：	设计
题 目：	遥感场景下的微小船舶检测系统设计 与实现
专业名称：	物联网工程
入校年份：	2022 级
学生姓名：	邝黄硕
指导教师：	惠天瑞 副教授
学院名称：	计算机与信息学院
完成时间：	2026 年 5 月

合 肥 工 业 大 学

本科毕业设计（论文）

遥感场景下的微小船舶检测系统设计与实现

学生姓名： 邝黄硕

学生学号： 2022217586

指导教师： 惠天瑞 副教授

专业名称： 物联网工程

学院名称： 计算机与信息学院

2026 年 5 月

A Dissertation Submitted for the Degree of Bachelor

**Design and Implementation of a Tiny Ship Detection
System in Remote Sensing Scenes**

By

Huangshuo Kuang

Hefei University of Technology

Hefei, Anhui, P.R.China

May, 2026

毕业设计（论文）独创性声明

本人郑重声明：所提交的毕业设计（论文）是本人在指导教师指导下进行独立研究工作所取得的成果。据我所知，除了文中特别加以标注和致谢的内容外，设计（论文）中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 合肥工业大学 或其他教育机构的学位或证书而使用过的材料。对本文成果做出贡献的个人和集体，本人已在设计（论文）中作了明确的说明，并表示谢意。

毕业设计（论文）中表达的观点纯属作者本人观点，与合肥工业大学无关。

毕业设计（论文）作者签名：

签名日期：2026 年 5 月 30 日

毕业设计（论文）版权使用授权书

本学位论文作者完全了解 合肥工业大学 有关保留、使用毕业设计（论文）的规定，即：除保密期内的涉密设计（论文）外，学校有权保存并向国家有关部门或机构送交设计（论文）的复印件和电子光盘，允许设计（论文）被查阅或借阅。本人授权 合肥工业大学 可以将本毕业设计（论文）的全部或部分内容编入有关数据库，允许采用影印、缩印或扫描等复制手段保存、汇编毕业设计（论文）。

（保密的毕业设计（论文）在解密后适用本授权书）

学位论文作者签名：

指导教师签名：

签名日期：2026 年 5 月 30 日

签名日期：2026 年 5 月 30 日

摘 要

遥感图像中的微小船舶检测是海上监管、港口监测、海事执法和应急救援等场景中的重要基础任务。与普通自然图像相比，中分辨率遥感图像中的船舶目标通常只占据少量像素，目标纹理也较为弱化；同时，海浪、云层、岸线和港区设施等复杂背景干扰进一步增加了检测难度，使模型更容易出现背景误判和弱小目标漏检。针对这一任务背景，本文以公开的 LEVIR-Ship 数据集为实验对象，对多种路线的检测方法进行比较研究，并据此实现遥感微小船舶检测系统。

在算法层面，本文先整理了通用目标检测、小目标检测和遥感船舶检测的国内外相关研究，然后在统一的数据划分、评价指标和结果记录口径下，选取 DRENet、FCOS 和 YOLO26 分别作为遥感微小船舶检测专用、无锚框目标检测和单阶段目标检测技术路线的代表性方法进行实验比较。本文以 AP50 作为主评价指标，并同步记录 AP50-95、精度、召回率和 F1 值等辅助指标。在 LEVIR-Ship 数据集上的测试结果显示，DRENet 的 AP50 为 0.7949、召回率为 0.8511，整体表现呈现明显的召回优先特征，但误检压力相对较大；YOLO26 的 AP50 为 0.7950、精度为 0.8430、AP50-95 为 0.3170，在精度与定位质量之间取得了较为均衡的表现；FCOS 的 AP50 为 0.7389、F1 值为 0.7944，精度与召回率的折中较好，但整体检出能力仍弱于前两者。进一步的阈值消融与输入尺寸消融结果，也从不同角度分析了后处理参数和推理输入规模对模型检测效果的影响。

在系统实现层面，本文对以上三个船舶检测模型进行集成，并将其推理功能统一封装为遥感微小船舶检测系统。系统前端采用 React 负责图像上传、任务查询和结果展示；后端采用 FastAPI 提供推理服务与任务接口；SQLite 数据库用于保存模型信息、任务状态、检测框结果和输出文件路径。系统支持单图与批量任务、模型启停管理、异步执行、可视化结果回查以及历史任务查询功能，从而能够将离线实验结果纳入页面化任务流程进行复核。

关键词：遥感图像；微小船舶检测；目标检测；检测系统；模型评估

ABSTRACT

Tiny ship detection in remote sensing imagery is an important supporting task in maritime surveillance, port monitoring, law enforcement and emergency response. In mid-resolution images, ship targets usually occupy only a small number of pixels and exhibit weak texture cues. At the same time, waves, clouds, coastlines and harbor facilities introduce complex background interference, which makes missed detections, false alarms and unstable cross-scene performance more likely in practice. Under this problem setting, this thesis conducts comparative experiments on the public LEVIR-Ship dataset and implements a remote-sensing tiny ship detection system.

For the algorithmic component, this thesis reviews related work on general object detection, small object detection and remote-sensing ship detection, and then selects DRENet, FCOS and YOLO26 as representative methods for dedicated remote-sensing tiny ship detection, anchor-free detection and one-stage detection under a unified protocol of data split, evaluation metrics and result recording. AP50 is used as the primary metric, while AP50-95, Precision, Recall and F1 score are recorded as complementary indicators. The experimental results on the LEVIR-Ship dataset show that DRENet achieves an AP50 of 0.7949 and a Recall of 0.8511, indicating a clear recall-oriented tendency together with relatively high false-alarm pressure. YOLO26 achieves an AP50 of 0.7950, a Precision of 0.8430 and an AP50-95 of 0.3170, showing a comparatively balanced trade-off between precision and localization quality. FCOS achieves an AP50 of 0.7389 and an F1 score of 0.7944, with a relatively better Precision–Recall balance but lower overall detection capability than the other two methods. Further threshold ablation and input-size ablation experiments also analyze the influence of post-processing parameters and inference input scale on detection performance from different perspectives.

For the system implementation, this thesis integrates the above three ship detection models and encapsulates their inference capability into a unified remote-sensing tiny ship detection system. The frontend is built with React for image upload, task query and result display. The backend uses FastAPI to provide inference services and task interfaces. SQLite

stores model information, task status, detection boxes and output file paths. The system supports single-image and batch-image tasks, model activation management, asynchronous execution, visual result review and history query, allowing offline detection outputs to be incorporated into a page-based task workflow for subsequent review.

KEYWORDS: Remote Sensing Images, Tiny Ship Detection, Object Detection, Detection System, Model Evaluation

目 录

1 绪论	1
1.1 研究背景	1
1.2 研究问题与挑战	1
1.3 研究目标与主要内容	2
1.4 本文主要工作与贡献	3
1.5 技术路线与研究方法	3
1.6 论文结构安排	4
1.7 本章总结	4
2 国内外研究现状	5
2.1 通用目标检测方法演进	5
2.2 小目标检测研究进展	5
2.3 遥感船舶检测研究现状	6
2.4 现有工作的不足与本文切入点	7
2.5 本章总结	8
3 数据集、评价指标与方法方案	9
3.1 实验基础	9
3.2 数据集介绍	9
3.3 数据集样例与任务特征	9
3.4 数据预处理与统一格式	10
3.5 评价指标	11
3.6 指标选择依据	12
3.7 模型方案	12
3.7.1 遥感微小船舶检测专用方法：DRENet	12
3.7.2 无锚框代表性目标检测方法：FCOS	14

3.7.3 单阶段代表性目标检测方法: YOLO26	15
3.8 统一实验协议与实现约束.....	16
3.9 本章总结	17
4 实验结果与分析	18
4.1 实验环境与设置	18
4.2 模型定量实验结果对比	18
4.3 效率与部署属性分析	20
4.4 模型逐项分析.....	21
4.4.1 DRENet 结果分析	21
4.4.2 FCOS 结果分析	21
4.4.3 YOLO26 结果分析	22
4.5 定性样例与误差分析	22
4.5.1 成功检测样例	22
4.5.2 漏检样例	23
4.5.3 误检样例	23
4.6 消融实验	24
4.6.1 阈值消融分析	24
4.6.2 输入尺寸敏感性分析	26
4.7 本章总结	27
5 系统需求分析、设计与实现.....	28
5.1 系统建设目标.....	28
5.2 系统需求分析.....	28
5.2.1 功能需求	28
5.2.2 非功能需求.....	29
5.3 系统总体架构.....	29
5.4 数据库设计	31
5.5 接口设计	32

5.6 关键实现流程.....	32
5.6.1 任务创建与执行流程	32
5.6.2 结果生成与展示流程	33
5.7 模块实现细节.....	34
5.7.1 端到端数据流与职责分解	34
5.7.2 单图检测逻辑（接口层）	34
5.7.3 推理调用逻辑（服务层）	35
5.7.4 结果聚合逻辑（存储层）	35
5.8 系统实现效果.....	36
5.8.1 前端页面实现效果	36
5.9 系统输出案例集	37
5.10 模块测试用例设计	39
5.10.1 测试执行结果	39
5.11 系统响应速度优化.....	40
5.11.1 性能瓶颈分析与优化思路	40
5.11.2 并行推理与模型预加载机制	41
5.11.3 进度端点与前端轮询重构	41
5.11.4 渲染、存储与结果访问优化	42
5.11.5 优化效果分析	42
5.12 本章总结	43
6 总结与展望.....	44
6.1 工作总结	44
6.2 不足分析	44
6.3 未来展望	45
参考文献	46
致谢	49

插图清单

图 1.1	技术路线图	3
图 2.1	本文相关研究方向与代表路线脉络	7
图 3.1	LEVIR-Ship 数据集典型样例	10
图 3.2	数据预处理与统一格式流程图	11
图 3.3	DRENet 检测流程示意	12
图 3.4	DRENet 网络结构图, 引自 ^[17]	13
图 3.5	FCOS 检测流程示意	14
图 3.6	FCOS 网络结构图, 引自 ^[4]	15
图 3.7	YOLO26 检测流程示意	15
图 3.8	YOLO26 网络结构图, 引自 ^[19]	17
图 4.1	模型主对比结果的指标可视化	19
图 4.2	模型效率与复杂度对比柱状图	20
图 4.3	模型多维度综合雷达图	21
图 4.4	模型成功检测样例对比	22
图 4.5	模型漏检样例对比	23
图 4.6	模型误检样例对比	24
图 4.7	模型阈值消融趋势图	25
图 4.8	输入尺寸敏感性趋势图	26
图 5.1	系统总体架构图	30
图 5.2	系统数据库 E-R 图	31
图 5.3	系统关键流程图	33
图 5.4	系统主要页面实现效果	37
图 5.5	样本 A 的系统输出结果图: 目标边界相对清晰场景下的检测结果示例	38
图 5.6	样本 B 的系统输出结果图: 弱纹理与低对比度条件下的检测结果示例	38
图 5.7	样本 C 的系统输出结果图: 复杂背景干扰条件下的检测结果示例	39

表格清单

表 2.1	本文相关研究方向与代表路线	7
表 3.1	LEVIR-Ship 数据集划分	9
表 4.1	实验环境与关键配置.....	18
表 4.2	模型在 LEVIR-Ship 数据集上的主对比结果	19
表 4.3	模型效率与复杂度对比	20
表 4.4	模型阈值消融结果	25
表 4.5	FCOS 与 YOLO26 输入尺寸敏感性分析结果	26
表 5.1	功能需求的操作与响应定义	29
表 5.2	系统核心接口设计	32
表 5.3	系统主要模块测试用例	40
表 5.4	系统响应速度优化的关键基准结果	42

1 绪论

1.1 研究背景

遥感图像中的船舶检测是海上监管、港口调度、海事执法与应急救援等应用中的基础环节。与自然场景目标检测相比，遥感图像具有视野范围大、背景复杂、目标稀疏和尺度变化显著等特点。依赖人工判读时，检测效率、一致性和可追溯性均存在不足。随着深度学习目标检测技术的发展，将其引入遥感船舶检测任务，并将结果组织为可复验、可回放的系统流程，已具有明确的研究与应用价值。

从任务定义看，遥感图像中的船舶检测属于标准目标检测问题：输入为遥感图像（单张或批量），输出为每张图像中的船舶目标集合，输出的每个目标包含边界框坐标、置信度和类别标识，并且由于遥感图像中目标普遍偏小、背景干扰强、尺度变化明显，该任务对检测模型的要求不仅是整体精度达标，还需要在召回率与精度之间取得合理平衡，既要尽量检出真实船舶目标，又要控制近岸纹理、云层和港区设施等背景带来的误检。

近年来，目标检测技术从二阶段方法发展到单阶段方法、无锚框方法，再到 Transformer 检测器，模型在精度、速度和表达能力上持续演进^[1-7]。与此同时，遥感小目标检测也一直在关注尺度变化、背景干扰和样本稀疏对模型稳定性的影响^[8-11]。围绕光学遥感目标检测与舰船检测，国内也已有较系统的综述工作对任务特点、算法脉络和应用场景进行了梳理^[12-16]。不过，在中分辨率遥感图像中，微小船舶占据的像素本就有限，还容易和海浪、云层、岸线或近岸建筑纹理混在一起，通用检测器直接迁移时往往会出现漏检和误检。

公开数据集和开源工具链逐步完善后，研究重点已由“模型能否完成训练”转向“结果能否统一评测、稳定复现并进入可运行流程”。仅给出单一模型指标已难以满足分析需要，仍需在统一协议下比较不同检测范式，并将算法能力接入系统。本文的研究工作即在这一背景下展开。

1.2 研究问题与挑战

本课题讨论的是“遥感场景下的微小船舶检测系统设计与实现”。本文关注的核心问题并非单纯提高某一模型的 AP50 指标，而是在弱纹理目标、复杂背景和可运行系统之间建立一种可验证、可解释的权衡关系。结合 LEVIR-Ship 数据集的图像特征

以及 DRENet 等已有工作^[17]，本文将问题进一步归纳为以下几个具体的难点：

第一，尺度问题：微小船舶在整幅图像中仅占据较少像素，特征图经过多次下采样后，可用于定位的细节信息进一步减少；第二，纹理混淆问题：海浪、云层、岸线和港区设施会形成大量近似船体的小纹理，模型一旦将这些纹理识别为候选目标，精度就会明显受影响；第三，样本比例问题：LEVIR-Ship 中不同图像块的目标密度、朝向和局部对比度差异较大，训练过程中正负样本比例并不稳定；第四，实验条件统一问题：数据划分、阈值和评测脚本一旦不一致，跨模型比较的结果就会较难解释，进而影响后续结论的可靠性。

针对上述问题，本文将研究工作组织为三条并行路线，以保证实验结果、误差分析与系统展示之间的逻辑一致性：

- (1) **实验协议线**：固定数据划分、评价指标、阈值设置和结果字段，并对配置文件、权重版本和运行日志进行统一记录，用以降低实验口径差异带来的偏差，使模型结果具备可比性和可复验性。
- (2) **模型比较线**：在统一协议下选取 DRENet、FCOS 和 YOLO26 三类代表模型，针对 AP50、精度、召回率、F1 值以及帧率、参数量和 FLOPs 等效率指标进行横向比较，并结合成功样例、漏检样例和误检样例分析性能差异来源。
- (3) **系统落地线**：将离线推理能力接入任务管理与可视化流程，形成从任务提交、异步执行到结果回看的完整链路，以验证模型结果在系统环境中的可用性与可追溯性，并为后续应用场景提供工程化支撑。

1.3 研究目标与主要内容

本文的研究目标为：围绕特定的 LEVIR-Ship 数据集整理一套可复查的数据和评测结果，首先完成 DRENet、FCOS 与 YOLO26 的对比实验，然后构建相应的 Web 系统来用于模型推理、结果展示与历史记录管理。

本文的具体研究工作包括：

- (1) **整理数据与评测口径**：固定数据划分、指标计算方式和结果记录字段，减少模型比较中的人为差异；
- (2) **完成三类模型实验**：基于 DRENet、FCOS 与 YOLO26 的训练记录、测试和正式结果来比较不同检测路线的表现；
- (3) **补充误差与消融观察**：结合阈值、输入尺寸和可视化样例来分析误检、漏检

和原因；

- (4) **搭建检测系统原型**：使用 React、FastAPI 与 SQLite 来构建 Web 系统以实现任务提交、异步执行、结果保存和历史回看。

1.4 本文主要工作与贡献

结合本文已完成的实验与系统实现，主要工作与贡献可概括为以下三个方面：

第一，围绕遥感微小船舶检测任务，本文整理了数据组织和评测记录方式。通过统一数据划分、输入口径、评价指标和结果字段，三类模型的实验结果获得了相对一致的比较基础。

第二，本文完成了 DRENet、FCOS 与 YOLO26 的对比实验，并结合阈值消融与定性样例分析模型在不同场景下的表现。该分析不仅呈现了各模型在 AP50 上的差异，也进一步揭示了精度、召回率、错误类型与部署取舍之间的对应关系。

第三，本文将离线推理能力整合到前后端分离的 Web 系统中。任务提交、异步执行、检测框可视化、结果持久化和历史回看都已完成，关键检测结果可以通过系统页面完成查询和回看。

1.5 技术路线与研究方法

图 1.1 展示了本文的技术路线。整体实施过程包括数据与标注核对、模型训练与推理、实验结果整理以及系统侧推理接口接入。统一的数据记录方式与推理入口保证了算法实验和系统实现之间的一致性，使定性样例、结构化结果与历史回看能够相互对应。




图 1.1 技术路线图

在具体实施过程中，本文先在数据侧核对图像与标注是否一一对应，并整理为各框架可共用的中间格式；再在模型层面选取专项方法、无锚框方法和单阶段方法三条路线进行同口径比较；随后结合误检样例、漏检样例和消融结果分析模型行为；

最终在系统侧检验推理能力在任务提交、状态查询和结果展示流程中的稳定性。

按照上述技术路线，本文形成了三类研究产出，分别为 LEVIR-Ship 数据与评测记录、DRENet/FCOS/YOLO26 的对比结果与误差分析，以及可运行的 Web 检测系统。后文各章均围绕这些研究产出展开。

1.6 论文结构安排

全文共分为六章，各章内容安排如下：

第一章为绪论，介绍研究背景、问题挑战、研究目标、主要工作以及技术路线；

第二章为国内外研究现状，梳理通用目标检测、小目标检测与遥感船舶检测相关研究，并明确本文切入点；

第三章介绍数据集、评价指标与方法方案，说明统一实验协议、模型选择依据以及实现约束；

第四章给出实验结果与分析，展示三模型主对比结果、效率对比、定性样例与消融实验；

第五章介绍系统需求分析、总体设计与实现过程，说明系统架构、数据库、接口与关键流程；

第六章为总结与展望，归纳全文工作，分析当前边界，并给出后续研究方向。

1.7 本章总结

本章围绕课题背景、研究问题、研究目标与技术路线，对本文的整体工作进行了说明。通过分析弱纹理目标、复杂背景、尺度变化和实验口径不一致等关键难点，进一步明确了本文以统一实验协议、多模型比较和系统落地为主线的研究组织方式，同时概述了全文的主要工作、技术路线和章节安排。这些内容为后续研究现状梳理、实验设计、结果分析和系统实现奠定了总体框架。

2 国内外研究现状

2.1 通用目标检测方法演进

通用目标检测的发展可从 R-CNN 系列展开。Girshick 等人的工作^[18] 将候选区域、特征提取和分类回归整合为统一检测流程，随后 Faster R-CNN^[1] 进一步将候选框生成网络化，成为二阶段路线中的代表性工作。该路线通常具有较好的定位性能，但候选区域处理会带来额外计算开销，推理速度低于更加直接的单阶段方法。

单阶段方法与之相比取消了显式候选区域生成过程，并直接在特征图上进行密集预测。YOLO 系列^[5, 19]、RetinaNet^[3] 和 EfficientDet^[20] 都属于该路线的代表工作，它们结构紧凑、推理速度快、部署便捷，因此在工程场景中应用较多；但当遇到复杂背景和弱目标时，误检与漏检问题仍需要单独分析。

无锚框方法的出发点是减少锚框尺寸、比例和匹配策略带来的调参负担。FCOS^[4] 直接在特征图位置上回归目标框，并用中心概率抑制偏离目标中心的预测。这个设计在通用场景中较有代表性，但遥感微小船舶的目标面积太小，无锚框方法能否稳定优于有锚框方法或专项方法，还需要放到同一任务口径下测试。

另一条近年的路线是 Transformer 检测器。DETR^[6] 将目标检测组织成端到端集合预测问题，Deformable DETR^[7] 和 DINO^[21] 继续改进收敛速度和检测精度。这类方法的全局建模能力较强，不过训练资源、数据规模和调参时间要求也更高。考虑到本课题需要同时完成实验比较和系统实现，本文将作为方法脉络的一部分讨论，没有把它列为主要复现对象。

综合来看，这些方法之间的差异不仅体现在检测精度上，也体现在推理速度、输入设置和调参成本等方面。国内关于深度学习目标检测方法的综述也从候选区域、回归与无锚框等角度总结了这一演进脉络^[22, 23]。本文选择 DRENet、FCOS 与 YOLO26，旨在对专项方法、无锚框方法和单阶段方法三条路线进行同口径比较。

2.2 小目标检测研究进展

小目标检测困难的原因，首先是因为可用像素少导致目标在特征图上经过下采样后可能只剩很小响应，纹理、边缘和上下文都不稳定；同时图像中大量背景区域会放大正负样本不平衡，围绕这些问题，相关研究常从下述几类思路展开。

一类做法直接改进特征表达。FPN^[2] 将浅层细节和深层语义结合起来，后来许

多小目标检测方法都沿用了这种多尺度思想。遥感场景中，SCRDet^[24]等方法进一步结合注意力和旋转检测，以适应小尺度、密集分布目标。这类方法容易和现有检测器组合，但遇到极弱纹理目标时，特征仍可能被背景响应盖住。

另一类思路从尺度入手。SNIP^[25]、SNIPER^[26]和AutoFocus^[27]的结果说明，训练样本选取、多尺度裁块和推理调度都会影响小目标表现。这类策略往往能改善候选区域分配，但实验流程随之变复杂。若不同模型采用不同尺度策略，后续横向比较的结论便需要结合实验条件谨慎解释。

还有一些工作并不大幅调整网络结构，而是通过训练目标设计和样本分布优化来改善小目标学习过程。Focal Loss^[3]通过降低易分类样本权重，使模型更多关注困难样本；数据增强、困难样本重采样和损失重加权也常被用于小目标训练，以缓解前景稀疏、易难样本失衡以及弱目标监督不足等问题。这类方法实现成本相对较低，也较容易与现有检测器结合，但其效果往往依赖数据标注质量、样本分布与超参数设置，迁移到不同任务时仍需重新验证。

最后一类是后处理和推理策略。小目标稀疏、背景又复杂时，置信度阈值、非极大值抑制（NMS）和融合策略会直接改变精度与召回率的平衡。基于这一点，本文在第四章设置了阈值消融实验，以检验相关参数对检测结果的具体影响。

已有综述^[8, 28]也指出，遥感小目标检测还受到旋转变换、密集分布、复杂背景纹理和标注成本影响。中文综述则更多从锚框优化、网络结构优化和特征增强等角度，对小目标检测的常见改进策略进行了归纳^[10, 11]。因此，本文分析模型差异时不只讨论网络结构，也把输入尺度、样本分布和后处理参数一并纳入。

2.3 遥感船舶检测研究现状

船舶检测是遥感目标检测中应用较早、需求较为明确的一类任务。随着公开数据集和开源框架增多，研究重心已经从手工特征逐步转向深度学习检测器。Zhao等人^[9]对光学遥感船舶检测进行了系统梳理，其中指出，这类任务既继承通用检测框架，又必须处理近岸干扰、尺度变化、旋转形态和复杂海况等遥感特有难题。国内关于光学遥感目标检测与舰船检测的综述工作也较为丰富，既有面向光学遥感图像通用目标检测的系统梳理^[15, 29]，也有面向舰船检测任务的专门总结^[12-14, 16, 30]。本文相关研究方向与代表路线脉络如图 2.1 所示。

LEVIR-Ship 数据集^[17]聚焦中分辨率遥感图像中的微小船舶，为不同方法提供




图 2.1 本文相关研究方向与代表路线脉络

了同一数据基础。DRENet 也是围绕该数据集提出的专项方法，其退化重建增强机制主要服务于训练阶段，希望让网络对弱纹理船舶目标更敏感。本文选择它作为主线模型之一，正是因为它和本文场景最贴近。

工程工具链的成熟也改变了此类课题的组织方式。MMDetection^[31] 等开源框架提供了训练、测试和部署所需的基础设施，使不同模型之间的复现与比较更加便利。相关研究也逐渐开始重视评测协议、复现记录和实验流程的一致性，而这种一致性通常需要借助 COCO、VOC 等通用基准协议加以统一^[32, 33]。

本文从通用目标检测、小目标检测和遥感船舶检测三条路线展开，各个路线的代表方法与本文之间的关系如表 2.1 所示。

表 2.1 本文相关研究方向与代表路线

研究方向	代表路线	本文定位
通用检测	Faster R-CNN / FCOS / YOLO / DETR	作为跨范式对比基础
小目标检测	多尺度融合、损失重加权、增强策略	用于分析性能差异来源
遥感船舶检测	LEVIR-Ship + 专项方法（如 DRENet）	聚焦微小船舶场景
工程化实现	MMDetection / Ultralytics / 服务化封装	支撑系统实现

2.4 现有工作的不足与本文切入点

从已有研究看，遥感微小船舶检测已经积累了较多方法成果，但在本文所涉及的多模型比较与系统实现任务中，仍有若干问题需要进一步处理。

第一，实验协议通常并不完全一致。数据划分、输入尺度、阈值和评测脚本若存在差异，结果便难以直接横向比较。第二，一些研究对训练配置和日志记录说明不

足，复现实验时容易受制于工程细节。第三，误差分析常停留在总体指标层面，对复杂海况、近岸背景和弱纹理目标导致的误检与漏检缺乏充分展开。第四，离线实验结果如何进入任务管理、可视化和历史回看流程，仍有待进一步完善。

针对这些问题，本文以统一协议下的多模型比较为主线，选取了 DRENet、FCOS 和 YOLO26 作为三个参照模型，并且结合指标、样例和消融结果讨论它们的适用范围。最后构建相应的 Web 图像推理系统，使算法结果能够进入任务管理、可视化和历史回看流程。

2.5 本章总结

本章从通用目标检测、小目标检测和遥感船舶检测三个方面梳理了与本文相关的研究现状。通用检测方法提供了二阶段、单阶段、无锚框和 Transformer 等跨范式比较坐标；小目标检测研究总结了多尺度表达、样本分配和后处理优化等常见改进思路；遥感船舶检测工作则进一步揭示了近岸干扰、弱纹理目标和复杂海况下的任务特点。与此同时，现有研究在实验协议一致性、误差分析充分性以及系统化落地方面仍存在一定不足。基于上述认识，第三章将进一步转入本文的实验基础与方法方案设计，具体说明数据集、评价指标、模型选择依据以及统一实验协议。

3 数据集、评价指标与方法方案

3.1 实验基础

本章介绍数据集来源、预处理方式、评价指标、模型选择和实验口径，为实验结果分析与系统实现提供统一基础。

3.2 数据集介绍

本文的实验统一采用 LEVIR-Ship 数据集^[17]。该数据集主要面向中分辨率遥感微小船舶检测任务，在复杂海面背景下能够较好反映小目标检出的实际难点，数据集划分如表 3.1 所示。

表 3.1 LEVIR-Ship 数据集划分

数据子集	图像数量	目标数量
训练集	2321	2002
验证集	788	665
测试集	788	552

LEVIR-Ship 中船舶目标普遍较小，背景纹理较为复杂。部分图像中，船体与海浪、岸线或港区设施之间的纹理差异有限，后处理阈值的变化会直接影响模型输出。基于这一特点，本文在实验设计中并未仅以单一主指标评价模型优劣，而是同时记录检出能力、误检控制和工程部署相关指标。

3.3 数据集样例与任务特征

LEVIR-Ship 涵盖了开阔海域、近岸区域、港口区域和多目标密集分布等场景，不同图像块之间背景纹理、目标密度、朝向和局部对比度的差异较大。模型一方面要对微弱目标保持敏感，另一方面又要抑制复杂背景中的伪目标响应。“目标小而背景强”这一矛盾构成了遥感微小船舶检测的核心难点。

图 3.1 展示了不同场景的样例图像。除 AP50 外，本文还记录精度、召回率和 F1 值，并保留成功检测、漏检和误检样例，以观察模型在不同背景条件下的具体表现。



图 3.1 LEVIR-Ship 数据集典型样例

3.4 数据预处理与统一格式

在跨框架实验中，较易产生偏差的环节往往是数据和评测脚本，而非网络结构本身。因此，为减小这部分误差，实验前先统一数据预处理和结果组织方式。

本文首先核对图像与标注文件是否一一对应，并检查空标注、异常坐标和类别不一致等情况；随后将数据统一整理为 COCO 中间格式，使 MMDetection 路线和 YOLO 路线尽量共用同一套评测基础；在此基础上固定 train、val、test 划分及样本清单，以避免模型之间因样本范围不同而产生额外差异；最后，将各模型输出统一整理为包含 image_id、model_name、bbox、score 和 category_id 的结构化记录，供可视化和数据库存储使用。

通过上述处理方式，本文实现了跨模型的数据组织、评测口径与结果表达统一，使模型差异尽可能反映检测范式和实现策略本身，而非数据划分、评测脚本或输出字段设置的不一致。统一格式和统一口径因此构成了本文实验方法的重要组成部分，并为后续结果比较与解释提供了基础。

统一格式也直接服务于系统实现。不同框架与实现方式的推理结果可以进入同

一套后处理与可视化逻辑；结构化结果也能写入 Web 系统数据库，使离线实验结果和在线任务回放使用同一类数据表达。数据预处理与统一格式流程如图 3.2 所示。




图 3.2 数据预处理与统一格式流程图

3.5 评价指标

本文实验使用 AP50 作为主指标，AP50-95、精度、召回率与 F1 值作为辅助指标，其相关定义如下：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (1)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (2)$$

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}, \quad (3)$$

$$\text{IoU} = \frac{|B_{pred} \cap B_{gt}|}{|B_{pred} \cup B_{gt}|}. \quad (4)$$

其中，精度（Precision）用于反映预测结果中真正例所占比例，召回率（Recall）用于反映真实目标被检出的比例，F1 值用于综合衡量精度与召回率之间的平衡，交并比（IoU）用于衡量预测框与标注框之间的重叠程度。AP50 对应交并比（IoU）阈值为 0.5 时的平均精度，本文用其观察模型能否有效检出微小船舶；AP50-95 覆盖多个交并比阈值，对边框位置质量更敏感；精度更接近误检控制情况，召回率更接近漏检控制情况，F1 值用于观察二者折中。本文还记录帧率（FPS）、参数量和 FLOPs 等效率指标，用于讨论模型接入系统时的部署成本。相关评测口径与交并比阈值区间设置与 COCO 指标定义保持一致^[32]。

3.6 指标选择依据

将 AP50 设为主评价指标，主要是考虑到遥感图像中的船舶目标尺度较小。预测框和标注框只要偏移几个像素，交并比就可能明显变化。若过度依赖高交并比阈值，边框回归误差会被放大，模型是否完成有效检出反而不易判断。AP50 用于衡量基本检出能力，AP50-95 则补充反映定位质量。

精度、召回率和 F1 值在本文中同样重要。由于 DRENet、FCOS 与 YOLO26 的设计出发点不同，若仅按照 AP50 排序，容易掩盖误检与漏检之间的取舍差异。召回率较高的模型更适合目标排查类场景，精度较高的模型则更适合结果输出需要稳定可控的系统展示场景。因此，精度-召回率平衡也是本文解释模型行为的重要依据。

3.7 模型方案

为了让对比不局限在同一类检测器内部，本文选取三类模型：DRENet 对应遥感微小船舶专项方法，FCOS 对应无锚框检测路线，YOLO26 对应单阶段检测路线。

3.7.1 遥感微小船舶检测专用方法：DRENet

DRENet 是针对 LEVIR-Ship 数据集提出的专项方法^[17]，通过在训练阶段引入退化重建增强机制，使网络更关注弱纹理船舶目标。本文将 DRENet 作为主模型之一，并重点考察其在召回率、复杂背景和召回优先任务中的表现。图 3.3 展示了 DRENet 的检测流程，其中训练期增强路径与检测主干路径共同参与特征学习，而推理阶段仅保留检测主干完成目标检出。




图 3.3 DRENet 检测流程示意

从神经网络工作机理看，DRENet 由“检测主干路径 + 训练期增强路径”两部分

构成。检测主干负责常规定位与分类；增强路径通过退化-重建任务向骨干特征注入弱纹理目标的判别信息，并在训练阶段提供附加监督。该设计的直接效果是提升模型对微小、低对比船舶目标的敏感性。

DRENet 的主要设计特点包括以下几个方面：

- (1) **退化重建增强机制**：训练阶段对输入图像施加模拟退化（模糊、噪声、分辨率下降等），再要求网络从退化版本中重建原始外观，该辅助分支与检测主干共享同一骨干网络，使骨干同时接受检测损失与重建损失的双重监督，从而显式强化对弱纹理目标的判别能力。即使目标在退化后几乎不可辨认，网络仍被约束去恢复其特征。
- (2) **跨阶段区域记忆增强模块（CRMA）**：该模块将浅层特征图（保留空间细节与边缘信息）与深层特征图（承载语义判别信息）进行跨阶段连接与融合，使小目标的定位信号不会在下采样过程中被完全淹没。相比仅依赖 FPN 的自顶向下路径，CRMA 提供了更直接的浅层与深层协同通道。
- (3) **双路径联合训练策略**：检测路径与重建路径在训练期并行运行，推理时只保留检测路径，不增加额外推理开销，这种“训练期增强、推理期无负担”的设计使 DRENet 在保持推理效率的同时获得了对弱纹理目标的更高敏感性。

从实验结果看，DRENet 的召回率通常更高，但在复杂背景下误检压力也相对更大，因此更适合作为召回优先路线。DRENet 的网络结构如图 3.4 所示，其核心在于将退化重建增强分支与检测主干协同训练，以提高对弱纹理目标的敏感性。




图 3.4 DRENet 网络结构图，引自^[17]

3.7.2 无锚框代表性目标检测方法：FCOS

FCOS 用位置回归替代锚框设计，减少了锚框尺寸、比例和匹配策略等超参数依赖^[4]。本文将 FCOS 作为无锚框路线的代表模型，与专项方法和单阶段路线放在同一评测口径下比较，观察其在遥感微小船舶任务上的实际表现。图 3.5 展示了 FCOS 的检测流程，即在多尺度特征图上直接进行逐点回归，并结合中心概率分支完成候选框排序与筛选。




图 3.5 FCOS 检测流程示意

FCOS 的基础机理是无锚框密集回归。输入图像经主干网络与特征金字塔网络 (FPN) 生成多尺度特征后，检测头在每个位置直接预测边框偏移和类别分数，并通过中心概率分支评估预测质量。最终由分类分数与中心概率联合排序，再经非极大值抑制 (NMS) 输出检测结果。

FCOS 的主要设计特点包括以下几个方面：

- (1) **逐点预测替代锚框匹配**：FCOS 在特征图每个位置直接预测该点到目标边界框四条边的距离偏移（上、下、左、右），以及类别概率，完全取消了锚框的尺度、比例和匹配阈值等超参数设计，这一改变降低了跨数据集迁移时的调参负担，也避免了锚框匹配中正负样本定义不一致的问题。
- (2) **中心概率分支抑制低质量候选**：远离目标中心的特征点往往产生定位不准确的预测框，传统无锚框方法中这些低质量候选会拉低整体排序效果，FCOS 引入中心概率分支，预测每个点距目标中心的相对距离，并将中心概率与分类分数相乘作为最终排序依据，从而有效抑制边缘区域的低质量候选框，提升检测结果的整体排序稳定性。
- (3) **基于 FPN 层级的尺度分配策略**：FCOS 为不同 FPN 层级显式指定目标尺度范围，每个层级只负责特定大小区间的目标检测，减少了不同层级之间的预

测重叠与竞争，使小目标在浅层层级获得更充分的响应空间。

在本课题中，FCOS 的优势在于训练口径清晰、精度-召回率折中较稳；其不足在于对输入尺寸较为敏感，当推理输入过小时，特征图分辨率不足以支撑逐点回归精度。FCOS 的网络结构如图 3.6 所示，其主干网络、特征金字塔网络和检测头共同构成了典型的无锚框检测框架。




图 3.6 FCOS 网络结构图，引自^[4]

3.7.3 单阶段代表性目标检测方法：YOLO26

YOLO 系列以单阶段预测和推理效率见长，在工程部署中使用较多^[5, 19]。本文选取 YOLO26 代表单阶段路线，关注它在检测精度、边框质量、训练链路成熟度和系统接入成本之间的表现。图 3.7 展示了 YOLO26 的检测流程，即通过主干网络提取特征、特征融合层进行跨尺度融合，并由多尺度检测头完成目标预测。




图 3.7 YOLO26 检测流程示意

YOLO26 延续单阶段端到端范式：主干网络提取语义特征，特征融合层执行跨

尺度融合，检测头在多个尺度同时输出候选框与类别分数，单次前向即可完成检出。该结构在工程上具备较好的吞吐效率与部署友好性。

YOLO 路线的主要设计特点包括以下几个方面：

- (1) **多尺度检测头增强小目标可见性：**YOLO26 在三个不同尺度的特征图（P3、P4、P5）上同时设置检测头，浅层特征图分辨率较高，能够保留更多小目标的细节信息，使微小船舶在浅层层级获得更充分的候选框生成机会，相比只在单一尺度输出的检测器，多尺度检测头对小目标的覆盖更完整。
- (2) **结构轻量化与高效模块设计：**YOLO26 采用 C2f 等高效构建模块替代传统重参数卷积，在保持特征表达能力的同时控制参数量与计算量，本文实验中 YOLO26 的参数量仅为 2.5M、FLOPs 为 3.7G，远低于 FCOS 的 32.2M 与 123.0G，使它在部署场景中具备更高的吞吐效率。
- (3) **任务对齐分配与训练增强策略：**YOLO26 采用任务对齐分配替代传统交并比匹配策略，将分类质量与定位质量联合评估来分配正负样本，使训练阶段的样本定义更贴合最终评测目标。同时配合 Mosaic、MixUp 等数据增强策略，提升模型对稀疏小目标和复杂背景的泛化能力。

在本课题中，YOLO26 的优势在于输出结果较为稳定、部署链路成熟，适合作为系统中的默认候选方案；它与 DRENet 在误检控制方面也能形成互补。YOLO26 的网络结构如图 3.8 所示，该结构通过轻量化模块与多尺度检测头兼顾检测精度和部署效率。


3.8 统一实验协议与实现约束

为保证模型比较具有明确边界，本文对实验协议作出统一约束：数据划分和评测口径保持一致，实验环境、配置文件、权重路径、日志文件和关键结果均保留记录，结果输出结构也作统一整理，以便系统侧调用。统一协议并不意味着将所有模型改造成完全相同的实现形式，而是在保留各自实现特征的前提下，采用统一评测流程比较不同模型在同一任务中的表现。

在实现层面，本文通过统一推理入口封装不同模型能力：

```
predict(image_path, model_name, conf_threshold, iou_threshold)
```

在统一推理入口基础上，本文进一步封装了融合推理接口和系统任务执行逻辑，模型训练后的离线评测、命令行单图推理、批量推理以及 Web 系统接入，均调用同

图 3.8 YOLO26 网络结构图，引自^[19]

一个核心入口。

3.9 本章总结

本章围绕实验基础与方法方案，对比较研究所需的数据、指标和模型设置进行了统一说明。文中介绍了 LEVIR-Ship 数据集的任务特点、数据预处理与结构化记录方式，明确了 AP50、AP50-95、精度、召回率和 F1 值等评价指标及其选择依据，并说明了 DRENet、FCOS 和 YOLO26 三类代表模型的设计特点、选取原因以及统一实验协议和推理接口封装约束。这些内容为第四章的实验结果分析和第五章的系统接入实现提供了统一基础。

4 实验结果与分析

4.1 实验环境与设置

本章基于 LEVIR-Ship 数据集上的实验记录，对模型 DRENet、FCOS 和 YOLO26 进行比较。记录指标包括 AP50、AP50-95、精度、召回率与 F1 值；工程方面记录了帧率（FPS）、参数量和 FLOPs。训练配置、权重文件、运行日志和结果文档也均已保存，文中表格和图示均可追溯到对应产物。除离线训练和测试外，系统侧推理流程也完成联调，相关输出可用于第五章的任务管理与结果回看说明。本文实验的硬件、软件和关键超参数记录如表 4.1 所示。

表 4.1 实验环境与关键配置

配置项	设置说明
操作系统	macOS（本地联调）+ Linux（云端训练）
主要计算设备	本地 CPU/MPS（推理与验证）；云端 NVIDIA RTX 3080 Ti 12GB（主训练）
后端框架	PyTorch, MMDetection (FCOS), Ultralytics (YOLO26), DRENet 原始实现
系统框架	FastAPI + React + SQLite
数据集与划分	LEVIR-Ship, 固定 train/val/test 划分 (2321/788/788)
输入尺寸 (主口径)	DRENet: 512; YOLO26: 512; FCOS: 800
置信度与交并比阈值	默认 conf=0.25、iou=0.50（另做阈值消融）
主要评测指标	AP50（主指标）、AP50-95、精度、召回率、F1 值
效率指标采集口径	帧率 (FPS) 统一在单图推理场景统计；参数量与 FLOPs 按模型结构计算并统一换算单位
结果记录与追踪	保留配置文件、权重路径、运行日志、结构化预测结果和可视化产物

4.2 模型定量实验结果对比

本文所集成的三个目标检测模型的核心实验结果如表 4.2 和图 4.1 所示，对应日志和权重均已留存。下表从 AP50、AP50-95、精度、召回率和 F1 五个指标展开对比，观察各模型在检出能力和输出质量上的具体差异。

表 4.2 模型在 LEVIR-Ship 数据集上的主对比结果

模型	AP50	AP50-95	精度	召回率	F1 值
DRENet	0.7949	0.2919	0.4927	0.8511	0.6241
FCOS	0.7389	0.2880	0.7621	0.8297	0.7944
YOLO26	0.7950	0.3170	0.8430	0.7220	0.7778




图 4.1 模型主对比结果的指标可视化

表 4.2 从检出精度、定位质量和综合性能三个维度对三类模型进行了横向比较。由图 4.1 可以直观看出，三模型在各项指标上呈现出不同的分布特征，没有单一模型在所有维度上均占优。具体而言，YOLO26 和 DRENet 的 AP50 几乎相同，分别为 0.7950 和 0.7949，而 FCOS 为 0.7389，故仅从 AP50 看，专项方法和成熟的单阶段路线在该数据集上都能完成较稳定检出，而 FCOS 与前两者依然有明显差距。

差异主要出现在 AP50-95、精度和召回率上。YOLO26 的 AP50-95 为 0.3170，高于 DRENet 的 0.2919 和 FCOS 的 0.2880，说明在更严格的交并比阈值下，其边框位置更稳定。DRENet 的召回率为 0.8511，高于 YOLO26 的 0.7220 和 FCOS 的 0.8297，但精度仅为 0.4927，低于 YOLO26 的 0.8430 和 FCOS 的 0.7621。这表明 DRENet 对可疑目标的保留更充分，但同时带来了更多误检；YOLO26 对候选框筛选更严格，输出结果更为整洁；FCOS 的精度和召回率折中较好，F1 值为 0.7944，但整体检出能力弱于前两者。

4.3 效率与部署属性分析

在工程部署场景下，除精度指标外，还要关注模型在速度和复杂度方面的表现，当前可用效率结果如表 4.3 所示。

表 4.3 模型效率与复杂度对比

模型	帧率 (FPS)	参数量 (M)	FLOPs(G)
DRENet	121.8993	4.7882	4.2057
FCOS	45.9559	32.1664	123.0000
YOLO26	69.0625	2.5042	3.6939

各模型在效率维度上的排序与精度维度并不完全一致。DRENet 在实验记录中的帧率最高，说明其推理速度最快；YOLO26 的参数量为 2.50M、FLOPs 为 3.69G，模型规模最小；FCOS 的参数量和计算量均较高，因此整体效率低于前两者。模型效率与复杂度对比的可视化结果如图 4.2所示。




图 4.2 模型效率与复杂度对比柱状图

从精度与效率两个维度综合分析，DRENet 在召回率与推理速度上具有明显优势，YOLO26 在定位质量、误检控制与模型规模之间更为均衡，FCOS 的精度-召回率折中较好，但整体检出能力与效率偏弱。为进一步展示三模型在精度与效率各维度上的相对表现，本文绘制了多维度雷达图，如图 4.3所示，其中参数效率和计算效率取逆指标（越小越优）进行归一化。




图 4.3 模型多维度综合雷达图

4.4 模型逐项分析

4.4.1 DRENet 结果分析

DRENet 在上述结果中的突出特点是召回率较高，其召回率为 0.8511，高于 YOLO26。这表明该模型在复杂背景和弱纹理目标场景下更倾向于保留候选框。若任务目标是优先发现可疑船舶并交由人工复核，则该路线具有更高的实际价值。其不足在于精度较低，仅为 0.4927，误检风险相对较高，近岸区域、港区设施和背景边缘纹理均可能被保留下来。因此，DRENet 更适合作为召回优先的模型候选方案。

4.4.2 FCOS 结果分析

FCOS 的 AP50 为 0.7389，低于 DRENet 与 YOLO26；但其精度为 0.7621、召回率为 0.8297、F1 值为 0.7944，表明在当前评测配置下，FCOS 的精度与召回率折中表现优于 DRENet。不过，FCOS 的参数量 (32.17M) 和计算量 (123.00G) 均明显高于另外两个模型，且推理速度最慢 (45.96 FPS)，因此整体推理效率偏低。在遥感微小船舶任务中，FCOS 的检出能力弱于 DRENet 和 YOLO26，但其精度-召回率平衡和 F1 稳定性仍具有一定参考价值。

4.4.3 YOLO26 结果分析

YOLO26 的 AP50 与 DRENet 几乎相同，但它的 AP50-95、精度和 F1 值更高，其中精度达到 0.8430，说明在当前阈值设置下，它能够一定程度上避免检出复杂背景中的伪目标。YOLO26 也更符合工程部署需求，其训练链路较为成熟，接口封装相对直接，因此在系统接入时的适配成本较低；同时，它也可以与 DRENet 在误检控制方面形成互补。

4.5 定性样例与误差分析

定量指标只能给出整体趋势，定性样例可以进一步呈现不同错误类型。本文整理成功检测、漏检和误检样例，并结合表 4.2 的指标解释模型行为。

4.5.1 成功检测样例

在成功样例中，模型 DRENet 在海面纹理较弱、目标尺寸较小的图像上仍能给出响应，与其召回偏高的定量结果相符，而 YOLO26 的结果更加整洁，尤其在多目标和常规场景中，预测框与标注框的匹配结果更稳定，同时 FCOS 也能在部分样例中完成定位，但其波动更大。如图 4.4 所示，各模型在本文代表样本上的检测风格差异较大。




图 4.4 模型成功检测样例对比

4.5.2 漏检样例

在漏检样例中,三类模型都会遗漏目标,但结果的遗漏位置和原因不同,如图 4.5 所示,结果的标注框与预测框之间的差异,主要是出现在弱纹理、小尺寸以及背景对比度不足的区域。




图 4.5 模型漏检样例对比

上述漏检现象主要影响召回率指标,反映模型对弱纹理、小尺度目标的敏感程度。然而,仅从漏检角度不足以完整解释各模型在精度上的显著差异。与漏检导致的召回损失不同,误检行为直接反映模型对背景干扰的抑制能力:当模型将海浪波纹、云层边缘或港区设施纹理误判为船舶目标时,会产生大量虚假候选框,从而直接降低精度。因此,为更全面地理解 DRENet、YOLO26 与 FCOS 在表 4.2 中的精度差异,有必要进一步分析三类模型的误检样例及其分布规律。

4.5.3 误检样例

误检样例则更能解释精度结果的差异,DRENet 更加容易把复杂背景纹理保留下来,而 YOLO26 偶尔会在边缘背景区域产生额外检测结果;同时 FCOS 也存在误检,但数量和位置与前两者不同,如图 4.6 所示,三者误检分布位置并不一致。



图 4.6 模型误检样例对比

结合这些样例与表 4.2 可知,模型之间的差异并不只体现在分数高低上。DRENet 更偏向优先检出目标,在复杂背景下误检会增多;YOLO26 更强调输出稳定性和边框质量,在弱目标场景下可能遗漏部分目标;FCOS 的精度-召回率折中较好,但检出能力和效率均弱于前两者。

4.6 消融实验

为进一步解释主表中精度与召回率的差异,本文补充了置信度阈值和输入尺寸两组消融实验。前者用于观察候选框筛选变化后各模型的响应,后者用于分析推理输入尺寸变化对检测结果的影响。选择这两个维度是因为置信度阈值是系统部署中最常调节的后处理参数,而输入尺寸则直接影响推理速度与显存占用,二者均关乎模型从实验环境向实际系统迁移时的性能取舍。消融实验保持其他条件不变,仅改变目标变量,以排除干扰因素。

4.6.1 阈值消融分析

阈值消融固定交并比阈值为 0.50,置信度阈值取 0.15、0.25 和 0.35。本文主要观察阈值升高后精度、召回率和 F1 值的变化情况。模型结果如表 4.4 所示。

表 4.4 模型阈值消融结果

模型	设置	AP50	精度	召回率	F1 值	结论
DRENet	conf=0.15	0.6616	0.6441	0.7935	0.7110	低阈值召回更高，但误检增加
DRENet	conf=0.25	0.6616	0.7331	0.7663	0.7493	默认值更均衡
DRENet	conf=0.35	0.6616	0.7778	0.7355	0.7561	精度继续上升，召回下降
FCOS	conf=0.15	0.7389	0.7283	0.8351	0.7781	低阈值检出更充分
FCOS	conf=0.25	0.7389	0.7621	0.8297	0.7944	默认值已较均衡
FCOS	conf=0.35	0.7389	0.7761	0.8225	0.7986	F1 略优于 0.25
YOLO26	conf=0.15	0.6661	0.6412	0.7899	0.7078	召回提升明显，但误检偏多
YOLO26	conf=0.25	0.6661	0.7527	0.7609	0.7568	综合表现最均衡
YOLO26	conf=0.35	0.5914	0.8248	0.6993	0.7569	精度最高，但 AP50 与召回下降




图 4.7 模型阈值消融趋势图

表 4.4 和图 4.7 显示，阈值升高后，模型的精度大多上升，召回率大多下降。这一趋势符合候选框筛选逻辑，也说明后处理阈值会明显改变遥感微小船舶检测结果。

DRENet 对阈值变化较为敏感。低阈值会进一步放大其召回倾向，但误检也随之增加；当阈值提高到 0.35 时，精度升至 0.7778，召回率降至 0.7355。若系统需要在检出率与误检数量之间取得折中，则 0.25 相比 0.15 和 0.35 更适合作为默认值。FCOS 和 YOLO26 的变化相对平缓：FCOS 在当前稳定权重下，阈值由 0.25 提高到 0.35 时，F1 值从 0.7944 小幅升至 0.7986，说明略高阈值可以减少部分冗余候选；YOLO26 在 0.25 时 AP50、精度和召回率的组合更均衡，继续升高到 0.35 后，精度虽提升至 0.8248，但 AP50 与召回率同时下降。因此，综合 AP50、精度、召回率和 F1 值，0.25

更适合作为实验与系统推理的默认阈值。

4.6.2 输入尺寸敏感性分析

输入尺寸敏感性分析固定置信度阈值为 0.25、交并比阈值为 0.50，只改变推理阶段的输入尺寸。DRENet 的推理流程对输入尺寸有固定约束（模型内部将输入缩放至预设分辨率后输出固定尺寸特征图，不支持自定义推理尺寸），因此本节重点比较 FCOS 与 YOLO26 在不同输入下的响应差异，结果如表 4.5 所示。

表 4.5 FCOS 与 YOLO26 输入尺寸敏感性分析结果

模型	设置	AP50	精度	召回率	F1 值	结论
FCOS	imgsz=512	0.4490	0.5903	0.6395	0.6139	输入过小时性能受限
FCOS	imgsz=640	0.6452	0.7405	0.7808	0.7601	相比 512 提升明显
FCOS	imgsz=800	0.7389	0.7621	0.8297	0.7944	本组综合表现最优
YOLO26	imgsz=512	0.6661	0.7527	0.7609	0.7568	基线稳定
YOLO26	imgsz=640	0.6737	0.7543	0.7953	0.7743	综合表现最优
YOLO26	imgsz=800	0.6564	0.6827	0.7989	0.7362	召回提高但误检增加




图 4.8 输入尺寸敏感性趋势图

图 4.8 展示了 FCOS 与 YOLO26 在不同输入尺寸下的指标变化趋势。由图和表 4.5 可知，FCOS 对输入尺寸更敏感，512 到 800 的 AP50、精度、召回率和 F1 值均呈上升趋势；YOLO26 在 640 输入下取得本组最高 AP50 和 F1 值，精度与召回率也保持较好平衡。当输入继续增至 800 时，YOLO26 的召回率略升，但精度和 F1 值明显下降，说明更大输入会带来更多候选目标，同时也更容易引入误检。

4.7 本章总结

本章在统一实验协议下，对 DRENet、FCOS 和 YOLO26 三种模型进行了系统比较，并从定量指标、定性样例和消融实验三个层面展开分析。主对比结果表明，DRENet 与 YOLO26 在 AP50 上接近，但前者更偏召回优先，后者在精度与定位质量方面更为均衡；FCOS 的精度与召回率折中较好，但整体检出能力和效率相对偏弱。误差样例分析以及阈值、输入尺寸消融实验进一步说明，不同模型在误检控制、漏检风险和参数敏感性方面存在明显差异。这些结果为模型选择与系统部署取舍提供了依据，也为第五章的系统实现和结果展示提供了实验支撑。

5 系统需求分析、设计与实现

5.1 系统建设目标

系统部分围绕遥感微小船舶检测任务展开，目标是实现图像上传、模型推理、任务管理、结果可视化和历史记录查询等功能。系统整体覆盖前端交互、后端服务、数据持久化和算法接入等环节，使实验结果能够以任务形式进行管理和复查。

本文系统采用 React + FastAPI + SQLite 的前后端分离架构。前端使用 React 负责任务提交、状态查询和结果展示；后端通过 FastAPI 组织 HTTP 接口并调用模型推理代码；SQLite 数据库用于保存任务、结果和产物路径。该架构层次清晰，便于后续接口维护和结果追踪。系统直接接入第四章训练好的 DRENet、FCOS 和 YOLO26 模型权重，使离线实验结果能够在 Web 环境中复用和展示。

5.2 系统需求分析

5.2.1 功能需求

结合课题任务，系统需要覆盖以下功能。

- (1) **模型管理**：可读取模型配置和展示模型名称、状态和权重信息，并且支持模型启用或停用；
- (2) **任务提交**：能够支持单张图像与批量图像上传，并允许用户设置模型类型和置信度阈值；
- (3) **任务执行**：用异步的方式执行推理任务，用于避免前端界面阻塞，且支持任务状态查询；
- (4) **结果展示**：展示检测框可视化图像、结构化检测结果表格及统计信息；
- (5) **结果持久化**：在系统重启后，仍可保留历史任务的结果和输出文件路径，以支持任务复查。

表 5.1 为各操作场景的响应定义，用于约束前后端联调时的行为一致性。功能需求覆盖了从模型管理、任务提交到结果展示的完整链路，既满足单图快速检测的场景，也支持批量任务的处理与进度跟踪。系统设计时预留了扩展空间，后续如需接入新模型或增加数据导出格式，可在现有模块基础上直接扩展。

表 5.1 功能需求的操作与响应定义

操作场景	用户操作	期望系统响应
模型管理	启用/停用模型	页面状态即时更新，后端返回成功状态并持久化
单图任务提交	上传 1 张图并提交	返回 <code>task_id</code> ，任务状态进入 <code>queued/running</code> ，跳转详情页
批量任务提交	上传多图并提交	返回 <code>task_id</code> ，列表与详情页显示总数与完成数进度
任务执行失败	模型路径错误或输入异常	状态变为 <code>failed</code> ，并在详情页返回可读错误信息
结果回看	打开历史任务详情	展示任务参数、可视化图、结构化结果和统计图
结果导出	点击 CSV 导出	生成并下载包含 <code>bbox/score/-source_model</code> 的结果文件

5.2.2 非功能需求

非功能需求主要包括可维护性、可复现性和稳定性。环境安装、数据库初始化和项目启动方式需要可重复；算法层、服务层和展示层的边界要清楚，后续替换模型时不至于牵动整套页面；界面信息需要能够清楚呈现任务状态、模型参数和检测结果。功能需求与非功能需求共同决定了系统的分层结构：前端负责交互展示，后端承担业务逻辑与任务调度，数据库处理持久化，算法层则封装模型推理能力。各层之间通过接口解耦，以支持后续功能扩展和模型替换。清晰的模块边界也便于对各层进行独立测试与验证，降低集成阶段的故障定位难度。这种设计在保证系统可维护性的同时，也为后续功能迭代和性能优化预留了调整空间。

5.3 系统总体架构

系统采用前后端的组织分离架构，如图 5.1 所示，前端页面用于处理任务创建、列表查询和结果可视化，后端为前端提供接口服务、任务调度、状态管理和历史文件访问；而数据库则用于保存模型、任务、检测结果和输出文件路径；算法能力层用于封装整体模型预测服务、模型适配器与融合逻辑，并由后端通过统一接口调用。分层设计将展示逻辑、业务逻辑与算法实现解耦，使界面迭代和模型替换能够独立进行，降低系统维护成本。




图 5.1 系统总体架构图

根据不同的功能，本系统可以划分为以下五层：

- (1) **前端展示层**：使用 React、Vite、TypeScript 与 Ant Design 技术栈，实现任务提交页、任务列表页、任务详情页和模型管理页；
- (2) **后端服务层**：使用 FastAPI 提供任务提交、任务查询、结果查询、模型查询和健康检查等接口；
- (3) **任务调度层**：使用 ThreadPoolExecutor 实现异步任务执行，以降低界面阻塞；
- (4) **数据持久化层**：使用 SQLite 与 SQLAlchemy 技术栈来保存模型信息、任务状态、检测结果与文件路径；
- (5) **算法能力层**：用于封装预测函数服务、模型适配器与融合逻辑以实现单模型与融合模式推理。

图 5.1 中的分层体现了系统各模块的职责边界，前端只和 HTTP 接口交互，不直接接触模型文件；而后端通过统一推理入口调用 DRENet、YOLO 或融合逻辑；数据库和输出目录则共同保存状态与产物路径，后续替换模型时，可以优先修改算法能

力层和配置文件。

5.4 数据库设计

根据任务追踪和结果回看功能，数据库的核心表包括 `models`、`tasks`、`results` 和 `task_files`，`models` 表保存模型名称、键值、权重路径和启停状态；`tasks` 表记录任务类型、执行模式、状态和时间；`results` 表保存检测框结构化结果；`task_files` 表记录输入图、输出 JSON 和可视化结果路径。




图 5.2 系统数据库 E-R 图

图 5.2 展示了四张表之间的关系，`tasks` 表位于任务链路中心，一条任务可以对应多条检测框结果，也可以对应多个输入或输出文件记录，`models` 表同时服务前端模型管理页和后端推理校验，通过组合这些表，系统可以记录从任务创建到结果回

看的完整链路。

5.5 接口设计

后端接口统一挂载在 `/api/v1` 路径下，其核心接口设计如表 5.2所示。

表 5.2 系统核心接口设计

接口路径	请求方式	功能说明
<code>/api/v1/tasks/infer</code>	POST	提交单图或批量推理任务，返回任务编号与初始状态
<code>/api/v1/tasks</code>	GET	查询任务列表、状态、进度与时间信息
<code>/api/v1/tasks/<task_id></code>	GET	查询单个任务的参数、状态与错误信息
<code>/api/v1/tasks/<task_id>/progress</code>	GET	查询任务进度，返回状态与完成计数，用于高频轮询
<code>/api/v1/tasks/<task_id>/results</code>	GET	查询任务结果、可视化文件路径和结构化检测框
<code>/api/v1/models</code>	GET	查询模型列表与启停状态
<code>/api/v1/models/<model_key></code>	PATCH	更新模型启停状态
<code>/api/v1/health</code>	GET	查询服务健康状态与模型加载情况

后端接口主要覆盖任务提交、任务查询、结果查询、模型查询和健康检查，且统一管理在 `/api/v1` 路径下，便于前端统一调用和后续接口维护。

5.6 关键实现流程

5.6.1 任务创建与执行流程

任务流程始于用户在前端上传图像。完成模式、模型和阈值选择后，前端调用 `/api/v1/tasks/infer`。后端接收请求后，首先校验图像、阈值和模型配置，并建立任务记录写入数据库；随后将任务交由线程池执行器，根据参数选择单模型或融合模式，再调用统一推理接口完成检测。

任务状态记录为 `queued`、`running`、`done` 和 `failed` 四种，前端列表页和详情页依据这些状态展示任务生命周期；若推理或文件处理过程中发生错误，后端会将错误信息写回任务记录，便于定位失败原因。

5.6.2 结果生成与展示流程

推理完成后，结构化检测结果写入数据库，输入图、输出 JSON 和可视化图像保存到 `outputs/tasks/<task_id>/`。任务运行期间，前端优先轮询 `/api/v1/tasks/<task_id>/progress` 接口，只获取 `status`、`done_count` 和 `input_count` 等字段；任务结束后，再请求结果接口加载完整检测框和可视化产物。任务执行与结果展示流程如图 5.3 所示。




图 5.3 系统关键流程图

5.7 模块实现细节

5.7.1 端到端数据流与职责分解

本文将一次任务的端到端链路拆分为四个阶段，即前端请求构建、后端推理编排、结果持久化和可视化回传。前端提交参数时，统一封装模型键值、阈值、执行模式和输入文件；后端接口层负责参数校验与任务建档；调度层在后台线程中调用预测服务并聚合检测框；存储层将任务状态、检测结果和产物路径落盘；最后由结果接口将结构化结果和可视化文件返回前端页面完成展示。该分段设计使接口层、算法层与存储层可以独立维护，后续替换模型时无需改动前端交互协议。

5.7.2 单图检测逻辑（接口层）

接口层的核心职责是“参数标准化 + 任务创建 + 异步投递”，其核心逻辑如下代码所示。

```
def submit_infer_task(request):
    payload = normalize_request(request)
    validate_model_and_threshold(payload)
    task = task_repo.create(
        mode=payload.mode,
        model_key=payload.model_key,
        conf=payload.conf,
        iou=payload.iou,
        status="queued"
    )
    executor.submit(run_infer_pipeline, task.id, payload)
    return {"task_id": task.id, "status": "queued"}
```

该逻辑保证了前端拿到任务编号后即可进入轮询，不需要阻塞等待推理完成，即使后续任务失败，也能通过 `task_id` 在详情页定位错误信息，提升了系统可观测性。异步投递机制将请求接收与推理执行解耦，使接口层能够快速响应前端请求，避免因模型推理耗时导致的连接超时或阻塞积压。

5.7.3 推理调用逻辑（服务层）

服务层聚焦“统一预测入口 + 多模型策略分发”，单模型模式下直接调用指定模型适配器；融合模式下按配置选择串行或并行执行，再将结果交给融合后处理。其核心流程如下代码所示。

```
def run_infer_pipeline(task_id, payload):
    task_repo.update_status(task_id, "running")
    image_list = prepare_inputs(payload.files)
    for image_path in image_list:
        if payload.mode == "single":
            records = predict_service.predict(
                image_path=image_path,
                model_name=payload.model_key,
                conf_threshold=payload.conf,
                iou_threshold=payload.iou
            )
        else:
            records = predict_service.predict_fusion(
                image_path,
                payload
            )
        result_repo.save_records(task_id, image_path, records)
    task_repo.update_status(task_id, "done")
```

该设计将“接口协议”与“算法实现”分离：接口层不感知具体模型框架差异，服务层通过适配器完成 DRENet、FCOS、YOLO26 的统一调用，便于后续新增模型。

5.7.4 结果聚合逻辑（存储层）

存储层负责“状态写回 + 文件索引 + 结构化检测框存储”，其目标是确保任务可追溯与结果可复查，对应逻辑如下代码所示。

```
def save_records(task_id, image_path, records):
```

```
vis_path = render_and_save(image_path, records, task_id)
json_path = dump_json(records, task_id, image_path)
db.insert_task_file(task_id, "input", image_path)
db.insert_task_file(task_id, "vis", vis_path)
db.insert_task_file(task_id, "json", json_path)
for rec in records:
    db.insert_result(
        task_id, image_path,
        rec["bbox"], rec["score"], rec["label"]
    )
```

通过上述写入流程，系统既能展示可视化图片，也能导出结构化表格，满足“页面复查 + 数据再分析”双重需求。

5.8 系统实现效果

经过前后端联调和真实模型接入测试，系统已完成任务创建、推理执行、结果保存和历史回放的整体链路联通。当前系统可以接入 DRENet、YOLO 与 FCOS 模型权重，完成单图和批量推理；任务列表模块支持轮询刷新、进度展示和失败状态标记；任务详情页展示模型来源、检测框、平均置信度和统计图表；结构化检测结果可以导出为 CSV 表格。SQLite 数据库则保存历史任务和检测结果，保证系统重启后仍可查询。

5.8.1 前端页面实现效果

任务提交页支持单图和批量输入，并将推理模式、模型选择和阈值参数集中在同一表单区域；任务列表页突出状态、进度、模式、创建时间和耗时等信息；任务详情页展示可视化结果、检测框表格、模型来源和统计图表，用于回看单次任务的输入、执行和输出。相比仅展示单张检测结果图，Web 前端可以同时呈现任务参数、执行状态、结果图像和结构化检测框，使实验结论不仅停留在表格和文字中，也能够通过系统任务记录进行复查。如图 5.4 所示，任务提交页、任务列表页和任务详情页共同构成了完整的使用链路。

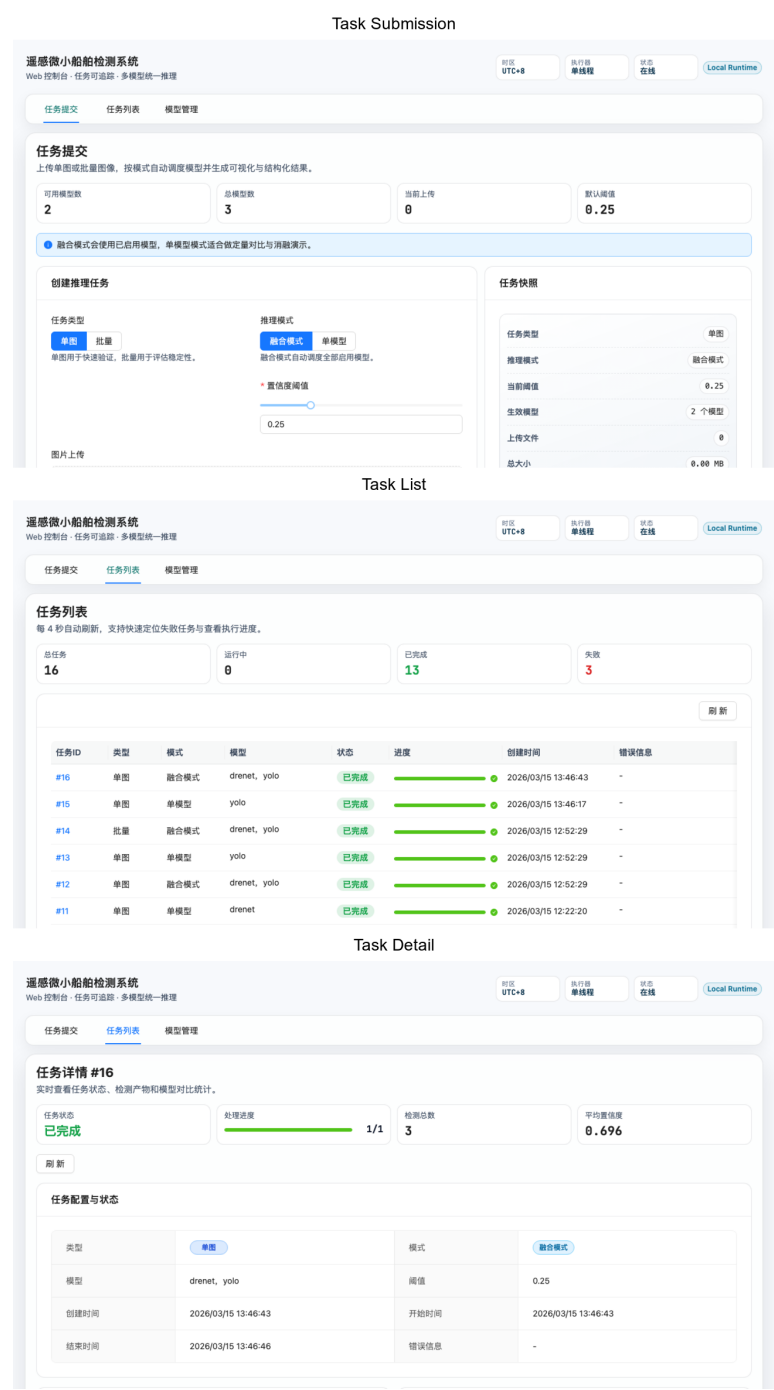


图 5.4 系统主要页面实现效果

5.9 系统输出案例集

本节选取数据集中三组不同样本的系统输出结果图，用于展示系统接入模型后在不同场景下的检测表现，三组样本分别覆盖相对清晰场景、弱纹理场景与复杂背景场景，以便观察模型在目标可见性与背景干扰变化条件下的输出差异。




图 5.5 样本 A 的系统输出结果图：目标边界相对清晰场景下的检测结果示例




图 5.6 样本 B 的系统输出结果图：弱纹理与低对比度条件下的检测结果示例



图 5.7 样本 C 的系统输出结果图：复杂背景干扰条件下的检测结果示例

结合图 5.5 至图 5.7 可以观察到：当目标边界清晰时，系统输出结果较稳定；而当目标纹理弱、对比度降低时，漏检风险上升；当背景纹理复杂时，误检风险增加，该结果与第四章中的定量与定性分析结论一致，说明系统侧结果展示能够较好反映模型在不同样本条件下的行为差异。

5.10 模块测试用例设计

为验证系统在正常与极端条件下的可用性，本文的测试覆盖了接口层、任务调度层、结果展示层和持久化层，按模块设计的测试用例如表 5.3 所示。

5.10.1 测试执行结果

基于表 5.3 的用例集合，本文完成了功能与异常场景的联调测试。测试结果表明，正常流程下任务提交、异步执行、结果回看和 CSV 导出均可稳定完成；异常流程下空输入、阈值越界、无效任务编号和模型异常也均能够返回可解释错误信息，且不会影响其他任务状态。

在服务重启后的历史任务复查测试中，任务记录与结果文件索引能够正确恢复；在高频轮询与并发查询场景下，任务状态字段保持一致，未观察到明显的数据库错乱。

表 5.3 系统主要模块测试用例

模块	用例类型	输入/场景	期望结果
任务提交	正常	合法图片 + 合法阈值	返回 <code>task_id</code> ，任务状态进入 <code>queued/running</code>
任务提交	极端	空文件、超限文件、阈值越界	请求被拒绝，返回明确错误信息
任务执行	正常	单图/批量任务	状态按 <code>queued->running->done</code> 演进，结果落盘
任务执行	极端	模型权重缺失、推理中断	状态进入 <code>failed</code> ，错误信息可追溯
结果查询	正常	已完成任务详情查询	返回可视化链接、结构化 <code>bbox</code> 、统计字段
结果查询	极端	不存在 <code>task_id</code>	返回 <code>404</code> 或业务错误码，不影响其他任务
数据持久化	正常	服务重启后查询历史任务	历史任务记录与结果仍可访问
数据持久化	极端	高频轮询与并发查询	状态字段一致，无明显数据错乱

上述结果表明，当前系统实现能够满足本课题对可用性、可观测性与可追溯性的基本要求。

5.11 系统响应速度优化

系统联调结果显示，模型本身的推理耗时并不高，但端到端页面返回结果的时间相对较长。进一步检查表明，等待时间并非主要消耗在检测模型上，而是分散在融合模式串行调用、重复图像解码、运行期间拉取完整结果、数据库频繁提交和结果接口重复解析等环节。因此，本文将优化重点放在端到端响应时间，而非单个模型函数耗时上。

5.11.1 性能瓶颈分析与优化思路

在对当前系统的任务提交、推理执行和结果展示三段流程进行检查后，发现主要性能开销集中在七处：融合模式下多模型默认串行；任务运行期间前端反复请求完整结果；可视化阶段对同一张大图多次执行 `Image.open`；批量任务逐图提交数据库事务；结果接口重复解析数据集信息和参考框；任务输入阶段复制源图；首次推

理时才加载模型权重。

针对上述问题，本文分别从融合推理并发执行、前端进度轮询、图像对象传递、批量任务分段提交、数据缓存、输入文件准备方式以及模型预加载等方面进行了优化，以减少端到端整体流程中的等待时间。各项优化均遵循“可配置、可回退”原则，在不破坏原有功能的前提下逐步引入性能改进，并通过微基准测试验证其实际效果。下文将依次介绍并行推理与模型预加载、前端轮询重构、渲染与存储优化等关键措施的具体实现。

5.11.2 并行推理与模型预加载机制

融合模式需要对于同一张图像调用多个模型，再合并其检测结果。初始实现按顺序执行，总耗时接近各模型耗时之和。为减少这部分的等待时间，后端推理运行时加入了基于 `ThreadPoolExecutor` 的并行推理机制，并通过环境配置控制并行模型数。并行度设为 1 时仍按串行执行；而当 GPU 资源较充足时，可以选择性地提高并行度来缩短融合推理时间。融合后处理阶段采用加权框融合思路统一多模型候选框^[34]，并与常见非极大值抑制类方法的设计取向保持一致^[35]。

并行机制未被设为默认开启。原因在于线程争抢会使单模型耗时上升，三模型并行也可能带来显存竞争。因此，本文保留默认并行度为 1，仅在资源允许时手动提高并行度，以增强系统在不同机器上的稳定性。

另外，优化后的系统在 `startup` 阶段预加载已启用模型权重，避免在第一次提交任务时才初始化模型。该改动虽然不改变稳态吞吐量，但能够减少首次推理的额外等待时间。

5.11.3 进度端点与前端轮询重构

优化前，任务详情页每 4 秒轮询一次，并同时请求任务详情和完整结果。该实现较为直接，但存在明显不足：任务实际完成后，页面最多仍需等待 4 秒才会刷新，且任务运行期间反复请求结果接口也会产生不必要的数据传输和后端解析开销。

针对该问题，后端新增进度查询接口，只返回 `status`、`done_count` 和 `input_count` 等字段；前端则改为两阶段轮询：当任务处于 `running` 时，每 1.5 秒请求进度接口，只更新任务进度条和状态；当任务转为 `done` 或 `failed` 后，再请求结果接口并加载完整检测数据和可视化产物。调整后，高频轮询响应由约 25KB 缩减到约 64B，页面

感知延迟也相应降低。

5.11.4 渲染、存储与结果访问优化

可视化渲染阶段原本会多次打开同一张图。为此，本文对 `render_detections` 函数的输入方式进行了扩展，使其既能接收图像路径，也能直接接收 `PIL.Image` 对象。因此，在融合模式下，系统只需打开一次原始图像，即可完成多个模型结果和融合结果的渲染。

针对批量任务，数据库提交策略也作了调整。原先每处理一张图就立即提交，现在改为每处理两张图或到达任务末尾时提交一次。该改动既保留阶段性进度，又减少事务提交次数；同时在结果接口中加入数据集信息和参考框缓存，避免同一张图片多次查询时重复遍历目录和解析标注。

在输入文件准备阶段，系统优先使用符号链接代替物理复制，以减少大图 I/O；若符号链接创建失败，则回退到复制方案。上述优化共同缩短了任务从提交到结果展示之间的实际等待时间。

5.11.5 优化效果分析

为检验这些改动的实际效果，本文对几个关键环节进行了微基准测试，结果如表 5.4 所示。

表 5.4 系统响应速度优化的关键基准结果

优化项	优化前	优化后	提升倍数	说明
三模型融合推理	465.6 ms	156.2 ms	2.98×	3 个工作线程并行相对串行
前端结果可感知延迟	4.0 s	1.5 s	2.67×	运行期间改为进度轮询
大图可视化渲染	443.9 ms	336.1 ms	1.32×	4096×4096 图像由 4 次解码降为 1 次
批量任务数据库提交	62.6 ms	37.6 ms	1.66×	10 张图任务由逐图提交改为分段提交
输入文件准备	2.4 ms	0.8 ms	3.00×	优先符号链接，失败时回退复制

表 5.4 中的收益主要来自两类改动：一类是减少串行等待，如融合推理并行和进

度轮询；另一类是减少重复工作，如图像传递优化、结果缓存和分段提交。测试结果与实际联调时页面响应加快的现象一致，说明这些优化措施取得了预期效果。

5.12 本章总结

本章围绕遥感微小船舶检测系统的需求分析、总体设计与实现过程展开说明。文中明确了系统在模型管理、任务提交、结果展示、历史回看和持久化方面的功能与非功能需求，给出了系统总体架构、数据库设计、接口设计和关键任务流程，并结合真实模型接入结果展示了系统页面、输出案例、测试用例和执行结果，同时从端到端响应时间角度分析了性能瓶颈及优化效果。相关内容表明，本文不仅完成了模型推理能力的系统化封装，也为实验结果的任务化管理和可视化复查提供了工程实现基础。

6 总结与展望

6.1 工作总结

在方法层面，本文围绕遥感微小船舶检测任务，梳理了通用目标检测、小目标检测和遥感船舶检测的相关研究，并在统一实验协议下构建了可比较的研究框架。通过统一数据划分、评价指标、结果记录方式和推理入口，本文选取 DRENet、FCOS 和 YOLO26 作为专项方法、无锚框方法和单阶段方法的代表模型，从而为后续实验比较和系统接入提供了一致的方法基础。

在实验评估层面，本文基于 LEVIR-Ship 数据集对三类模型进行了系统比较，并结合主对比实验、定性样例分析以及阈值与输入尺寸消融实验，分析了不同模型在检出能力、误检控制、定位质量和部署效率方面的差异。实验结果表明，DRENet 与 YOLO26 在 AP50 上较为接近，但前者更偏召回优先，后者在精度与定位质量方面更为均衡；FCOS 的精度-召回率折中较好，但整体检出能力与效率相对偏弱。相关分析说明，遥感微小船舶检测结果不能仅依据单一指标判断，还需要结合误检、漏检和部署约束进行综合评价。

在系统设计与实现层面，本文采用 React、FastAPI 和 SQLite 构建了遥感微小船舶检测系统，将模型推理、任务调度、结果展示、历史回看和结构化存储纳入同一工作流程。系统完成了真实模型权重接入、单图与批量任务执行、结果可视化展示和历史任务查询等功能，使离线实验结果能够在系统环境中进行复查和回放。总体来看，本文的工作重点不在于提出新的检测网络，而在于围绕同一任务建立可复查的数据口径、实验记录与系统实现流程。

6.2 不足分析

当前工作已经完成主要目标，但仍有以下几处不足：

第一，DRENet 的推理流程不支持自定义输入尺寸，导致输入尺寸消融实验只能覆盖 FCOS 和 YOLO26，三模型在该维度上的比较不够完整。第二，FCOS 的训练配置（如主干网络选择、数据增强策略）与 DRENet 和 YOLO26 不完全对齐，可能对最终指标产生一定影响。第三，系统目前仅在本地环境完成联调，尚未在多平台或真实部署场景下验证稳定性和跨环境迁移能力。第四，消融实验仅覆盖置信度阈值和输入尺寸两个维度，未涉及数据增强、损失函数和后处理策略等其他可能影响模

型行为的因素。

这些问题不影响本文对三模型主要结论的有效性，但若要进一步提高评测严谨性和系统可迁移性，仍需补齐 DRENet 的尺寸消融、统一 FCOS 的训练配置、完善部署流程，并扩展消融维度。

6.3 未来展望

未来研究可从以下几个方面进一步展开：补充融合模式的统一离线评测，量化单模型结果与融合展示之间的关系；围绕 DRENet 和 YOLO26 的误检、漏检取舍继续调整阈值、后处理和融合策略；进一步整理 FCOS 的训练配置，以提高跨模型比较的严谨性；完善模型接入与部署流程；并在更多遥感场景和数据集上检验方法与系统的泛化情况。随着上述工作持续推进，现有系统还可进一步扩展为实验管理平台，例如将统一报告导出、批量回评和参数留痕接入同一工作流，使实验复查与系统展示共享更多底层能力。

参考文献

- [1] Shaoqing Ren, Kaiming He, Ross Girshick, Jian Sun. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]//Advances in Neural Information Processing Systems: vol. 28. 2015: 91-99.
- [2] Tsung-Yi Lin, Piotr Dollar, Ross Girshick, Kaiming He, Bharath Hariharan, Serge Belongie. Feature Pyramid Networks for Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 2117-2125.
- [3] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, Piotr Dollar. Focal Loss for Dense Object Detection[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 2999-3007.
- [4] Zhi Tian, Chunhua Shen, Hao Chen, Tong He. FCOS: Fully Convolutional One-Stage Object Detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 9626-9635.
- [5] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788.
- [6] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, Sergey Zagoruyko. End-to-End Object Detection with Transformers[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2020: 213-229.
- [7] Xizhou Zhu, Weijie Su, Lewei Lu, Bin Li, Xiaogang Wang, Jifeng Dai. Deformable DETR: Deformable Transformers for End-to-End Object Detection[C]//International Conference on Learning Representations (ICLR). 2021: 1-16.
- [8] Xuan Wang, Aoran Wang, Jinglei Yi, Yongchao Song, Abdellah Chehri. Small Object Detection Based on Deep Learning for Remote Sensing: A Comprehensive Review[J]. Remote Sensing, 2023, 15(13): 3265.
- [9] Tianqi Zhao, Yongcheng Wang, Zheng Li, Yunxiao Gao, Chi Chen, Hao Feng, Zhikang Zhao. Ship Detection with Deep Learning in Optical Remote-Sensing Images: A Survey of Challenges and Advances[J]. Remote Sensing, 2024, 16(7): 1145.
- [10] 杜紫薇, 周恒, 李承阳, 李忠博, 谢永强, 董昱辰, 齐锦. 面向深度卷积神经网络的小目标检测算法综述[J]. 计算机科学, 2022, 49(12): 205-218.
- [11] 廖龙杰, 吕文涛, 叶冬, 郭庆, 鲁竞, 刘志伟. 基于深度学习的小目标检测算法研究进展[J]. 浙江理工大学学报, 2023, 49-50(自科三): 331-343.
- [12] 王彦情, 马雷, 田原. 光学遥感图像舰船目标检测与识别综述[J]. 自动化学报, 2011, 37(9): 1029-1039.
- [13] 徐芳, 刘晶红, 孙辉, 王腾龙, 王璇. 光学遥感图像海面船舶目标检测技术进展[J]. 光学精密工程, 2021, 29(4): 916-931.
- [14] 宋志娜, 眭海刚, 李永成. 高分辨率可见光遥感图像舰船目标检测综述[J]. 武汉大学学报 (信息科学版), 2021, 46(11): 1703-1715.
- [15] 廖育荣, 王海宁, 林存宝, 李阳, 方宇强, 倪淑燕. 基于深度学习的光学遥感图像目标检测研究进展[J]. 通信学报, 2022, 43(5): 190-203.

- [16] 黄泽贤, 吴凡路, 傅瑶, 张宇, 蒋晓楠. 基于深度学习的遥感图像舰船目标检测算法综述[J]. 光学精密工程, 2023, 31(15): 2295-2318.
- [17] Jianqi Chen, Keyan Chen, Hao Chen, Zhengxia Zou, Zhenwei Shi. A Degraded Reconstruction Enhancement-Based Method for Tiny Ship Detection in Remote Sensing Images With a New Large-Scale Dataset[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.
- [18] Ross Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2014: 580-587.
- [19] Joseph Redmon, Ali Farhadi. YOLOv3: An Incremental Improvement[J]. arXiv preprint arXiv:1804.02767, 2018: 1-6.
- [20] Mingxing Tan, Ruoming Pang, Quoc V. Le. EfficientDet: Scalable and Efficient Object Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 10781-10790.
- [21] Hao Zhang, Feng Li, Shilong Liu, Lei Zhang, Hang Su, Jun Zhu, Lionel M. Ni, Heung-Yeung Shum. DINO: DETR with Improved DeNoising Anchor Boxes for End-to-End Object Detection [C]//International Conference on Learning Representations (ICLR). 2023: 1-19.
- [22] 张婷婷, 章坚武, 郭春生, 陈华华, 周迪, 王延松, 徐爱华. 基于深度学习的图像目标检测算法综述[J]. 电信科学, 2020, 36(7): 92-106.
- [23] 赵永强, 饶元, 董世鹏, 张君毅. 深度学习目标检测方法综述[J]. 中国图象图形学报, 2020, 25(4): 629-654.
- [24] Xue Yang, Jirui Yang, Junchi Yan, Yue Zhang, Tengfei Zhang, Zhi Guo, Xian Sun, Kun Fu. SCRDet: Towards More Robust Detection for Small, Cluttered and Rotated Objects[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 8231-8240.
- [25] Bharat Singh, Larry S. Davis. An Analysis of Scale Invariance in Object Detection – SNIP[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 3578-3587.
- [26] Bharat Singh, Mahyar Najibi, Larry S. Davis. SNIPER: Efficient Multi-Scale Training[C]// Advances in Neural Information Processing Systems: vol. 31. 2018: 9333-9343.
- [27] Mahyar Najibi, Bharat Singh, Larry S. Davis. AutoFocus: Efficient Multi-Scale Inference[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 9744-9754.
- [28] Gong Cheng, Junwei Han. A Survey on Object Detection in Optical Remote Sensing Images[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2016, 117: 11-28.
- [29] 聂光涛, 黄华. 光学遥感图像目标检测算法综述[J]. 自动化学报, 2021, 47(8): 1749-1768.
- [30] 李晨鑫, 胥辉旗, 钱坤, 邓博元, 冯泽钦. 基于深度学习的舰船目标检测技术综述[J]. 兵器装备工程学报, 2021, 42(12): 57-63.
- [31] Kai Chen, Jiaqi Wang, Jiangmiao Pang, Yuhang Cao, Yu Xiong, Xiaoxiao Li, Shuyang Sun, Wansen Feng, Ziwei Liu, Jiarui Xu, Zheng Zhang, Dazhi Cheng, Chenchen Zhu, Tianheng Cheng, Qijie Zhao, Buyu Li, Xin Lu, Rui Zhu, Yue Wu, Jifeng Dai, Jingdong Wang, Jianping Shi, Wanli

- Ouyang, Chen Change Loy, Dahua Lin. MMDetection: Open MMLab Detection Toolbox and Benchmark[J]. arXiv preprint arXiv:1906.07155, 2019: 1-13.
- [32] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollar, C. Lawrence Zitnick. Microsoft COCO: Common Objects in Context[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2014: 740-755.
- [33] Mark Everingham, Luc Van Gool, Christopher K. I. Williams, John Winn, Andrew Zisserman. The PASCAL Visual Object Classes (VOC) Challenge[J]. International Journal of Computer Vision, 2010, 88(2): 303-338.
- [34] Roman Solovyev, Weimin Wang, Tatiana Gabruseva. Weighted Boxes Fusion: Ensembling Boxes from Different Object Detection Models[J]. Image and Vision Computing, 2021, 107: 104117.
- [35] Navaneeth Bodla, Bharat Singh, Rama Chellappa, Larry S. Davis. Soft-NMS – Improving Object Detection with One Line of Code[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 5561-5569.

致谢

这篇论文从选题到定稿，经历了实验、联调和反复修改等多个阶段，在此过程中得到过许多帮助。在论文完成之际，谨向一直给予支持和帮助的老师、同学与朋友表示感谢。

首先感谢指导教师。无论是选题方向、实验安排，还是系统实现和论文修改，老师都给予了许多具体而细致的指导。许多原本较为零散的思路，最终能够整理成现在的版本，离不开这些宝贵建议。

同时感谢在实验和系统联调整个过程中给予帮助的同学和朋友。模型训练、环境配置、页面体验和结果分析中遇到的多项问题，都是在与他们的交流和协作中逐步发现并解决的。

由于时间和精力有限，论文中仍然可能存在不足之处，恳请老师批评指正。

作者：邝黄硕

2026 年 5 月 30 日